TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
HCM·UTE
HCMC University of Technology and Engineering

BÁO CÁO MÔN BIG DATA

XÂY DỰNG HỆ THỐNG THU THẬP, LƯU TRỮ VÀ PHÂN TÍCH DỮ LIỆU SẢN PHẨM MỸ PHẨM VÀ CHĂM SÓC CÁ NHÂN TỪ HASAKI VÀ COCOLUX

Nhóm thực hiện: **Nhóm 5**
Giảng viên hướng dẫn: **Th.S Trần Quang Khải**

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

BỐI CẢNH & LÝ DO CHỌN ĐỀ TÀI

- Ngành Làm đẹp và Chăm sóc cá nhân chiếm **14%** thị phần TMĐT trong quý III và IV/2025.
- Dữ liệu sản phẩm trên Hasaki và Cocolux phân tán, chưa được hệ thống hóa, gây khó khăn cho việc so sánh giá và khuyến mãi.
- Cần xây dựng hệ thống thu thập, chuẩn hóa và phân tích dữ liệu tự động.

MỤC TIÊU ĐỀ TÀI

- Tự động thu thập dữ liệu từ Hasaki và Cocolux.
- Làm sạch, chuẩn hóa và lưu trữ dữ liệu tập trung.
- Phân tích, trực quan hóa nhằm nhận diện đặc điểm thị trường, định giá và khuyến mãi.

PHẠM VI DỮ LIỆU

6.486
Hasaki

2.930
Cocolux

9.416 sản phẩm
Dữ liệu thu thập ban đầu từ 2 website

5 nhóm danh mục: Chăm sóc da · Trang điểm · Chăm sóc cơ thể · Chăm sóc tóc · Nước hoa

Trường dữ liệu: Tên sản phẩm, thương hiệu, giá bán, giá gốc, dung tích, xuất xứ, đánh giá, khuyến mãi và các thông tin liên quan.

CHƯƠNG 2. THU THẬP DỮ LIỆU

Nguồn dữ liệu và quy trình thu thập

NGUỒN DỮ LIỆU

HASAKI

6.486
sản phẩm

COCOLUX

2.930
sản phẩm

5 nhóm danh mục chung

- Chăm sóc da
- Trang điểm
- Chăm sóc tóc
- Chăm sóc cơ thể
- Nước hoa

▶ Đối chiếu danh mục giữa hai website và loại trùng theo URL sản phẩm.

QUY TRÌNH THU THẬP

Python + Playwright
Điều khiển trình duyệt Chromium tự động

1. **Thu thập đường dẫn**
   Cuộn trang, bấm Xem thêm, chuyển trang và lấy URL.
2. **Đọc thông tin sản phẩm**
   Ưu tiên JSON-LD, kết hợp HTML, nhãn và Regex.
3. **Lưu dữ liệu**
   Ghi từng bản ghi vào JSONL, sau đó tổng hợp Excel.
4. **Kiểm tra độ đầy đủ**
   Thống kê dữ liệu từng trường và đánh dấu required_ok.

» **Thu thập song song 2 nguồn**

KẾT QUẢ THU THẬP

9.416
Bản ghi dữ liệu thô
19 trường dữ liệu / sản phẩm

Nguyên tắc thu thập

- Nghỉ ngẫu nhiên 2–4 giây giữa các sản phẩm.
- Ghi dữ liệu liên tục để có thể chạy tiếp.
- Không tự động vượt CAPTCHA.

Khó khăn chính
Website tải bằng JavaScript, phân trang không đồng nhất, CAPTCHA và một số trường thông tin bị thiếu.

CHƯƠNG 3. LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU

3.1. Làm sạch và chuẩn hóa dữ liệu bằng Python

Quy trình 6 bước

1. **clean_hasaki.py**
   sửa review_count bất thường, bỏ cột sold
2. **clean_cocolux.py**
   loại 3 trang lỗi "404", chuẩn hóa product_code
3. **merge_products.py**
   gộp hai nguồn
4. **clean_merged.py**
   chuẩn hóa origin, brand; xử lý giá, rating, tồn kho
5. **fix_brand.py**
   chuẩn hóa lại brand trên tệp Excel
6. **check_final_data.py**
   kiểm tra chất lượng

Lỗi chính và cách xử lý

Lỗi	Cách xử lý
Trang lỗi "404", giá 60đ, thiếu mã	Loại 5 dòng
6 mã sản phẩm trùng	Kiểm tra thủ công, giữ 1 URL, loại 6 dòng
origin viết nhiều cách	44 → 26 giá trị
brand không đồng nhất (hoa/thường, &)	Viết HOA, gộp biến thể: 616 → 488
2 sản phẩm brand "Blog làm đẹp"	Sửa thành PERSPIREX, BESILKI
rating có điểm nhưng 0 lượt đánh giá	Đặt thành thiếu (1.971 sản phẩm)

Kết quả

11 dòng bị loại
(0,12% dữ liệu thô)

19 → 17 cột
(bỏ sold, skin_type)

- Không còn dòng, URL hay mã sản phẩm trùng
- Mức giảm giá nhất quán trên 9.405 sản phẩm

Còn thiếu:

rating	origin	volume
59,42%	32,07%	20,23%

CHƯƠNG 3. LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU

3.2. LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU

QUY TRÌNH THỰC HIỆN

1. **Nạp dữ liệu**
   Upload products_final.xlsx lên Google Colab (9.405 dòng, 17 cột).
2. **Kiểm tra dữ liệu trùng lặp**
   Kiểm tra trùng toàn bộ dòng, URL và tổ hợp source + name + brand + product_code.
3. **Phát hiện lỗi định dạng**
   Kiểm tra product_code; phát hiện 1 dòng không đúng định dạng số.
4. **Loại bỏ bản ghi lỗi**
   Xóa 1 dòng có product_code không hợp lệ.
5. **Chuẩn hóa dữ liệu**
   Tách volume thành volume_value và volume_unit; chuẩn hóa đơn vị và kiểu dữ liệu.

NỘI DUNG LÀM SẠCH & CHUẨN HÓA

LÀM SẠCH

- Kiểm tra trùng lặp: không phát hiện bản ghi trùng.
- product_code: chuyển sang kiểu chuỗi để bảo toàn số 0 ở đầu; loại 1 dòng sai định dạng.

CHUẨN HÓA

- volume: tách giá trị và đơn vị đo.
- Quy đổi đơn vị: gr → g; l → ml; kg → g.
- Kiểu dữ liệu: scraped_at → Date; product_code → string; bổ sung volume_value, volume_unit.

products_clean.xlsx

KẾT QUẢ SAU XỬ LÝ

CHỈ TIÊU	FILE GỐC	FILE SẠCH
Tổng bản ghi	9.405	9.404
Số trường	17	19
Hasaki	6.482	6.481
Cocolux	2.923	2.923

Dữ liệu được loại bỏ bản ghi lỗi, chuẩn hóa đơn vị đo và kiểu dữ liệu, sẵn sàng cho phân tích.

3.2. Làm sạch và chuẩn hóa dữ liệu (kiểu dữ liệu)

Bảng thuộc tính trước chuẩn hóa

Thuộc tính	Ý nghĩa	Kiểu gốc	Kiểu sau chuẩn hóa
source	Nguồn dữ liệu	string	string
category_group	Nhóm ngành hàng	string	string
category	Danh mục	string	string
url	Đường dẫn sản phẩm	string	string
name	Tên sản phẩm	string	string
brand	Thương hiệu	string	string
product_code	Mã sản phẩm	int64	string
price	Giá bán (VND)	int32	int32
price_original	Giá gốc (VND)	int32	int32
discount_pct	% giảm giá	int32	int32

Bảng thuộc tính sau chuẩn hóa

Thuộc tính	Ý nghĩa	Kiểu gốc	Kiểu sau chuẩn hóa
rating	Điểm đánh giá	Mixed	string
review_count	Số lượt đánh giá	int64	int32
in_stock	Còn hàng (0/1)	int64	int32
volume	Dung tích (chuỗi gốc)	String	string
origin	Xuất xứ	String	string
scraped_at	Thời điểm thu thập	String	Date
required_ok	Có đạt yêu cầu	Boolean	Boolean
volume_value	Giá trị dung tích	(không có)	String
volume_unit	Đơn vị dung tích	(không có)	String

Dữ liệu sau khi chuẩn hóa đảm bảo đúng nhất quán, chính xác và dễ dàng phân tích.

CHƯƠNG 4 . THIẾT KẾ LƯU TRỮ DỮ LIỆU

MongoDB Compass - BIGDATA_CUOIKI/DATA.product_clean

Connections Edit View Collection Help

Compass

My Queries

Data Modeling

CONNECTIONS (4)

Search connections

- BIGDATA_CUOIKI
  - DATA
    - app_metadata
    - audit_log
    - counters
    - **product_clean**
    - users
- cluster.bgtht0j.mongodb.net
- localhost:27017
- localhost:27017

Welcome | DATA | product_clean

BIGDATA_CUOIKI > DATA > product_clean

Open MongoDB shell

Documents 9.4K | Aggregations | Schema | Indexes 3 | Validation

Type a query: { field: 'value' } or Generate query

Explain | Reset | Find | Options

ADD DATA | BULK | EXPORT DATA | EXPORT CODE

100 | 1 – 100 of 9404


```
{
  "_id": {...},
  "source": "hasaki",
  "category_group": "Chăm sóc da",
  "category": "Chăm sóc da mặt",
  "url": "https://hasaki.vn/san-pham/combo-cocoon-nuoc-can-bang-sen-hau-giang-310ml-nuoc-tay-trang-bi-dao-500ml-124096.html",
  "name": "Combo Cocoon Nước Cân Bằng Sen Hậu Giang 310ml + Nước Tẩy Trang Bí Đao 500ml",
  "brand": "COCOON",
  "product_code": "422222531",
  "price": 268000,
  "price_original": 590000,
  "discount_pct": 55,
  "rating": "4.9",
  "review_count": 13,
  "in_stock": true,
  "volume": "500ml",
  "origin": "Việt Nam",
  "scraped_at": {...},
  "required_ok": true,
  "volume_value": "500",
  "volume_unit": "ml",
  "id": 1
}
```

```
{
  "_id": {...},
  "source": "hasaki",
  "category_group": "Chăm sóc da",
  "category": "Chăm sóc da mặt",
  "url": "https://hasaki.vn/san-pham/kem-duong-vichy-lam-sang-san-chac-da-ban-dem-50ml-93797.html",
  "name": "Kem Dưỡng Vichy Sáng Da, Mờ Thâm Nám Ban Đêm 50ml",
```

CHƯƠNG 5. TRỰC QUAN HÓA DỮ LIỆU VÀ DASHBOARD

DASHBOARD

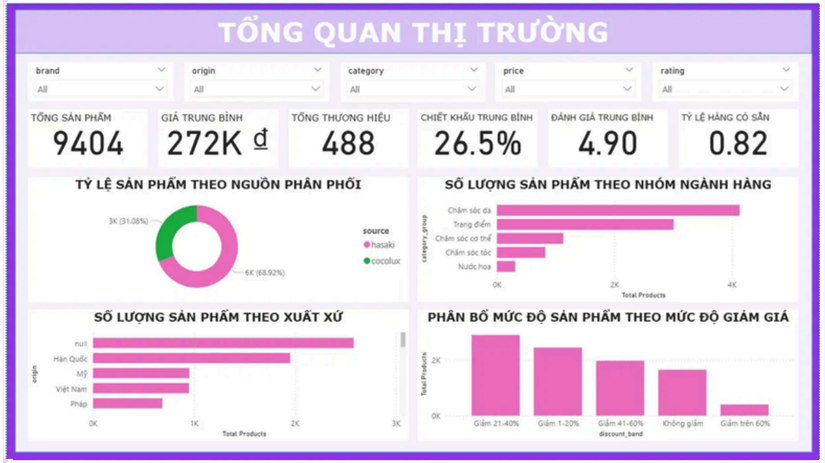

Dashboard tổng quan thị trường sản phẩm mỹ phẩm và chăm sóc cá nhân

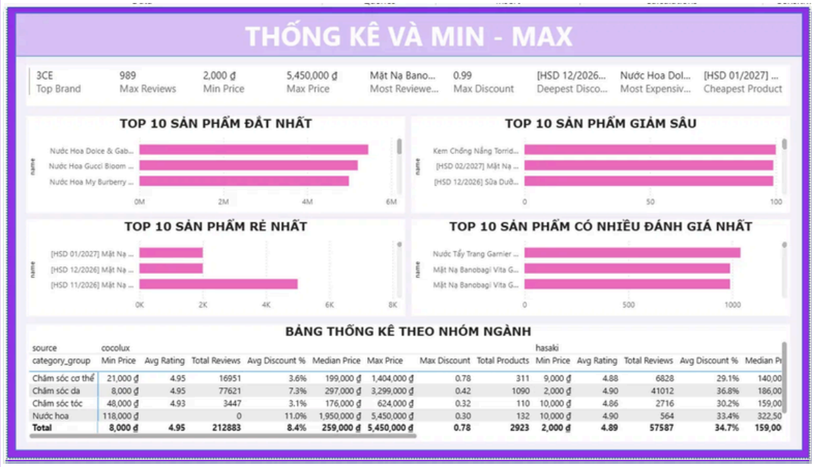

Dashboard thống kê và xác định giá trị Min – Max của sản phẩm

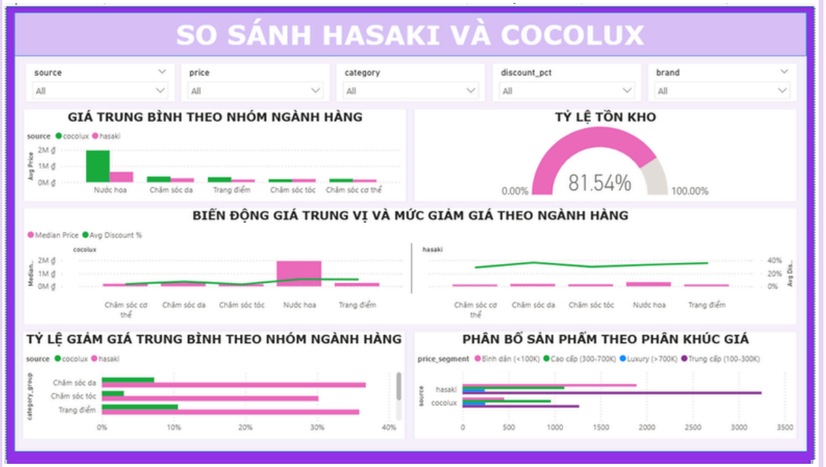

Dashboard so sánh sản phẩm giữa hai nền tảng Hasaki và Cocolux

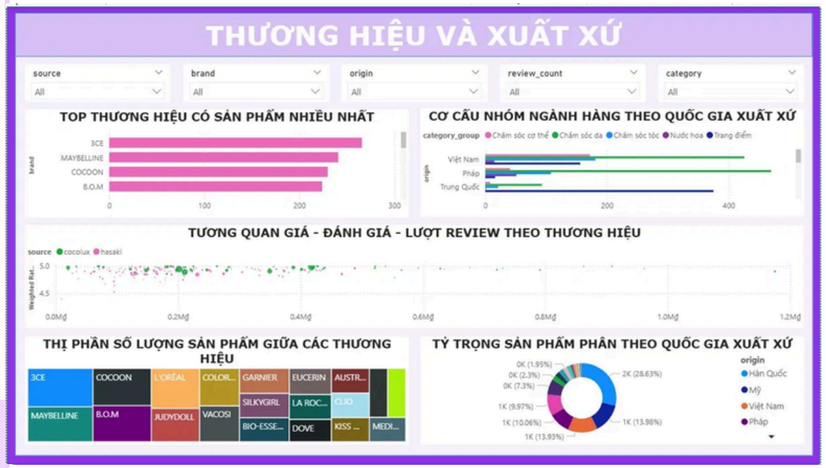

Dashboard phân tích thương hiệu và xuất xứ sản phẩm

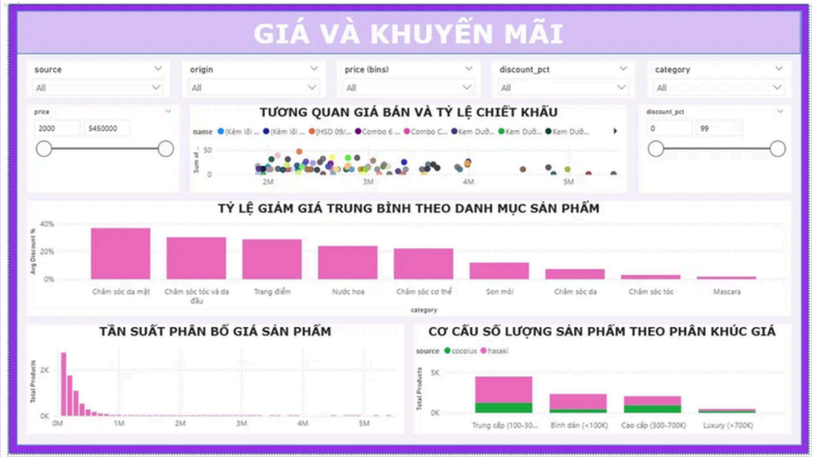

Dashboard phân tích giá bán và chương trình khuyến mãi

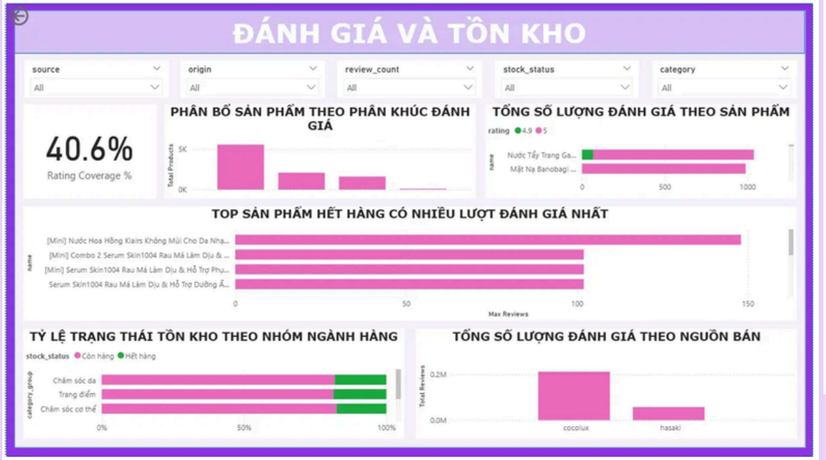

Dashboard phân tích đánh giá khách hàng và tình trạng tồn kho

CHƯƠNG 6. MÔ HÌNH HỌC MÁY

BỐN MÔ HÌNH · PHÂN KHÚC & DỰ ĐOÁN GIÁ

Tổng quan bốn mô hình

Không giám sát
Phân khúc thương hiệu
K-Means, K = 4, chạy riêng từng sàn

Có giám sát · hồi quy
Dự đoán giá niêm yết
Random Forest, sai lệch trung vị 14,6%

Có giám sát · phân loại
Dự đoán hết hàng
Random Forest, AUC 0,813, recall 0,724

Không giám sát
Phát hiện bất thường
IQR + Isolation Forest + LOF, 68 sản phẩm

9.392 sản phẩm · Hasaki **6.477** · Cocolux **2.915** · Chia **80%** học / **20%** kiểm tra · Kiểm định chéo **5 phần** · So với mô hình mốc · Seed **42** · chạy lại ~**5 phút**

Phân khúc thương hiệu

K-Means · K = 4

Hasaki · 213 thương hiệu
- Nhiều sản phẩm, nhiều combo (69)
- Giảm giá sâu, giá cao (67)
- Ít giảm giá, giá rẻ (61)
- Hay hết hàng, ít sản phẩm (16)

Silhouette 0,179 · nhóm chồng lấn

Cocolux · 132 thương hiệu
- Ít giảm giá, ít sản phẩm (57)
- Nhiều đánh giá, nhiều sản phẩm (36)
- Giảm giá sâu, giá cao (34)
- Nhiều combo, nhiều sản phẩm (5)

Silhouette 0,299 · tách nhóm rõ

Dự đoán giá niêm yết

Random Forest · 8.152 sản phẩm

0,839	0,863	14,6%
R^2 kiểm định chéo	R^2 tập kiểm tra	Sai lệch trung vị (Ridge: 23,8%)

Thương hiệu quyết định giá (mức quan trọng 0,876), sau đó là loại sản phẩm, combo và dung tích; sàn bán gần như không ảnh hưởng. Mô hình đoán thấp ở thiết bị (0,73), serum và toner; thêm dữ liệu sẽ còn cải thiện.

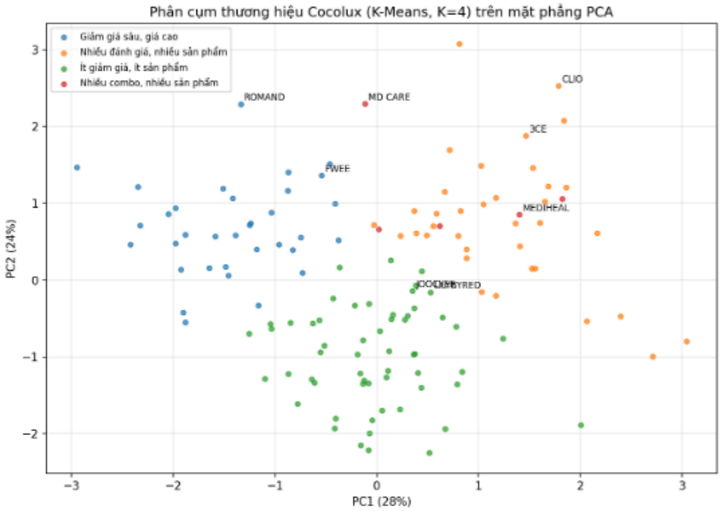

Phân cụm thương hiệu Cocolux trên mặt phẳng PCA

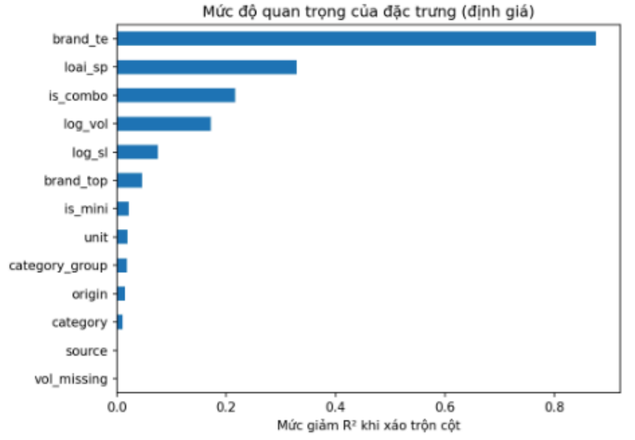

Mức quan trọng của đặc trưng · dự đoán giá

CHƯƠNG 6. MÔ HÌNH HỌC MÁY

HẾT HÀNG · BẤT THƯỜNG & ĐÁNH GIÁ

Dự đoán hết hàng

Random Forest · 5.263 sản phẩm Hasaki

0,813	92/127	0,241
AUC (Logistic mốc: 0,786)	Sản phẩm hết được bắt (recall 0,724)	Precision · 290 báo động giả

Cách xử lý

- Hàng cận hạn [HSD] dùng quy tắc riêng (90,5% đã hết hàng)
- Ngưỡng 0,376, ưu tiên không bỏ sót

Ý nghĩa

- Precision gấp đôi đoán ngẫu nhiên (0,12)
- Rút gọn danh sách cần rà tồn kho

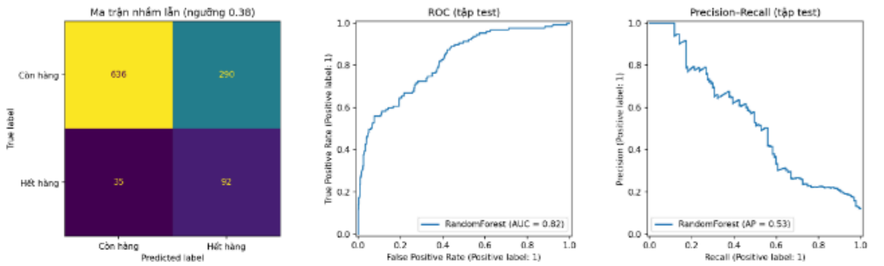

Ma trận nhầm lẫn · ROC · Precision–Recall (hết hàng)

Phát hiện bất thường

5.172 sản phẩm

IQR	+	Isolation Forest	+	LOF	→	≥ 2 phương pháp	→	Cả 3 phương pháp
160		104		104		68		12

Đặc điểm chung: giảm giá 85–89%, giá niêm yết cao gấp 6–13 lần giá dự đoán. Mô hình giá phát hiện thêm **154 sản phẩm** lệch giá quá 3 độ lệch chuẩn.

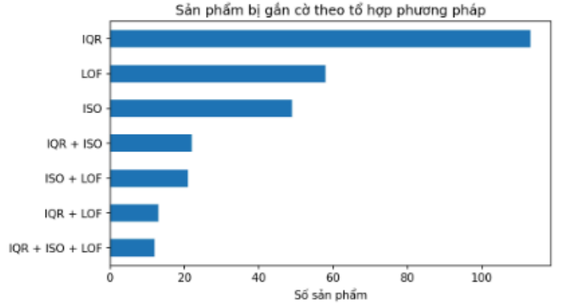

Sản phẩm bị gắn cờ theo tổ hợp phương pháp

Đánh giá chung

Giá niêm yết	Hết hàng	Phân khúc	Bất thường
Dùng làm giá tham chiếu	Chỉ dùng để sàng lọc	Mô tả, khám phá	Danh sách cần kiểm tra
Khá cao	Trung bình thấp	TB · thấp (Hasaki)	Chưa kiểm chứng

Hạn chế: dữ liệu chụp tại một thời điểm nên không dự báo xu hướng; thương hiệu mới bị đoán kém; danh sách bất thường chưa được kiểm tra thủ công.

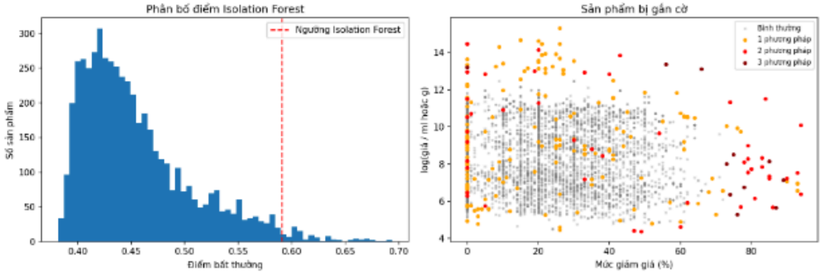

Điểm Isolation Forest & sản phẩm bị gắn cờ

CHƯƠNG 7. XÂY DỰNG HỆ THỐNG WEBSITE

KIẾN TRÚC HỆ THỐNG & LƯU TRỮ DỮ LIỆU

Công nghệ sử dụng

Python + Streamlit
Xây dựng và vận hành website

MongoDB + MongoDB Compass
Lưu trữ, truy vấn và quản lý dữ liệu

Pandas + NumPy
Làm sạch, xử lý và phân tích dữ liệu

Plotly
Trực quan hóa dữ liệu

Quy trình hoạt động

Dữ liệu Hasaki & Cocolux → **MongoDB** → **MongoDB Compass** → **Website Streamlit**

Thêm – sửa – xóa sản phẩm trên website sẽ được cập nhật trực tiếp vào MongoDB và có thể kiểm tra bằng MongoDB Compass.

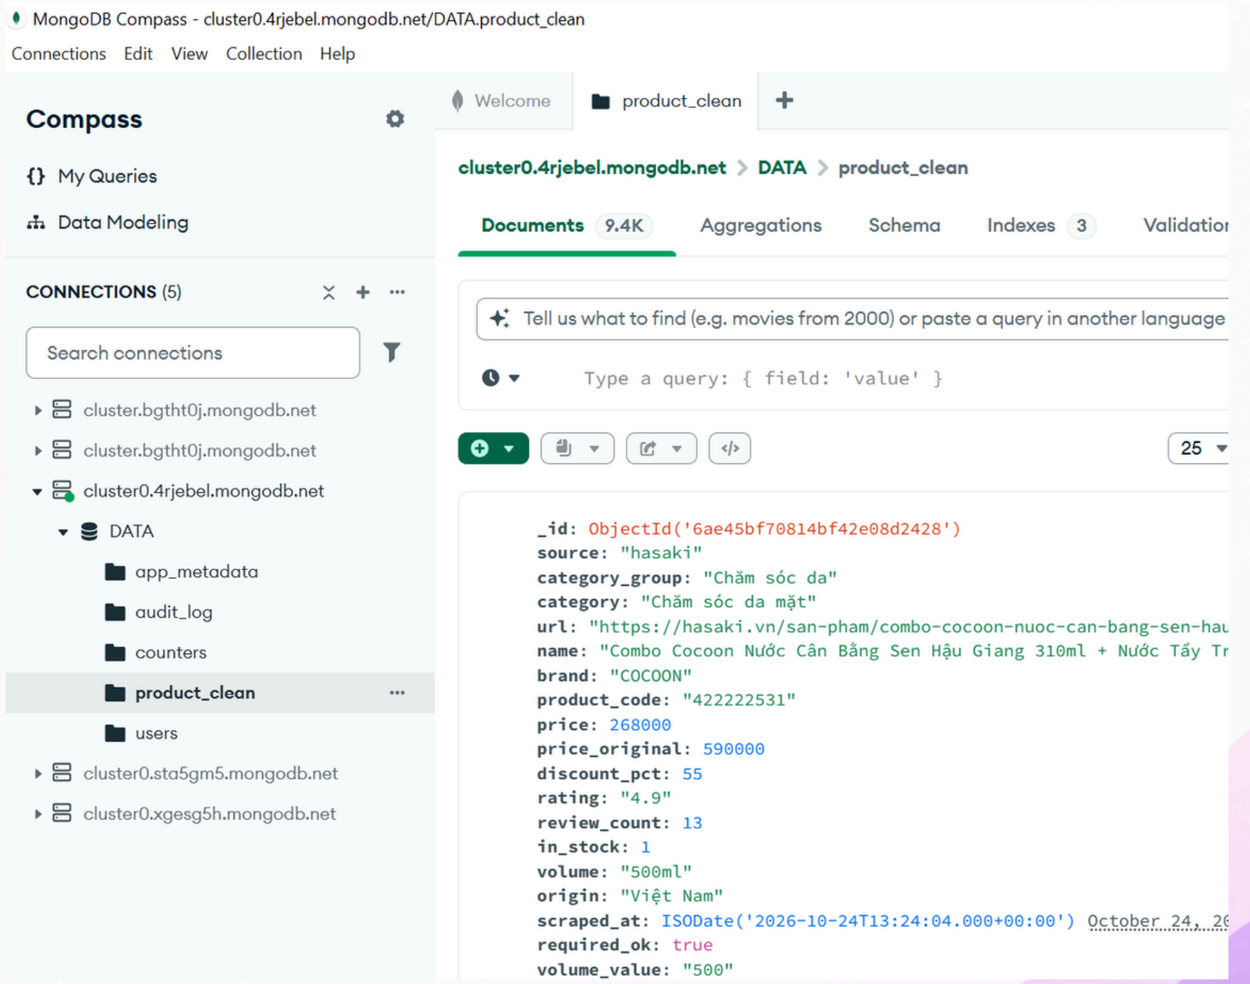

CHƯƠNG 7. XÂY DỰNG HỆ THỐNG WEBSITE

GIAO DIỆN & CÁC CHỨC NĂNG CHÍNH

01

Dashboard phân tích

- Tổng quan thị trường
- So sánh Hasaki – Cocolux
- Thương hiệu, giá, khuyến mãi, đánh giá và tồn kho

02

Đăng nhập & phân quyền

- **Admin:** Toàn quyền quản lý hệ thống
- **Editor:** Quản lý sản phẩm
- **Viewer:** Xem và phân tích dữ liệu

03

Tìm kiếm & lọc dữ liệu

- Lọc theo nguồn (Hasaki, Cocolux)
- Danh mục, thương hiệu
- Khoảng giá, mức giảm giá và các tiêu chí khác

04

CRUD & xuất báo cáo

- Thêm, xem, sửa, xóa sản phẩm trực tiếp trên website
- Dữ liệu được cập nhật vào MongoDB
- Xuất báo cáo dưới dạng CSV và Excel

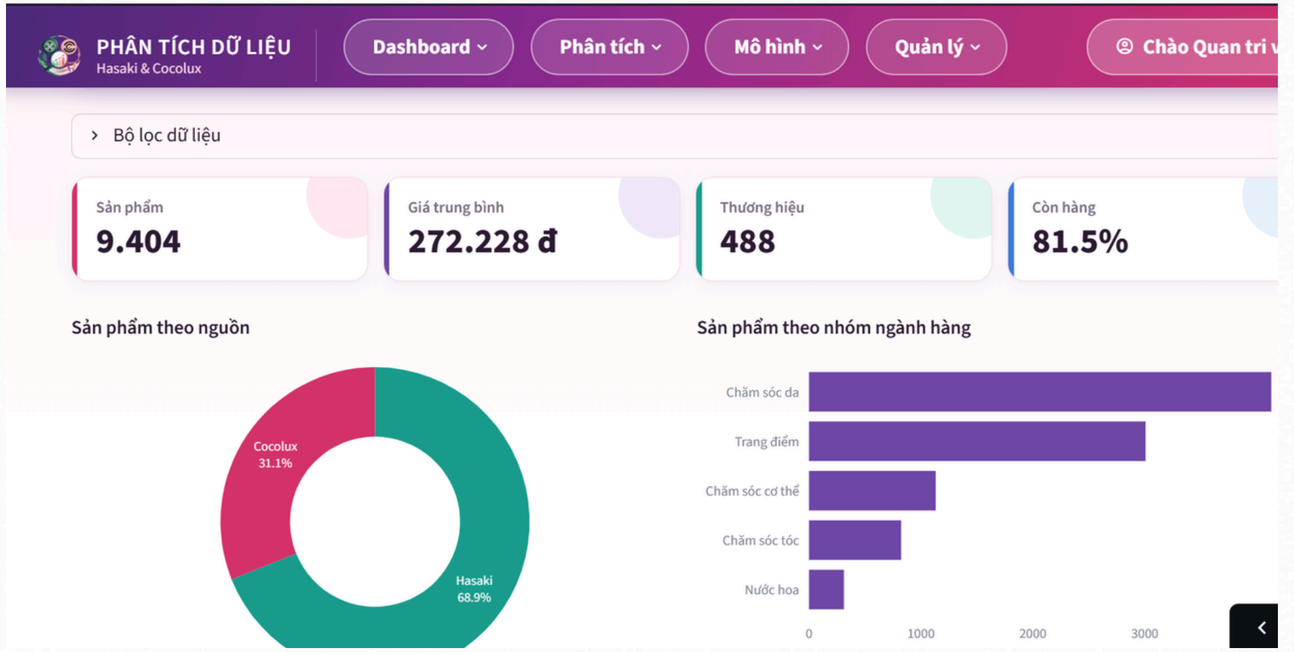

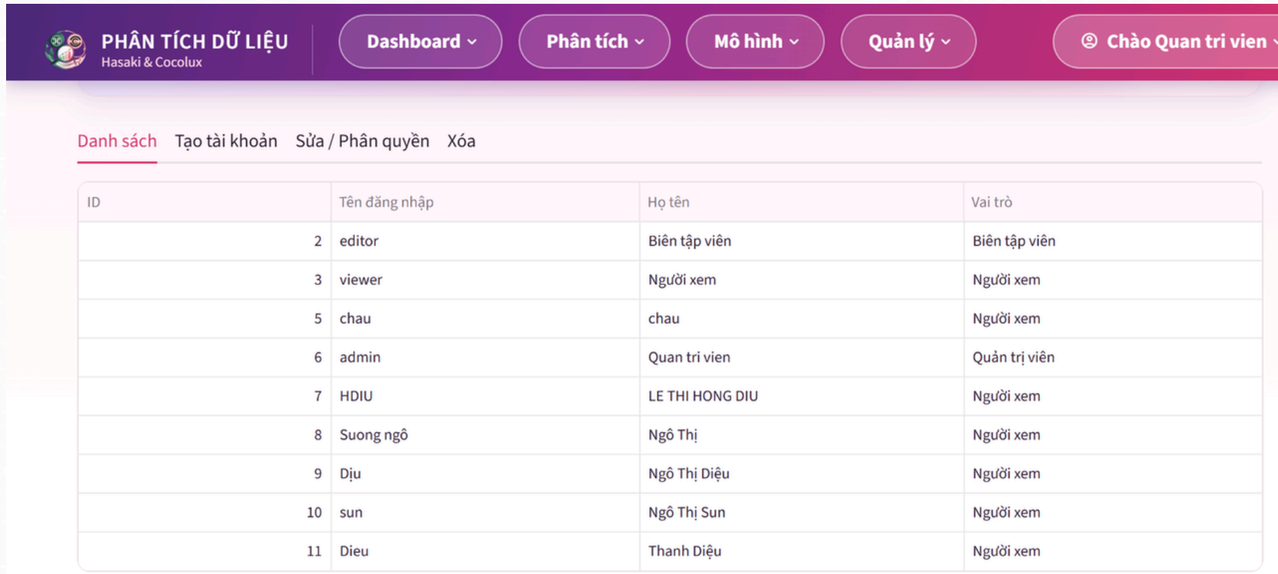

ID	Tên đăng nhập	Họ tên	Vai trò
2	editor	Biên tập viên	Biên tập viên
3	viewer	Người xem	Người xem
5	chau	chau	Người xem
6	admin	Quan tri vien	Quản trị viên
7	HDIU	LE THI HONG DIU	Người xem
8	Suong ngô	Ngô Thị	Người xem
9	Dịu	Ngô Thị Diệu	Người xem
10	sun	Ngô Thị Sun	Người xem
11	Dieu	Thanh Diệu	Người xem

CHƯƠNG 8. NHẬN ĐỊNH, ĐỀ XUẤT

NHẬN ĐỊNH VỀ DỮ LIỆU & ĐỀ XUẤT GIẢI PHÁP

Nhận định về dữ liệu

Chất lượng và độ phủ dữ liệu

9.404 sản phẩm
(Hasaki: 6,481, Cocolux: 2.923)

488 thương hiệu
(loại 12 bản ghi ~ 0,12%)

- Trường giá, giảm giá, thương hiệu có độ tin cậy cao
- Một số trường thiếu dữ liệu: Rating (59,4%), Origin (27,5%), Volume (20,2%)

Đặc điểm thị trường

43,9%
Chăm sóc da

32,0%
Trang điểm

3,3%
Nước hoa

Hasaki	Cocolux
34,7%	8,4%
chiết khấu TB	chiết khấu TB

- Khuyến mãi tập trung ở phân khúc giá thấp
- Hasaki giảm giá mạnh, Cocolux định vị cao cấp
- Thị trường phân tán, ít thương hiệu lớn

Kết quả các mô hình học máy

Mô hình	Kết quả chính	Nhận định
Dự đoán giá (Random Forest)	R^2 = 0,839; sai lệch 14,6%	Giá tham chiếu đáng tin cậy
Dự đoán hết hàng (Hasaki)	AUC = 0,813; Recall = 0,724	Hỗ trợ sàng lọc tồn kho
Phân khúc thương hiệu (K-Means)	Silhouette: 0,299 & 0,179	Tách nhóm khá rõ
Phân khúc khách hàng (K-Means)	Silhouette: 0,371 & 0,275	Phân khúc khách hàng hiệu quả

Đề xuất

1 Tối ưu chiến lược giá & khuyến mãi

- Hasaki: duy trì ưu đãi nhưng kiểm soát giảm giá sâu
- Cocolux: cân nhắc tăng khuyến mãi ở phân khúc phổ thông

2 Quản lý tồn kho hiệu quả

- Ưu tiên rà soát hàng HSD và nhôm hết hàng
- Đảm bảo nguồn cung cho sản phẩm có nhu cầu cao

3 Phát triển danh mục & thương hiệu

- Mở rộng nhôm nước hoa, thương hiệu cao cấp
- Đa dạng hóa thương hiệu để tăng sức hút

Kết luận

Dữ liệu cho thấy Hasaki cạnh tranh bằng giá, trong khi Cocolux định vị cao hơn về thương hiệu. Việc phân tich đúng đặc điểm thị trường và ứng dụng mô hình học máy sẽ giúp đưa ra chiến lược phù hợp, tối ưu hiệu quả kinh doanh.

TRƯỜNG ĐẠI HỌC
CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
HCM·UTE
HCMC University of Technology and Engineering

THANK YOU

Xin cảm ơn thầy và các bạn đã lắng nghe