BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP.HCM

KHOA CÔNG NGHỆ THÔNG TIN



MÔN HỌC: ỨNG DỤNG PHÂN TÍCH DỮ LIỆU LỚN TRONG KINH DOANH (BIG DATA)

XÂY DỰNG HỆ THỐNG THU THẬP, LƯU TRỮ VÀ PHÂN TÍCH DỮ LIỆU SẢN PHẨM MỸ PHẨM VÀ CHĂM SÓC CÁ NHÂN TỪ HASAKI VÀ COCOLUX

GVHD: Th.S Trần Quang Khải

Nhóm: 05

Sinh viên thực hiện:

1. Hoàng Thị Diệu Châu	24126022
2. Mai Ngọc Châu	24126023
3. Lê Thị Hồng Diệu	24126031
4. Trần Thị Thanh Diệu	24126032
5. Ngô Thị Sương	24126195

Mã lớp học: 261ABDA433708_03

Thành phố Hồ Chí Minh, Tháng 11 năm 2026

DANH SÁCH THÀNH VIÊN THAM GIA VIẾT BÁO CÁO

HỌC KÌ 1, NĂM HỌC: 2026 – 2027

Lớp: 261ABDA433708_03

Báo cáo đồ án: **XÂY DỰNG HỆ THỐNG THU THẬP, LƯU TRỮ VÀ PHÂN TÍCH DỮ LIỆU SẢN PHẨM MỸ PHẨM VÀ CHĂM SÓC CÁ NHÂN TỪ HASAKI VÀ COCOLUX**

STT	HỌ VÀ TÊN	MSSV	TỶ LỆ % HOÀN THÀNH
1	Hoàng Thị Diệu Châu	24126022	100%
2	Mai Ngọc Châu	24126023	100%
3	Lê Thị Hồng Diệu	24126031	100%
4	Trần Thị Thanh Diệu	24126032	100%
5	Ngô Thị Sương	24126195	100%

Trưởng nhóm: Hoàng Thị Diệu Châu - Sđt: 0326837327

Nhận xét của giảng viên:

.....
.....
.....
.....
.....

Ngày ..... tháng..... năm.....

Giảng viên chấm điểm

Th.S Trần Quang Khải

BẢNG PHÂN CÔNG NHIỆM VỤ
HỌC KÌ 1, NĂM HỌC: 2026 - 2027

Lớp: 261ABDA433708_03

Báo cáo đồ án: **XÂY DỰNG HỆ THỐNG THU THẬP, LƯU TRỮ VÀ PHÂN TÍCH DỮ LIỆU SẢN PHẨM MỸ PHẨM VÀ CHĂM SÓC CÁ NHÂN TỪ HASAKI VÀ COCOLUX**

STT	HỌ VÀ TÊN	MSSV	PHÂN CHIA NHIỆM VỤ
1	Hoàng Thị Diệu Châu	24126022	Chương 2, Nội dung phần 3.1
2	Mai Ngọc Châu	24126023	Chương 7
3	Lê Thị Hồng Diệu	24126031	Chương 5, Chương 8
4	Trần Thị Thanh Diệu	24126032	Chương 6
5	Ngô Thị Sương	24126195	Chương 1, Chương 4, Nội dung phần 3.2

Trưởng nhóm: Hoàng Thị Diệu Châu - Sđt: 0326837327

Nhận xét của giảng viên:

.....
.....
.....
.....
.....

Ngày ..... tháng..... năm.....

Giảng viên chấm điểm

Th.S Trần Quang Khải

MỤC LỤC

LỜI CẢM ƠN

DANH MỤC HÌNH ẢNH

DANH MỤC BẢNG

PHẦN NỘI DUNG

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI 1

1.1 Bối cảnh 1

1.2 Vấn đề kinh doanh và lý do chọn đề tài 1

1.3 Mục tiêu và câu hỏi phân tích 2

1.4 Phạm vi dữ liệu 3

1.5 Bố cục báo cáo 3

CHƯƠNG 2: THU THẬP DỮ LIỆU 5

2.1. Nguồn dữ liệu 5

2.2 Các trường dữ liệu 5

2.2.1 Trường bắt buộc 6

2.2.2 Trường không bắt buộc 6

2.2.3 Trường phụ trợ 6

2.3 Chương trình thu thập 7

2.3.1 Công nghệ sử dụng 7

2.3.2 Quy trình thu thập 7

2.3.3 Nguyên tắc thu thập 9

2.4 Kết quả thu thập 9

2.5 Khó khăn và cách xử lý 10

CHƯƠNG 3: LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU 12

3.1. Làm sạch và chuẩn hóa dữ liệu bằng Python 12

3.1.1 Tổng quan quy trình 12

3.1.2 Các vấn đề phát hiện trong dữ liệu thô 12

3.1.3 Kết quả tổng hợp 18

CHƯƠNG 4. THIẾT KẾ VÀ LƯU TRỮ DỮ LIỆU 22

4.1 Lựa chọn hệ quản trị cơ sở dữ liệu 22

4.2 Thiết kế cấu trúc lưu trữ 23

4.3 Nhập dữ liệu 26

4.4 Truy vấn minh họa 26

4.5 Sao lưu và phục hồi dữ liệu 36
CHƯƠNG 5. TRỰC QUAN HÓA DỮ LIỆU VÀ DASHBOARD 47
5.1 Các chỉ số thống kê và giá trị min–max 47
5.1.1. Mục đích thống kê dữ liệu 47
5.1.2 Thống kê tổng quan bộ dữ liệu 47
5.1.2 Thống kê theo nguồn dữ liệu 48
5.1.3 Giá trị min–max 49
5.1.4 Thống kê theo nhóm ngành và nguồn 50
5.2 Thiết kế dashboard 51
5.2.1 Nguyên tắc thiết kế 51
5.2.2 Trang 1 - Tổng quan thị trường 51
5.2.3 Trang 2 – Thống kê và Min–Max 52
5.2.4 Trang 3 – So sánh Hasaki và Cocolux 53
5.2.5 Trang 4 - Thương hiệu và Xuất xứ 54
5.2.6 Trang 5 - Giá và Khuyến mãi 55
5.2.7 Trang 6 – Đánh giá và Tồn kho 56
5.2.8 Tổng hợp các loại biểu đồ đã sử dụng 57
5.3 Các phát hiện chính 58
CHƯƠNG 6: MÔ HÌNH HỌC MÁY 61
6.1 Mô hình học không giám sát: phân khúc thương hiệu (K-Means) 64
6.2 Mô hình học có giám sát 72
6.2.1 Dự đoán giá niêm yết 72
6.2.2 Dự đoán hết hàng 78
6.3 Mô hình thứ ba: phát hiện bất thường (IQR + Isolation Forest + LOF) 82
6.4 Đánh giá và so sánh kết quả 87
CHƯƠNG 7. XÂY DỰNG HỆ THỐNG WEBSITE 89
7.1. Kiến trúc hệ thống 89
7.1.1. Mô hình kiến trúc tổng thể 89
7.1.2. Công nghệ và thư viện sử dụng 89
7.1.3. Tổ chức dữ liệu và các mô-đun 90
7.1.4. Thiết kế cơ sở dữ liệu và quy trình lưu trữ 91
7.2. Giao diện và chức năng chính 93
7.2.1. Nguyên tắc thiết kế giao diện 93
7.2.2. Các nhóm chức năng 93

7.2.3. Luồng tương tác của người dùng 94
7.3. Đăng nhập và phân quyền người dùng 95
7.3.2. Cơ chế bảo vệ tài khoản 96
7.3.3. Phân quyền theo vai trò 96
7.4. Tìm kiếm và lọc dữ liệu 98
7.4.2. Các điều kiện lọc 99
7.4.3. Xử lý và hiển thị kết quả 99
7.5. Quản lý dữ liệu 101
7.5.1. Tổng quan chức năng CRUD 101
7.5.2. Xem và tra cứu dữ liệu 101
7.5.3. Thêm sản phẩm (Create) 102
7.5.4. Cập nhật sản phẩm (Update) 103
7.5.5. Xóa sản phẩm (Delete) 103
7.5.6. Tính nhất quán, nhật ký và sao lưu 104
7.6. Xuất báo cáo thống kê 105
7.6.1. Mục đích của chức năng xuất báo cáo 105
7.6.2. Nội dung thống kê được tổng hợp 106
7.6.3. Xuất tệp CSV và Excel 106
CHƯƠNG 8. NHẬN ĐỊNH, ĐỀ XUẤT 109
8.1 Nhận định về dữ liệu 109
8.1.1 Nhận định về chất lượng và độ phủ của dữ liệu 109
8.1.2 Nhận định về đặc điểm thị trường 109
8.1.3 Nhận định về kết quả các mô hình học máy 110
8.2 Đề xuất kinh doanh 111
8.2.1 Đối với thương hiệu và nhà phân phối 111
8.2.2 Đối với nhà bán lẻ 112
8.3 Hạn chế 113
8.3.1 Hạn chế về dữ liệu 113
8.3.2 Hạn chế về mô hình học máy 113
8.3.3 Hạn chế về hệ thống 114
8.4 Hướng phát triển 114
PHẦN KẾT LUẬN 116
TÀI LIỆU THAM KHẢO 117

LỜI CẢM ƠN

Trước hết, nhóm chúng em xin gửi lời cảm ơn chân thành đến Thầy Trần Quang Khải, giảng viên học phần Ứng dụng phân tích dữ liệu lớn trong kinh doanh (Big Data), đã tận tình giảng dạy, truyền đạt những kiến thức chuyên môn và hướng dẫn nhóm trong suốt quá trình học tập cũng như thực hiện đồ án cuối kỳ.

Thông qua học phần, nhóm chúng em đã có cơ hội tiếp cận và tìm hiểu sâu hơn về vai trò của dữ liệu lớn trong hoạt động kinh doanh, từ quá trình thu thập, làm sạch, chuẩn hóa, lưu trữ dữ liệu đến phân tích, trực quan hóa và ứng dụng các mô hình học máy. Đặc biệt, những kiến thức được học đã giúp nhóm vận dụng vào việc thực hiện đề tài "Xây dựng hệ thống thu thập, lưu trữ và phân tích dữ liệu sản phẩm mỹ phẩm và chăm sóc cá nhân từ Hasaki và Cocolux".

Mặc dù đã cố gắng hoàn thành đồ án, do hạn chế về thời gian và kinh nghiệm, bài làm khó tránh khỏi những thiếu sót. Nhóm chúng em rất mong nhận được những nhận xét và góp ý từ Thầy để hoàn thiện đồ án tốt hơn.

Cuối cùng, nhóm chúng em xin kính chúc Thầy Trần Quang Khải thật nhiều sức khỏe, hạnh phúc và thành công trong công tác giảng dạy.

Nhóm chúng em xin chân thành cảm ơn Thầy!

DANH MỤC HÌNH ẢNH

Hình 2.1. Khai báo danh mục Hasaki cần thu thập 7
Hình 2.2. Khai báo danh mục Cocolux cần thu thập 7
Hình 2.3. Lấy tên và thương hiệu: ưu tiên JSON-LD, thiếu thì dùng cách dự phòng 8
Hình 3.1. Đoạn mã sửa khi tìm đúng 4 sản phẩm (clean_hasaki.py) 14
Hình 3.2. Đoạn mã xóa cột "sold" (clean_hasaki.py) 14
Hình 3.3. Đoạn mã xóa sản phẩm thiếu giá hoặc mã sản phẩm (clean_cocolux.py) 14
Hình 3.4. Đoạn mã giữ một URL cho mỗi mã trùng (clean_merged.py) 15
Hình 3.5. Tạo khóa so sánh và chuẩn hóa thương hiệu (fix_brand.py) 17
Hình 3.6. Đoạn mã sao lưu tệp trước khi ghi (fix_brand.py) 17
Hình 3.7. Upload file dữ liệu lên Google Colab 20
Hình 3.8. Kiểm tra và xử lý lỗi định dạng product_code 21
Hình 4.1. Giao diện MongoDB lưu trữ dữ liệu của nhóm 24
Hình 4.2. Ví dụ về 1 document 25
Hình 4.3. Kết quả thực thi câu lệnh đếm tổng số lượng bản ghi trong collection product_clean 27
Hình 4.4. Kết quả thống kê số lượng sản phẩm theo từng nhóm danh mục 27
Hình 4.5. Kết quả thống kê giá trung bình, giảm giá trung bình và tỉ lệ còn hàng theo nhóm 29
Hình 4.6. Kết quả thống kê tổng số lượng và giá trung bình theo các thương hiệu hàng đầu 30
Hình 4.7. Kết quả thống kê tổng số lượng và giá trung bình theo các thương hiệu hàng đầu 31
Hình 4.8. Kết quả thống kê tổng số lượng, giá trung bình và giảm giá trung bình theo xuất xứ sản phẩm 32
Hình 4.9. Lệnh truy vấn và kết quả thống kê Top 10 thương hiệu có tỷ lệ giảm giá sâu nhất (từ 30 sản phẩm trở lên) 33
Hình 4.10. Lệnh truy vấn và kết quả thống kê Top 10 thương hiệu có tỷ lệ giảm giá sâu nhất (từ 30 sản phẩm trở lên) 34
Hình 4.11. Lệnh truy vấn và kết quả tổng quan thống kê cho toàn bộ collection 35
Hình 4.12. Lệnh chạy hai lệnh kiểm tra phiên bản trong Command Prompt 37
Hình 4.13. Lệnh chạy hai lệnh kiểm tra phiên bản trong Command Prompt 38
Hình 4.14. Cấu trúc thư mục chứa các tệp sao lưu dữ liệu (.bson và .metadata.json) sau khi chạy script 39
Hình 4.15. Giao diện hiển thị các collection sau khi khôi phục dữ liệu 41

Hình 5.1. Dashboard tổng quan thị trường sản phẩm mỹ phẩm và chăm sóc cá nhân 52
Hình 5.2. Dashboard thống kê và xác định giá trị Min – Max của sản phẩm 53
Hình 5.3. Dashboard so sánh sản phẩm giữa hai nền tảng Hasaki và Cocolux 54
Hình 5.4. Dashboard phân tích thương hiệu và xuất xứ sản phẩm 55
Hình 5.5. Dashboard phân tích giá bán và chương trình khuyến mãi 56
Hình 5.6. Dashboard phân tích đánh giá khách hàng và tình trạng tồn kho 57
Hình 6.1. Sơ đồ trình tự chạy các bước, từ bước 0 đến website 64
Hình 6.2. Chọn số nhóm K cho Hasaki theo ba thước đo 66
Hình 6.3. Chọn số nhóm K cho Cocolux theo ba thước đo 67
Hình 6.4. Phân bố thương hiệu Hasaki theo 4 nhóm trên mặt phẳng PCA 68
Hình 6.5. Hồ sơ đặc trưng của 4 nhóm thương hiệu Hasaki 69
Hình 6.6. Phân bố thương hiệu Cocolux theo 4 nhóm trên mặt phẳng PCA 70
Hình 6.7. Hồ sơ đặc trưng của 4 nhóm thương hiệu Cocolux 71
Hình 6.8. Giá thật và giá dự đoán của Random Forest trên tập kiểm tra 75
Hình 6.9. Mức quan trọng của các đặc trưng trong mô hình dự đoán giá 76
Hình 6.10. Đường cong học của mô hình dự đoán giá 77
Hình 6.11. Tỷ lệ giá dự đoán so với giá thật theo loại sản phẩm 78
Hình 6.12. Ma trận nhầm lẫn, đường ROC và đường Precision-Recall của mô hình hết hàng 81
Hình 6.13. Mức quan trọng của các đặc trưng trong mô hình dự đoán hết hàng 82
Hình 6.14. Số sản phẩm bị gắn cờ theo tổ hợp phương pháp 85
Hình 6.15. Phân bố điểm Isolation Forest và vị trí các sản phẩm bị gắn cờ 85
Hình 7.1. Giao diện tổng quan của website phân tích mỹ phẩm Hasaki – Cocolux 93
Hình 7.2. Giao diện dashboard trực quan hóa dữ liệu 94
Hình 7.3. Giao diện đăng nhập và đăng ký tài khoản 96
Hình 7.4. Giao diện quản lý tài khoản và phân quyền người dùng 97
Hình 7.5. Giao diện tìm kiếm và lọc sản phẩm 100
Hình 7.6. Giao diện danh sách và tra cứu sản phẩm 102
..... 103
Hình 7.9. Giao diện xuất báo cáo thống kê 107

DANH MỤC BẢNG

Bảng 1.1. Bảng đối chiếu danh mục giữa hai nguồn....3
Bảng 2.1. Đối chiếu danh mục giữa hai nguồn....5
Bảng 2.2. Các trường bắt buộc....6
Bảng 2.3. Các trường không bắt buộc....6
Bảng 2.4. Số bản ghi thô theo nguồn và nhóm danh mục....9
Bảng 2.5. Số bản ghi có dữ liệu theo từng trường (dữ liệu thô)....9
Bảng 2.6. Khó khăn khi thu thập và cách xử lý....10
Bảng 3.1. Các chương trình làm sạch....12
Bảng 3.2. Vấn đề phát hiện và bước xử lý....12
Bảng 3.3. Các dòng bị xóa ở bước 4....15
Bảng 3.4. Các quy tắc sửa giá trị....15
Bảng 3.5. Một số thương hiệu được gộp bằng bảng đối chiếu....16
Bảng 3.6. Số dòng và số cột qua từng giai đoạn....18
Bảng 3.7. Các dòng bị xóa (tổng 11 dòng, khoảng 0,12% dữ liệu thô)....18
Bảng 3.8. Số sản phẩm theo nhóm danh mục....19
Bảng 3.9. Các cột còn thiếu dữ liệu trong bộ dữ liệu cuối....19
Bảng 4.1. Đặc điểm của dữ liệu....22
Bảng 4.2. Bảng mô tả cấu trúc các trường dữ liệu và kiểu dữ liệu trong collection sản phẩm....25
Bảng 4.3. Bảng tổng hợp môi trường và thông số kỹ thuật thực hiện sao lưu, phục hồi dữ liệu....36
Bảng 4.4. Bảng dữ liệu databasse DATA....37
Bảng 4.5. Mô tả ý nghĩa các tham số trong câu lệnh mongodump....38
Bảng 4.6. Thống kê số lượng document và tệp dữ liệu tương ứng sau khi thực hiện sao lưu39
Bảng 4.7. Mô tả ý nghĩa các tham số trong câu lệnh mongorestore....41
Bảng 4.8. Thống kê số lượng document và lỗi phát sinh sau khi khôi phục dữ liệu vào cơ sở dữ liệu đích....41
Bảng 4.9. So sánh dữ liệu trước và sau khi phục hồi....42
Bảng 5.1. Các chỉ số thống kê tổng quan....47
Bảng 5.2. So sánh các chỉ số giữa Hasaki và Cocolux....48
Bảng 5.3. Các giá trị nhỏ nhất và lớn nhất....49
Bảng 5.4. Thống kê theo nhóm ngành hàng và nguồn dữ liệu....50

Bảng 5.5. Các loại biểu đồ và mục đích sử dụng 57
Bảng 6.1. Tổng quan bốn mô hình học máy trong chương 61
Bảng 6.2. Các chỉ số đánh giá dùng trong chương 61
Bảng 6.3. Các tệp mã nguồn và trình tự chạy 62
Bảng 6.4. Các đặc trưng dùng để phân khúc thương hiệu 65
Bảng 6.5. Đặc điểm 4 nhóm thương hiệu Hasaki 67
Bảng 6.6. Đặc điểm 4 nhóm thương hiệu Cocolux 69
Bảng 6.7. So sánh K-Means với các thuật toán phân cụm khác 71
Bảng 6.8. Kết quả ba mô hình dự đoán giá niêm yết 74
Bảng 6.10. Ma trận nhầm lẫn của mô hình hết hàng tại ngưỡng 0,376 (tập kiểm tra) 80
Bảng 6.11. Các đặc trưng dùng để phát hiện bất thường 83
Bảng 6.12. Số sản phẩm bị gắn cờ theo từng phương pháp 84
Bảng 6.13. Năm sản phẩm có điểm Isolation Forest cao nhất 86
Bảng 6.14. So sánh tổng hợp bốn mô hình 87
Bảng 7.1. Các công nghệ và thư viện được sử dụng trong hệ thống website phân tích dữ liệu mỹ phẩm Hasaki - Cocolux 89
Bảng 7.2. Phân quyền sử dụng các chức năng website theo ba nhóm người dùng 96
Bảng 7.3. Cấu trúc và nội dung các trang tính trong tệp báo cáo Excel xuất từ website 106
Bảng 8.1. Nhận định về kết quả các mô hình học máy 110
Bảng 8.2. Bảng đề xuất kinh doanh 111
Bảng 8.3. Bảng hướng phát triển 114

PHẦN NỘI DUNG

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1 Bối cảnh

Ngành Làm đẹp và Chăm sóc cá nhân ngày càng khẳng định vai trò là một trong những ngành hàng chủ lực của thị trường thương mại điện tử (TMĐT) Việt Nam. Theo dữ liệu từ Metric (tổng hợp trên Shopee, Lazada và TikTok Shop), ngành này chiếm 14% tổng quy mô thị trường TMĐT trong cả quý III/2025 và quý IV/2025, duy trì thị phần ổn định qua hai quý liên tiếp.

Đáng chú ý, trong quý IV/2025, tổng doanh thu ngành ghi nhận 15,3 nghìn tỷ đồng, tăng trưởng 23% so với quý III/2025 và so với cùng kỳ năm 2024. Mức tăng trưởng này phản ánh nhu cầu tích cực đối với các sản phẩm Làm đẹp và Chăm sóc cá nhân, đặc biệt trong giai đoạn cuối năm khi các sàn đẩy mạnh chiến dịch khuyến mãi và kích cầu (Metric, 2025).

Nghiên cứu thị trường ngành Làm đẹp và Chăm sóc cá nhân ngày nay không chỉ đóng vai trò hỗ trợ mà là yếu tố sống còn trong môi trường cạnh tranh ngày càng gay gắt. Những doanh nghiệp đầu tư nghiêm túc vào nghiên cứu thị trường bài bản sẽ có lợi thế rõ rệt trong việc thấu hiểu khách hàng, đánh giá cạnh tranh, phát triển sản phẩm phù hợp và đưa ra quyết định chiến lược chính xác.

Bên cạnh các sàn TMĐT tổng hợp, thị trường còn có các chuỗi bán lẻ mỹ phẩm chuyên biệt vận hành đồng thời kênh cửa hàng và kênh trực tuyến, tiêu biểu là Hasaki và Cocolux. Khác với các sàn tổng hợp, danh mục sản phẩm trên các nền tảng này tập trung hoàn toàn vào làm đẹp và chăm sóc cá nhân, được trình bày theo cấu trúc danh mục, thương hiệu, dung tích, xuất xứ, mức giá và khuyến mãi tương đối rõ ràng. Đây là nguồn dữ liệu công khai có giá trị để quan sát cách các nhà bán lẻ định vị sản phẩm, định giá và cạnh tranh với nhau.

Tuy vậy, dữ liệu sản phẩm trên các website này nằm rải rác ở hàng nghìn trang, được trình bày dưới dạng văn bản tự do (ví dụ: tên sản phẩm lẫn dung tích, giá hiển thị dạng chuỗi ký tự) và thay đổi liên tục theo chương trình khuyến mãi. Muốn khai thác hiệu quả, cần một quy trình thu thập tự động, làm sạch, chuẩn hóa và lưu trữ trong một hệ thống thống nhất, làm nền tảng cho các phân tích định lượng. Đó là bối cảnh hình thành đề tài này.

1.2 Vấn đề kinh doanh và lý do chọn đề tài

Đối với thương hiệu, nhà phân phối và người bán trong ngành mỹ phẩm, các câu hỏi chiến lược thường gặp là: sản phẩm của mình đang được định giá cao hay thấp so với mặt bằng chung; đối thủ đang khuyến mãi mạnh ở nhóm hàng nào; thương hiệu nào đang chiếm ưu thế về độ phủ danh mục và mức độ quan tâm của khách hàng; phân khúc giá nào còn

khoảng trống. Việc trả lời các câu hỏi này bằng cách duyệt web thủ công vừa tốn thời gian, vừa thiếu tính hệ thống và không thể lặp lại.

Cụ thể, có những khăn chính:

- Dữ liệu phân tán: thông tin nằm trên nhiều website, mỗi website có cấu trúc danh mục và cách trình bày riêng, gây khó khăn cho việc so sánh trực tiếp.

- Dữ liệu phi cấu trúc: dung tích, xuất xứ, giá gốc, giá bán đều xuất hiện dưới dạng văn bản, cần được tách và chuẩn hóa về kiểu dữ liệu phù hợp trước khi tính toán.

- Dữ liệu biến động: giá và mức giảm giá thay đổi theo từng đợt khuyến mãi, nên cần ghi nhận kèm mốc thời gian thu thập để có thể theo dõi và đối chiếu.

- Thiếu nền tảng lưu trữ tập trung: nếu không có một kho dữ liệu thống nhất, mỗi lần phân tích lại phải làm lại từ đầu, khó đảm bảo tính nhất quán giữa các lần phân tích.

Đề tài được lựa chọn dựa trên ba lý do. Thứ nhất, về tính thực tiễn: ngành Làm đẹp và Chăm sóc cá nhân có quy mô lớn, tăng trưởng tốt và mức độ cạnh tranh cao như đã nêu ở mục 1.1, nên nhu cầu về thông tin thị trường là rõ ràng. Thứ hai, về khoảng trống dữ liệu: các số liệu thị trường phổ biến như của Metric tập trung vào các sàn TMĐT tổng hợp, trong khi dữ liệu mức sản phẩm của các chuỗi bán lẻ chuyên biệt như Hasaki và Cocolux chưa được hệ thống hóa ở dạng sẵn sàng phân tích. Thứ ba, về tính khả thi và giá trị học thuật: dữ liệu được công khai trên website, có cấu trúc tương đối đồng nhất, cho phép xây dựng trọn vẹn một quy trình từ thu thập, làm sạch, lưu trữ đến phân tích và trực quan hóa, qua đó vận dụng các kiến thức về kỹ thuật dữ liệu và phân tích dữ liệu vào một bài toán cụ thể.

Do vậy, đề tài không dừng ở việc phân tích một tập dữ liệu có sẵn mà hướng tới xây dựng một hệ thống có thể tái sử dụng: có thể chạy lại để cập nhật dữ liệu, mở rộng sang nhóm sản phẩm hoặc nền tảng khác khi cần. Đó cũng chính là lý do nhóm lựa chọn thực hiện đề tài: "XÂY DỰNG HỆ THỐNG THU THẬP, LƯU TRỮ VÀ PHÂN TÍCH DỮ LIỆU SẢN PHẨM MỸ PHẨM VÀ CHĂM SÓC CÁ NHÂN TỪ HASAKI VÀ COCOLUX"

1.3 Mục tiêu và câu hỏi phân tích

- Mục tiêu tổng quát

Xây dựng hệ thống thu thập, lưu trữ và phân tích dữ liệu sản phẩm mỹ phẩm và chăm sóc cá nhân từ hai nền tảng Hasaki và Cocolux, nhằm hỗ trợ việc nhận diện đặc điểm thị trường, hành vi định giá và khuyến mãi của hai nhà bán lẻ.

- Mục tiêu cụ thể

+ Thiết kế và triển khai quy trình thu thập dữ liệu sản phẩm tự động từ website Hasaki và Cocolux theo các nhóm danh mục đã xác định.

+ Làm sạch và chuẩn hóa dữ liệu: loại bỏ bản ghi trùng lặp, kiểm tra các trường bắt buộc, tách dung tích thành giá trị số và đơn vị, tính toán phần trăm giảm giá, chuẩn hóa tên thương hiệu và xuất xứ.

+ Thiết kế mô hình lưu trữ dữ liệu thống nhất cho hai nguồn, bảo đảm có thể truy vấn và tái sử dụng cho các phân tích tiếp theo.

+ Phân tích dữ liệu và trực quan hóa kết quả để trả lời các câu hỏi phân tích bên dưới, từ đó rút ra nhận định hữu ích cho người làm kinh doanh.

1.4 Phạm vi dữ liệu

Nguồn dữ liệu: Dữ liệu được thu thập từ hai website bán lẻ mỹ phẩm là Hasaki (hasaki.vn) và Cocolux (cocolux.com). Đây là dữ liệu công khai hiển thị trên trang danh mục và trang chi tiết sản phẩm.

Nhóm ngành hàng. Dữ liệu bao gồm 5 nhóm ngành hàng chính:

Bảng 1.1. Bảng đối chiếu danh mục giữa hai nguồn

Nhóm danh mục	Hasaki	Cocolux
Chăm sóc da	3.041	1.091
Trang điểm	1.729	1.283
Chăm sóc cơ thể	821	311
Chăm sóc tóc	714	113
Nước hoa	181	132
Tổng	6.486	2.930

Nguồn: Tác giả tự tổng hợp.

Các trường dữ liệu chính: source, category_group, category, url, name, brand, product_code, volume, origin, skin_type, price, price_original, discount_pct, rating, review_count, in_stock, sold, scraped_at, required_ok.

1.5 Bố cục báo cáo

Chương 1. Giới thiệu đề tài

Chương 2. Thu thập dữ liệu

Chương 3. Làm sạch và chuẩn hóa dữ liệu

Chương 4. Thiết kế và lưu trữ dữ liệu

Chương 5. Trực quan hóa dữ liệu và dashboard

Chương 6. Mô hình học máy

Chương 7. Xây dựng hệ thống website

Chương 8: Nhận định, đề xuất

CHƯƠNG 2: THU THẬP DỮ LIỆU

2.1. Nguồn dữ liệu

Nhóm thu thập dữ liệu từ hai website thương mại điện tử chuyên về mỹ phẩm tại Việt Nam là Hasaki (hasaki.vn) và Cocolux (cocolux.com). Hasaki là chuỗi bán lẻ mỹ phẩm và chăm sóc sắc đẹp có danh mục sản phẩm đa dạng, trang sản phẩm hiển thị nhiều thông tin chi tiết như xuất xứ, loại da và đánh giá. Cocolux là hệ thống bán lẻ mỹ phẩm chính hãng, tập trung chủ yếu vào nhóm trang điểm và chăm sóc da.

Nhóm chọn hai nguồn này vì ba lý do. Thứ nhất, cả hai cùng thuộc lĩnh vực mỹ phẩm và chăm sóc cá nhân nên dữ liệu có thể gộp lại để phân tích và so sánh. Thứ hai, trang sản phẩm đều công khai và hiển thị đầy đủ các thông tin cơ bản như tên, thương hiệu, giá và đánh giá. Thứ ba, dùng nhiều nguồn giúp tăng số lượng bản ghi và giảm sự phụ thuộc vào một website.

Dữ liệu được thu thập theo năm nhóm danh mục lớn. Vì hai website đặt tên và chia danh mục khác nhau, nhóm đối chiếu các danh mục lớn về năm nhóm chung như Bảng 2.1.

Bảng 2.1. Đối chiếu danh mục giữa hai nguồn

STT	Nhóm danh mục	Hasaki	Cocolux
1	Chăm sóc da	Chăm Sóc Da Mặt	Chăm Sóc Da
2	Trang điểm	Trang Điểm	Son Môi, Trang Điểm, Mascara
3	Chăm sóc tóc	Chăm Sóc Tóc Và Da Đầu	Chăm Sóc Tóc
4	Chăm sóc cơ thể	Chăm Sóc Cơ Thể	Chăm Sóc Cơ Thể
5	Nước hoa	Nước Hoa	Nước Hoa

Nguồn: Tác giả tự tổng hợp.

Đơn vị đếm dữ liệu là một sản phẩm tương ứng một bản ghi. Một sản phẩm có thể xuất hiện ở nhiều danh mục (ví dụ một cây mascara nằm đồng thời trong "Mascara" và "Trang Điểm" của Cocolux) nên nhóm chỉ giữ một bản duy nhất cho mỗi địa chỉ URL.

2.2 Các trường dữ liệu

Dữ liệu thô của mỗi sản phẩm gồm 19 trường, chia thành ba loại: bắt buộc, không bắt buộc và phụ trợ. Sau khi làm sạch, bộ dữ liệu cuối còn 17 trường do loại bỏ sold và skin_type.

2.2.1 Trường bắt buộc

Nhóm xác định bảy trường bắt buộc. Một bản ghi chỉ được xem là hợp lệ khi có đủ các trường này.

Bảng 2.2. Các trường bắt buộc

Trường	Ý nghĩa
name	Tên sản phẩm
brand	Thương hiệu
product_code	Mã sản phẩm hoặc mã vạch
price	Giá bán hiện tại (VNĐ)
url	Đường dẫn trang sản phẩm, dùng làm khóa duy nhất
category	Danh mục sản phẩm
source	Nguồn dữ liệu (Hasaki hoặc Cocolux)

Nguồn: Tác giả tự tổng hợp.

2.2.2 Trường không bắt buộc

Sáu trường dưới đây được phép để trống, vì có hay không có thông tin phụ thuộc vào cách từng website hiển thị.

Bảng 2.3. Các trường không bắt buộc

Trường	Ý nghĩa
rating	Điểm đánh giá trung bình (thang 5)
review_count	Số lượt đánh giá
price_original	Giá gốc trước khi giảm (VNĐ)
volume	Dung tích hoặc khối lượng (ví dụ 50ml)
skin_type	Loại da phù hợp
origin	Xuất xứ thương hiệu

Nguồn: Tác giả tự tổng hợp

2.2.3 Trường phụ trợ

Chương trình tạo thêm sáu trường phụ trợ: category_group (nhóm danh mục lớn theo Bảng 2.1), discount_pct (phần trăm giảm giá, tính từ giá bán và giá gốc), in_stock (tình trạng còn

hàng), sold (số lượng đã bán), scraped_at (thời điểm thu thập) và required_ok (dấu hiệu bản ghi có đủ trường bắt buộc).

2.3 Chương trình thu thập

2.3.1 Công nghệ sử dụng

Chương trình thu thập crawl_all.py được viết bằng Python trên Visual Studio Code. Nhóm dùng thư viện Playwright để điều khiển trình duyệt Chromium tự động (mở trang, cuộn trang, bấm nút). Playwright được chọn vì cả hai website tải danh sách sản phẩm bằng JavaScript nên không thể chỉ tải mã HTML tĩnh. Dữ liệu được ghi ra tệp .jsonl (mỗi dòng một bản ghi JSON) và sau đó tổng hợp thành tệp Excel. Mỗi nguồn chạy trong một tiến trình riêng nhờ thư viện multiprocessing nên Hasaki và Cocolux được thu thập song song.

2.3.2 Quy trình thu thập

Với mỗi nguồn, chương trình thực hiện bốn bước.

Bước 1: Thu thập đường dẫn sản phẩm.

Các danh mục cần thu thập được khai báo sẵn trong chương trình. Hàm collect_links mở từng trang danh mục và gom toàn bộ liên kết sản phẩm. Do mỗi trang hiển thị danh sách theo cách khác nhau, hàm này kết hợp bốn cách: cuộn trang xuống để tải thêm sản phẩm; bấm nút "Xem thêm", trong đó chỉ giữ lại nút nào thực sự làm tăng số sản phẩm; bấm nút sang trang kế tiếp và thay đổi tham số trên URL (?p=2, ?page=2...). Chương trình dừng khi cuộn nhiều lần liên tiếp mà không xuất hiện liên kết mới. Liên kết sản phẩm được nhận dạng bằng biểu thức chính quy riêng của từng trang và được loại trùng bằng tập hợp (set).

```
HASAKI_CATEGORIES = [
    ("Chăm sóc da", "Chăm sóc da mặt", "https://hasaki.vn/danh-muc/cham-soc-da-mat-c4.html"),
    ("Trang điểm", "Trang điểm", "https://hasaki.vn/danh-muc/trang-diem-c23.html"),
    ("Chăm sóc tóc", "Chăm sóc tóc và da đầu", "https://hasaki.vn/danh-muc/cham-soc-toc-c96.html"),
    ("Chăm sóc cơ thể", "Chăm sóc cơ thể", "https://hasaki.vn/danh-muc/cham-soc-co-the-c12.html"),
    ("Nước hoa", "Nước hoa", "https://hasaki.vn/danh-muc/nuoc-hoa-c103.html"),
]
```

Hình 2.1. Khai báo danh mục Hasaki cần thu thập

Nguồn: Tác giả tự tổng hợp

```
COCOLUX_CATEGORIES = [
    ("Chăm sóc da", "Chăm sóc da", "https://cocolux.com/danh-muc/cham-soc-da-skincare-i.105"),
    ("Trang điểm", "Son môi", "https://cocolux.com/danh-muc/son-moi-lips-i.98"),
    ("Trang điểm", "Trang điểm", "https://cocolux.com/danh-muc/trang-diem-makeup-i.83"),
    ("Trang điểm", "Mascara", "https://cocolux.com/danh-muc/mascara-i.97"),
    ("Chăm sóc tóc", "Chăm sóc tóc", "https://cocolux.com/danh-muc/cham-soc-toc-haircare-i.146"),
    ("Chăm sóc cơ thể", "Chăm sóc cơ thể", "https://cocolux.com/danh-muc/cham-soc-co-the-bodycare-i.130"),
    ("Nước hoa", "Nước hoa", "https://cocolux.com/danh-muc/nuoc-hoa-perfume-i.148"),
]
```

Hình 2.2. Khai báo danh mục Cocolux cần thu thập

Nguồn: Tác giả tự tổng hợp

Mỗi phần tử gồm nhóm danh mục lớn, tên danh mục và URL trang danh mục.

Bước 2: Đọc thông tin từng sản phẩm.

Hàm parse_product mở từng liên kết và lấy dữ liệu theo nguyên tắc thử nguồn đáng tin cậy nhất trước, nếu không được thì dùng cách dự phòng. Chương trình ưu tiên đọc dữ liệu có cấu trúc JSON-LD mà trang đã nhúng sẵn. Khi thiếu, chương trình dùng thẻ <h1>, các nhãn như "Thương hiệu", "Xuất xứ", "Loại da" hoặc dò chữ trên trang bằng biểu thức chính quy (ví dụ giá có dạng 199.000đ). Số lượt đánh giá lấy theo số lớn nhất hiển thị trên trang vì JSON-LD đôi khi chỉ ghi số đánh giá mẫu. Dung tích được tách từ tên sản phẩm, còn phần trăm giảm giá được tính từ giá gốc và giá bán. Cuối cùng, trường required_ok được đặt là đúng nếu bản ghi có đủ trường bắt buộc.

```
def parse_product(page, url, source, group, cat):
    page.goto(url, wait_until="domcontentloaded", timeout=60000)
    check_blocked(page)
    page.wait_for_timeout(2500)
    text = page.inner_text("body")
    ld = read_jsonld_product(page)
    # tên
    name = ld.get("name")
    if not name:
        try:
            name = page.locator("h1").first.inner_text().strip()
        except Exception:
            name = None
    # thương hiệu
    brand = ld.get("brand")
    if isinstance(brand, dict):
        brand = brand.get("name")
    if not brand:
        brand = label(text, "Thương hiệu")
    if not brand:
        try:
            brand = page.locator('a[href*="/thuong-hieu/"]').first.inner_text().strip()
        except Exception:
            brand = None
```

Hình 2.3. Lấy tên và thương hiệu: ưu tiên JSON-LD, thiếu thì dùng cách dự phòng

Nguồn: Tác giả tự tổng hợp

Bước 3: Lưu dữ liệu.

Mỗi sản phẩm được ghi ngay một dòng vào tệp data/raw_<nguồn>.jsonl. Nhờ ghi liên tục và bỏ qua các URL đã thu thập, chương trình có thể chạy lại và tiếp tục khi bị gián đoạn mà không sinh dữ liệu trùng.

Bước 4: Thống kê độ đầy đủ.

Cuối mỗi lần chạy, hàm coverage in ra số bản ghi có giá trị của từng trường, giúp phát hiện sớm trường nào hay bị thiếu.

Chương trình có ba chế độ chạy: --links-only (chỉ đếm số sản phẩm của mỗi danh mục), --test (chạy thử với ba danh mục, mỗi danh mục ba sản phẩm) và chạy đầy đủ không tham số.

2.3.3 Nguyên tắc thu thập

Để tránh gây tải lớn cho website, chương trình nghỉ ngẫu nhiên từ 2 đến 4 giây giữa các sản phẩm và 5 giây giữa các danh mục. Trình duyệt chạy ở chế độ có giao diện. Khi gặp trang yêu cầu xác thực hoặc CAPTCHA, chương trình chỉ chờ người dùng tự xử lý trong cửa sổ trình duyệt mà không tự vượt xác thực.

2.4 Kết quả thu thập

Dữ liệu được thu thập từ Hasaki trong khoảng 12 giờ và Cocolux khoảng 7 giờ. Kết quả là 9.416 bản ghi thô với 19 cột, không có URL trùng.

Bảng 2.4. Số bản ghi thô theo nguồn và nhóm danh mục

Nhóm danh mục	Hasaki	Cocolux
Chăm sóc da	3.041	1.091
Trang điểm	1.729	1.283
Chăm sóc cơ thể	821	311
Chăm sóc tóc	714	113
Nước hoa	181	132
Tổng	6.486	2.930

Nguồn: Tác giả tự tổng hợp

Bảng 2.5. Số bản ghi có dữ liệu theo từng trường (dữ liệu thô)

Trường	Hasaki (6.486)	Cocolux (2.930)
name, brand, url, category, source	6.486	2.930
product_code	6.485	2.927
price	6.486	2.927
review_count	6.485	2.927
rating	2.866	2.927
price_original	6.425	1.336
volume	5.791	1.714

origin	6.404	12
skin_type	3.321	0
sold	0	0

Nguồn: Tác giả tự tổng hợp

Nhận xét:

- Các trường bắt buộc gần như đầy đủ ở cả hai nguồn.

- Hasaki cung cấp nhiều thông tin hơn ở nhóm trường không bắt buộc (xuất xứ, loại da), Cocolux gần như không có xuất xứ và hoàn toàn không có loại da.

- Điểm đánh giá của Hasaki chỉ có ở khoảng 44% bản ghi, chủ yếu do nhiều sản phẩm chưa có lượt đánh giá.

- Trường sold trống hoàn toàn ở cả hai nguồn.

2.5 Khó khăn và cách xử lý

Bảng 2.6. Khó khăn khi thu thập và cách xử lý

Khó khăn	Cách xử lý
Trang tải sản phẩm bằng JavaScript, mỗi trang chia danh sách một kiểu (cuộn, "Xem thêm", số trang).	Dùng Playwright và kết hợp bốn cách lấy liên kết.
Có nhiều nút "Xem thêm", trong đó có nút ở phần mô tả nội dung (SEO) không làm hiện thêm sản phẩm.	Thử từng nút và chỉ giữ nút nào làm tăng số sản phẩm.
Không biết đã lấy đủ liên kết chưa.	So số liên kết thu được với số "N kết quả" mà trang hiển thị; lưu riêng các liên kết "trông giống sản phẩm nhưng không khớp mẫu" để kiểm tra.
Trang có thể yêu cầu xác thực hoặc CAPTCHA.	Tạm dừng chờ người dùng xử lý trong cửa sổ trình duyệt; nếu vẫn bị chặn thì dừng và lưu tiến độ để chạy tiếp sau.
Thu thập lâu, dễ bị gián đoạn.	Ghi từng bản ghi ngay khi cào và bỏ qua URL đã có khi chạy lại.
Danh mục hai trang đặt tên và chia khác nhau.	Đối chiếu về năm nhóm chung (Bảng 2.1) và chỉ giữ một bản cho mỗi URL.

Cấu trúc trang không đồng nhất giữa hai nguồn và giữa các sản phẩm.	Dùng nhiều lớp dự phòng (JSON-LD, thẻ HTML, nhãn, biểu thức chính quy); thêm trường required_ok để đánh dấu bản ghi thiếu trường bắt buộc.
Số đánh giá trong JSON-LD không chính xác (đôi khi chỉ là số đánh giá mẫu).	Ưu tiên số hiển thị trên trang (lấy số lớn nhất).
Một số trường không lấy được dữ liệu: sold trống hoàn toàn ở cả hai nguồn; Cocolux gần như không có origin và skin_type; một số trang lỗi "404".	Giữ nguyên dữ liệu thô để đánh giá, việc xử lý được thực hiện ở bước làm sạch.

Nguồn: Tác giả tự tổng hợp

CHƯƠNG 3: LÀM SẠCH VÀ CHUẨN HÓA DỮ LIỆU

3.1. Làm sạch và chuẩn hóa dữ liệu bằng Python

3.1.1 Tổng quan quy trình

Nhóm dùng 6 chương trình Python, chạy lần lượt. Mỗi bước lưu ra một tệp riêng nên có thể kiểm tra lại từng giai đoạn, còn dữ liệu thô không bị đụng đến.

Bảng 3.1. Các chương trình làm sạch

Chương trình	Nhiệm vụ	Tệp kết quả
clean_hasaki.py	Sửa số lượt đánh giá sai; bỏ cột sold	hasaki_cleaned.xlsx
clean_cocolux.py	Xóa dòng lỗi; đổi kiểu dữ liệu; bỏ cột trống	cocolux_cleaned.xlsx
merge_products.py	Gộp hai nguồn thành một bảng	products_merged.xlsx
clean_merged.py	Xóa dòng không hợp lệ; chuẩn hóa xuất xứ, thương hiệu; xử lý giá gốc, đánh giá, tồn kho	products_final.xlsx
fix_brand.py	Chuẩn hóa thương hiệu ngay trên tệp Excel, có sao lưu	Ghi vào tệp cũ, kèm _backup.xlsx
check_final_data.py	Kiểm tra chất lượng (không sửa dữ liệu)	final_data_quality_report.xlsx

Nguồn: Tác giả tự tổng hợp

3.1.2 Các vấn đề phát hiện trong dữ liệu thô

Dữ liệu thô có 9.416 dòng (Hasaki 6.486, Cocolux 2.930) và 19 cột, không trùng dòng, không trùng URL. Tuy nhiên nhóm phát hiện 13 vấn đề, mỗi vấn đề được xử lý ở một bước nhất định.

Bảng 3.2. Vấn đề phát hiện và bước xử lý

Vấn đề	Nguồn	Mô tả
Số lượt đánh giá quá lớn	Hasaki	4 máy sấy tóc Philips có 39.728.743 lượt đánh giá
Cột sold trống	Cả hai	Không có dữ liệu ở cả hai nguồn
Dòng lỗi thu thập	Cocolux	3 dòng tên "404", thiếu giá và mã sản phẩm
Mã sản phẩm sai kiểu	Cocolux	Mã bị đọc thành số, Excel hiển thị dạng khoa học

Vấn đề	Nguồn	Mô tả
Cột skin_type thiếu nhiều	Cả hai	Cocolux không có; sau khi gộp thiếu khoảng 64,7%
Giá quá thấp	Hasaki	1 chai nước hoa 100ml giá 60 đồng
Thiếu mã sản phẩm	Hasaki	1 sản phẩm (Bột Ăn Dặm)
Trùng mã sản phẩm	Cả hai	6 mã xuất hiện ở 2 URL (bản cũ và bản "Mới")
Xuất xứ viết lộn xộn	Cả hai	44 giá trị, ví dụ "Đức" và "Germany"; có giá trị sai như "Nơi sản xuất"
Thiếu giá gốc và % giảm	Cả hai	Sản phẩm không khuyến mãi
Điểm sao mâu thuẫn	Cả hai	Có điểm sao nhưng 0 lượt đánh giá
Thiếu tình trạng tồn kho	Cả hai	Nhiều sản phẩm không rõ còn hàng hay không
Thương hiệu viết lộn xộn	Cả hai	616 cách viết; 2 sản phẩm ghi "Blog làm đẹp"

Nguồn: Tác giả tự tổng hợp

Bước 1: Làm sạch dữ liệu Hasaki

- Sửa số lượt đánh giá. Nhóm mở trang Hasaki kiểm tra và thấy 4 sản phẩm Philips không có đánh giá nào, nên đưa về 0. Chương trình dừng nếu không tìm đúng 4 sản phẩm.

```
name_mask = df["name"].astype(str).str.contains(
    "Máy Sấy Tóc Philips",
    case=False,
    na=False)
review_mask = df["review_count"].eq(39728743)
mask = name_mask & review_mask
fixed_count = int(mask.sum())
print(f"\nSố sản phẩm tìm thấy cần sửa: {fixed_count}")
if fixed_count != 4:
    raise ValueError(
        f"Chỉ tìm thấy {fixed_count}/4 sản phẩm cần sửa. "
        "Chương trình dừng để tránh thay đổi dữ liệu sai.")
print("\nCác sản phẩm được sửa:")
print(
    df.loc[mask, ["name", "review_count"]].to_string(index=False))
df.loc[mask, "review_count"] = 0
```

Hình 3.1. Đoạn mã sửa khi tìm đúng 4 sản phẩm (clean_hasaki.py)

Nguồn: Tác giả tự tổng hợp

- Bỏ cột sold vì không có dữ liệu.

```
removed_columns = []

if "sold" in df.columns and df["sold"].isna().all():
    df.drop(columns=["sold"], inplace=True)
    removed_columns.append("sold")
    print("\nĐã loại cột sold vì toàn bộ giá trị đều trống.")
```

Hình 3.2. Đoạn mã xóa cột "sold" (clean_hasaki.py)

Nguồn: Tác giả tự tổng hợp

Kết quả: 6.486 dòng, 18 cột.

Bước 2: Làm sạch dữ liệu Cocolux

- Xóa dòng lỗi. Xóa mọi sản phẩm thiếu giá hoặc mã sản phẩm. Đó chính là 3 trang "404": 2.930 − 3 = 2.927 dòng.

```
remove_mask = missing_price | missing_product_code
removed_products = df.loc[remove_mask].copy()

print("Tổng số sản phẩm bị xóa:", len(removed_products))

if not removed_products.empty:
    print("\nDanh sách sản phẩm bị xóa:")
    print(
        removed_products[
            ["name", "price", "product_code"]
        ].to_string(index=False)
    )

df = df.loc[~remove_mask].copy()

print("Số sản phẩm còn lại:", len(df))
```

Hình 3.3. Đoạn mã xóa sản phẩm thiếu giá hoặc mã sản phẩm (clean_cocolux.py)

Nguồn: Tác giả tự tổng hợp

- Đổi kiểu dữ liệu. Cột giá, đánh giá, tồn kho đổi sang số; mã sản phẩm đổi sang chuỗi chữ vì mã chỉ để nhận diện, không để tính toán.

- Bỏ cột trống: skin_type và sold.

Kết quả: 2.927 dòng, 17 cột.

Bước 3: Gộp hai nguồn

Nối hai bảng: 6.486 + 2.927 = 9.413 sản phẩm. Cocolux không có skin_type nên để trống cột này, hai bảng đều có 18 cột. Cột source được giữ để biết sản phẩm đến từ Hasaki hay Cocolux. Sau khi gộp không có dòng trùng hay URL trùng.

Bước 4: Làm sạch sau khi gộp

- Xóa dòng không hợp lệ

Bảng 3.3. Các dòng bị xóa ở bước 4

Quy tắc	Nội dung	Lý do	Số dòng
R1	Xóa sản phẩm có giá dưới 1.000 đồng	Giá 60 đồng không thể là giá thật của nước hoa 100ml	1
R2	Xóa sản phẩm thiếu mã sản phẩm	Mã dùng để nhận diện sản phẩm	1
R3	Với mỗi mã trùng, kiểm tra từng cặp URL và chỉ giữ một	Một sản phẩm không được tính hai lần	6

Nguồn: Tác giả tự tổng hợp

Với R3, nhóm chỉ xử lý 6 mã đã kiểm tra tay, không tự xóa mã trùng khác, và chương trình dừng nếu URL chọn không khớp đúng một dòng.

```
for code, url in preferred_urls.items():
    matched = df_clean[
        (df_clean["_product_code_check"] == code)
        & (df_clean["url"] == url)
    ]

    if len(matched) != 1:
        raise ValueError(
            f"Mã {code}: URL được chọn phải khớp đúng 1 dòng, "
            f"nhưng hiện khớp {len(matched)} dòng. "
            "Dừng để tránh xóa nhầm dữ liệu. "
            "Hãy kiểm tra product_code và URL trong file đầu vào."
        )

target_codes = set(preferred_urls.keys())
```

Hình 3.4. Đoạn mã giữ một URL cho mỗi mã trùng (clean_merged.py)

Nguồn: Tác giả tự tổng hợp

- Chuẩn hóa xuất xứ. Nhóm lập bảng đối chiếu để gộp các cách viết của cùng một nước, và chuyển giá trị sai (như "Nơi sản xuất", "Dubai") thành ô trống. Số giá trị khác nhau giảm từ 44 xuống 26; 24 giá trị sai được chuyển thành ô trống.

- Sửa giá gốc, đánh giá và tồn kho

Bảng 3.4. Các quy tắc sửa giá trị

Quy tắc	Nội dung	Lý do	Số lượng
R4	Nếu thiếu cả giá gốc và % giảm: điền giá gốc = giá bán, % giảm = 0	Không có khuyến mãi nghĩa là bán đúng giá niêm yết. Nếu chỉ thiếu một trong hai thì không điền	1.648 sản phẩm

Quy tắc	Nội dung	Lý do	Số lượng
R5	Nếu 0 lượt đánh giá: bỏ điểm sao (để trống)	Chưa ai đánh giá thì chưa có điểm sao thật	1.971 sản phẩm
R6	Cột in_stock: 1 = còn hàng, 0 = hết hàng; ô trống đổi thành 0	Giả định của nhóm: không thấy chữ "Còn hàng" thì coi là hết hàng	1.736 ô

Nguồn: Tác giả tự tổng hợp

- Bỏ cột skin_type. Cột này chỉ Hasaki có, thiếu khoảng 64,7% sau khi gộp nên không dùng chung được cho hai nguồn. Bộ dữ liệu còn 17 cột.

- Phần giữ nguyên. Nhóm không xóa sản phẩm chỉ vì thiếu rating, origin hay volume (R7), và không tự điền 0 vào các ô trống còn lại (R8), vì 0 và "chưa có thông tin" là hai ý khác nhau. R4 và R6 là hai ngoại lệ đã nêu lý do ở trên.

Kết quả bước 4: 9.413 − 8 = 9.405 sản phẩm, 17 cột. Khi xuất Excel, ô trống của volume, origin, rating được ghi chữ "NULL" cho dễ nhìn (chỉ là cách hiển thị).

Bước 5: Chuẩn hóa thương hiệu

Cột brand có 616 cách viết, nhiều cái thực ra là cùng một thương hiệu. Cách làm có trong clean_merged.py và trong fix_brand.py (chạy riêng trực tiếp trên tệp Excel):

- Làm gọn: đổi & thành &, thống nhất dấu nháy, bỏ khoảng trắng thừa.

- Tạo khóa so sánh: bỏ dấu, bỏ ký tự đặc biệt, viết thường. Nhờ vậy "Kissme" và "KISS ME" cho cùng một khóa.

- Gộp: tên nào có trong bảng đối chiếu thì đổi thành tên chuẩn; các tên còn lại viết hoa toàn bộ.

- Sửa theo mã sản phẩm: 2 sản phẩm ghi "Blog làm đẹp" được sửa thành PERSPIREX và BESILKI.

Bảng 3.5. Một số thương hiệu được gộp bằng bảng đối chiếu

Các cách viết	Tên chuẩn
L'Oreal, L'Oréal	L'ORÉAL
Banobagi, BANO:BAGI	BANOBAGI
JM SOLUTION, JMsolution	JM SOLUTION
KISS ME, Kissme	KISS ME
On: The Body, ON:THE BODY	ON: THE BODY
A Bonne, A BONNÉ	A BONNE

Các cách viết	Tên chuẩn
CETAPHIL BABY	CETAPHIL

Nguồn: Tác giả tự tổng hợp

Dòng cuối là quyết định của nhóm: coi "CETAPHIL BABY" là một dòng sản phẩm của thương hiệu CETAPHIL. Nhóm chỉ gộp các cách viết của cùng thương hiệu, không gộp theo công ty mẹ.

```python
def make_brand_key(value):
    """Tạo khóa so sánh: bỏ dấu, bỏ ký tự đặc biệt, chữ thường."""
    text = unicodedata.normalize("NFD", str(value))
    text = "".join(c for c in text if unicodedata.category(c) != "Mn")
    text = text.replace("đ", "d").replace("Đ", "D")
    return re.sub(r"[^a-z0-9]", "", text.lower())


def normalize_brand(value):
    """Giải mã &amp;amp;, thống nhất dấu nháy, bỏ khoảng trắng thừa, viết HOA."""
    if value is None:
        return None

    text = html.unescape(str(value))                # &amp;amp; -> &
    text = text.replace("’", "'").replace("`", "'")  # dấu nháy cong -> thẳng
    text = re.sub(r"\s+", " ", text).strip()

    if not text:
        return None

    return brand_manual.get(make_brand_key(text), text.upper())
```

Hình 3.5. Tạo khóa so sánh và chuẩn hóa thương hiệu (fix_brand.py)

Nguồn: Tác giả tự tổng hợp

An toàn khi sửa trực tiếp trên Excel. fix_brand.py có ba lớp bảo vệ: kiểm tra mã sản phẩm khớp đúng một dòng rồi mới sửa (không khớp thì dừng); sao lưu tệp gốc thành _backup.xlsx trước khi ghi; chỉ sửa cột brand.

```python
if MAKE_BACKUP:
    shutil.copy2(INPUT_FILE, BACKUP_FILE)
    print(f"\nĐã sao lưu file gốc: {BACKUP_FILE}")

try:
    wb.save(INPUT_FILE)
except PermissionError:
    sys.exit(
        "LỖI: Không ghi được file. Hãy đóng products_clean.xlsx trong Excel rồi chạy lại."
    )

print(f"Đã lưu kết quả vào: {INPUT_FILE}")
print("\nHOÀN TẤT!")
```

Hình 3.6. Đoạn mã sao lưu tệp trước khi ghi (fix_brand.py)

Nguồn: Tác giả tự tổng hợp

Kết quả: số thương hiệu giảm từ 616 xuống 488; không còn "Blog làm đẹp"; số dòng không đổi.

Bước 6: Kiểm tra chất lượng

Chương trình check_final_data.py chỉ đọc products_final.xlsx và lập báo cáo:

- Trùng lặp: không trùng dòng, URL hay mã sản phẩm.

- Giá trị bất thường: không có giá ≤ 0, giá gốc thấp hơn giá bán, % giảm ngoài 0 đến 100, điểm sao ngoài 0 đến 5, hay số lượt đánh giá âm hoặc lẻ.

- Kiểm tra % giảm giá: tính lại bằng công thức (Giá gốc − Giá bán) / Giá gốc × 100% cho cả 9.405 sản phẩm; không sản phẩm nào lệch quá 1 điểm phần trăm so với cột discount_pct.

- Trường bắt buộc: cả 7 trường (name, brand, product_code, price, url, category, source) đều đủ.

3.1.3 Kết quả tổng hợp

Bảng 3.6. Số dòng và số cột qua từng giai đoạn

Giai đoạn	Hasaki	Cocolux	Tổng	Số cột
Dữ liệu thô	6.486	2.930	9.416	19
Sau bước 1, 2	6.486	2.927	9.413	18 và 17
Sau bước 3 (gộp)			9.413	18
Sau bước 4, 5 (cuối)	6.482	2.923	9.405	17

Nguồn: Tác giả tự tổng hợp

Bảng 3.7. Các dòng bị xóa (tổng 11 dòng, khoảng 0,12% dữ liệu thô)

Lý do	Số dòng	Nguồn	Bước
Lỗi thu thập "404"	3	Cocolux	2
Giá dưới 1.000 đồng	1	Hasaki	4
Thiếu mã sản phẩm	1	Hasaki	4
Trùng mã sản phẩm	6	Hasaki 2, Cocolux 4	4
Tổng	11		

Nguồn: Tác giả tự tổng hợp

Bảng 3.8. Số sản phẩm theo nhóm danh mục

Nhóm danh mục	Hasaki	Cocolux	Tổng
Chăm sóc da	3.040	1.090	4.130
Trang điểm	1.728	1.280	3.008
Chăm sóc cơ thể	821	311	1.132
Chăm sóc tóc	713	110	823
Nước hoa	180	132	312
Tổng	6.482	2.923	9.405

Nguồn: Tác giả tự tổng hợp

Bảng 3.9. Các cột còn thiếu dữ liệu trong bộ dữ liệu cuối

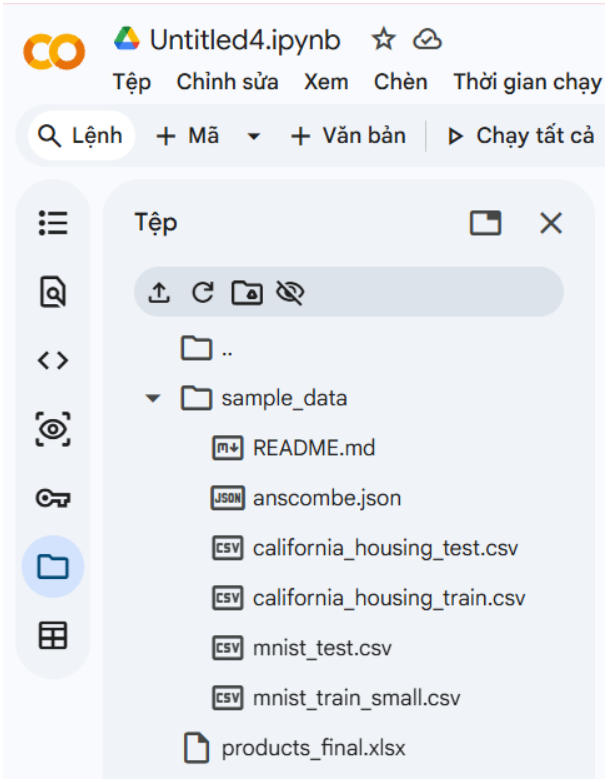
Cột	Số ô trống	Tỷ lệ
rating	5.588	59,42%
origin	3.016	32,07%
volume	1.903	20,23%

Nguồn: Tác giả tự tổng hợp

Các cột còn lại không có ô trống, kể cả 7 trường bắt buộc. rating thiếu nhiều vì phần lớn sản phẩm chưa có ai đánh giá; origin thiếu chủ yếu vì Cocolux gần như không có thông tin này. Cả ba đều là trường không bắt buộc nên được giữ nguyên.

Làm sạch dữ liệu bằng pandas

- Upload file “products_final.xlxs” lên Google Colab



Hình 3.7. Upload file dữ liệu lên Google Colab

Nguồn: Tác giả tự tổng hợp

- Tiến hành đọc file dữ liệu:

```
import pandas as pd
    df = pd.read_excel('products_final.xlsx',
        dtype={'product_code': str})
    df.shape
```

Kết quả:

```
    (9405, 17)
```

- Kiểm tra lại trùng lặp dữ liệu:

```
    print("Trùng toàn bộ dòng:", df.duplicated().sum())
    print("Trùng url:", df.duplicated("url").sum())
    print("Trùng source+name+brand+product_code  :",
        df.duplicated(["source", "name", "brand","product_code"]).sum())
```

- Kiểm tra phát hiện lỗi"product_code"

```
ma = df["product_code"].astype("string").str.strip()
    khong_phai_so = ~ma.str.fullmatch(r"\d+", na=False)
    print("Số dòng:", khong_phai_so.sum())    # 1
```

df.loc[khong_phai_so, ["source", "name", "product_code", "url"]]

```
ma = df["product_code"].astype("string").str.strip()
khong_phai_so = ~ma.str.fullmatch(r"\d+", na=False)
print("Số dòng:", khong_phai_so.sum())    # 1
df.loc[khong_phai_so, ["source", "name", "product_code", "url"]]
```

```
Số dòng: 1
```

	source	name	product_code	url
4313	hasaki	Mascara Maybelline Tơi Dài Mi Không Giới Hạn	mascara-maybelline-toi-dai-mi-khong-gioi-han	https://hasaki.vn/san-pham/mascara-maybelline-...

Hình 3.8. Kiểm tra và xử lý lỗi định dạng product_code

Nguồn: Tác giả tự tổng hợp

-> Phát hiện 1 dòng dữ liệu bị lỗi định dạng product_code không phải ở dạng số sau đó tiến hành xóa dòng dữ liệu bị lỗi:

n_truoc = len(df)

df = df[~khong_phai_so].copy()

print("Đã xóa:", n_truoc - len(df), "dòng")

print("Số dòng còn lại:", len(df))

- Kết quả sau khi làm sạch:

Bảng 3.10. Kết quả sau khi làm sạch

Chỉ tiêu	File gốc (products_final)	File sau làm sạch (products_clean)	Chênh lệch
Số bản ghi	9.405	9.404	−1
Số trường	17	19	+2
Bản ghi Hasaki	6.482	6.481	−1
Bản ghi Cocolux	2.923	2.923	0

CHƯƠNG 4. THIẾT KẾ VÀ LƯU TRỮ DỮ LIỆU

4.1 Lựa chọn hệ quản trị cơ sở dữ liệu

Đặc điểm dữ liệu cần lưu trữ

Bộ dữ liệu products_clean.xlxs đã được làm sạch ở chương trước, hiện có các đặc điểm sau:

Bảng 4.1. Đặc điểm của dữ liệu

Chỉ tiêu	Giá trị
Số sản phẩm	9.404
Số thuộc tính	19
Nguồn	Hasaki 6.481; Cocolux 2.923
Nhóm sản phẩm	5 nhóm: Chăm sóc da (4.130), Trang điểm (3.007), Chăm sóc cơ thể (1.132), Chăm sóc tóc (823), Nước hoa (312)
Thương hiệu	488
Xuất xứ	26 quốc gia
Giá bán	2.000đ đến 5.450.000đ, trung vị 189.000đ
Tồn kho	Còn hàng 7.668; hết hàng 1.736
Thiếu rating	5.587 sản phẩm (59,4%)
Thiếu origin	2.582 sản phẩm (27,5%)
Thiếu volume	1.902 sản phẩm (20,2%)

Nguồn: Tác giả tự tổng hợp

Từ các số liệu này có thể rút ra ba đặc điểm quan trọng. Thứ nhất, dữ liệu thiếu giá trị không đồng đều giữa các sản phẩm. Thứ hai, dữ liệu chỉ xoay quanh một thực thể là sản phẩm, chưa có khách hàng và đơn hàng. Thứ ba, dữ liệu được cào từ web nên nguồn và thuộc tính có thể thay đổi hoặc mở rộng theo thời gian.

Lý do chọn MongoDB (NoSQL)

Mô hình document khớp tự nhiên với dữ liệu sản phẩm: Mỗi sản phẩm là một đối tượng độc lập, đầy đủ thông tin (tên, giá, thương hiệu, đánh giá, tồn kho...). Lưu mỗi sản phẩm thành một document giúp đọc toàn bộ thông tin chỉ với một thao tác, không cần phép JOIN.

Phù hợp với quy trình thu thập dữ liệu: Dữ liệu crawl thường ở dạng JSON/CSV, nhập thẳng vào MongoDB bằng Compass mà không cần thiết kế bảng trước. Việc thu thập lại theo định kỳ (scraped_at) chỉ là thêm document mới hoặc cập nhật document cũ.

Truy vấn và thống kê mạnh: Aggregation pipeline ($match, $group, $sort, $facet, $bucket) cho phép thống kê theo nhóm, thương hiệu, nguồn, xuất xứ, khoảng giá ngay trên cơ sở dữ liệu, phục vụ trực tiếp bước phân tích ở các chương sau.

Dễ triển khai và chia sẻ trong nhóm: MongoDB Atlas là dịch vụ đám mây có gói miễn phí, mọi thành viên kết nối cùng một cluster qua MongoDB Compass hoặc mongosh với một connection string, không cần cài đặt server riêng. Đây cũng là bộ công cụ đã được hướng dẫn trong học phần.

Khả năng mở rộng. Nếu sau này nhóm bổ sung bình luận chi tiết, lịch sử giá theo thời gian, hoặc khách hàng và đơn hàng, MongoDB cho phép lưu dạng lồng nhau (embedding) hoặc tham chiếu (referencing) mà không phải thiết kế lại toàn bộ.

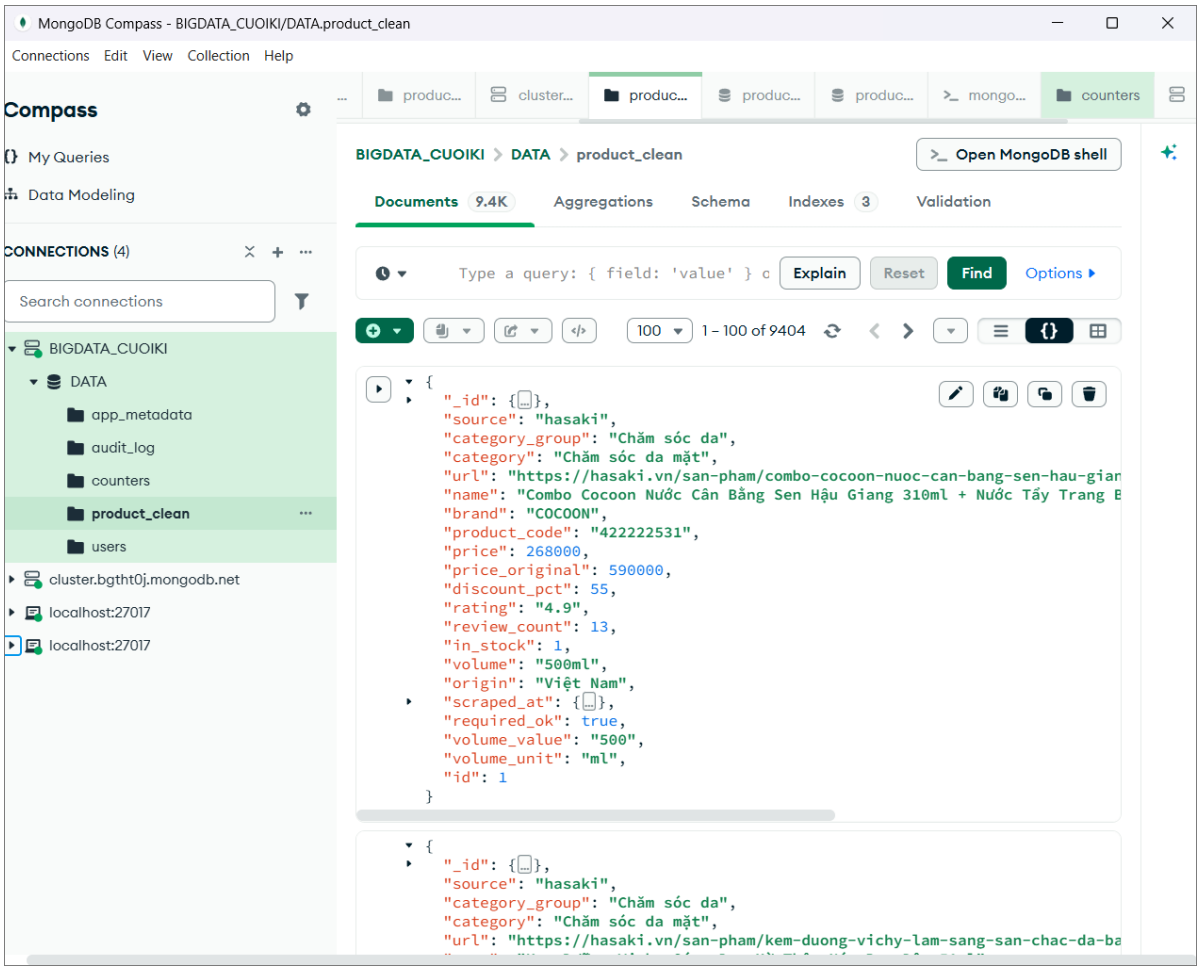
4.2 Thiết kế cấu trúc lưu trữ

- Hệ quản trị: MongoDB (cluster trên MongoDB Atlas).

- Công cụ giao diện: MongoDB Compass (xem dữ liệu, import/export, aggregation builder, schema, indexes).

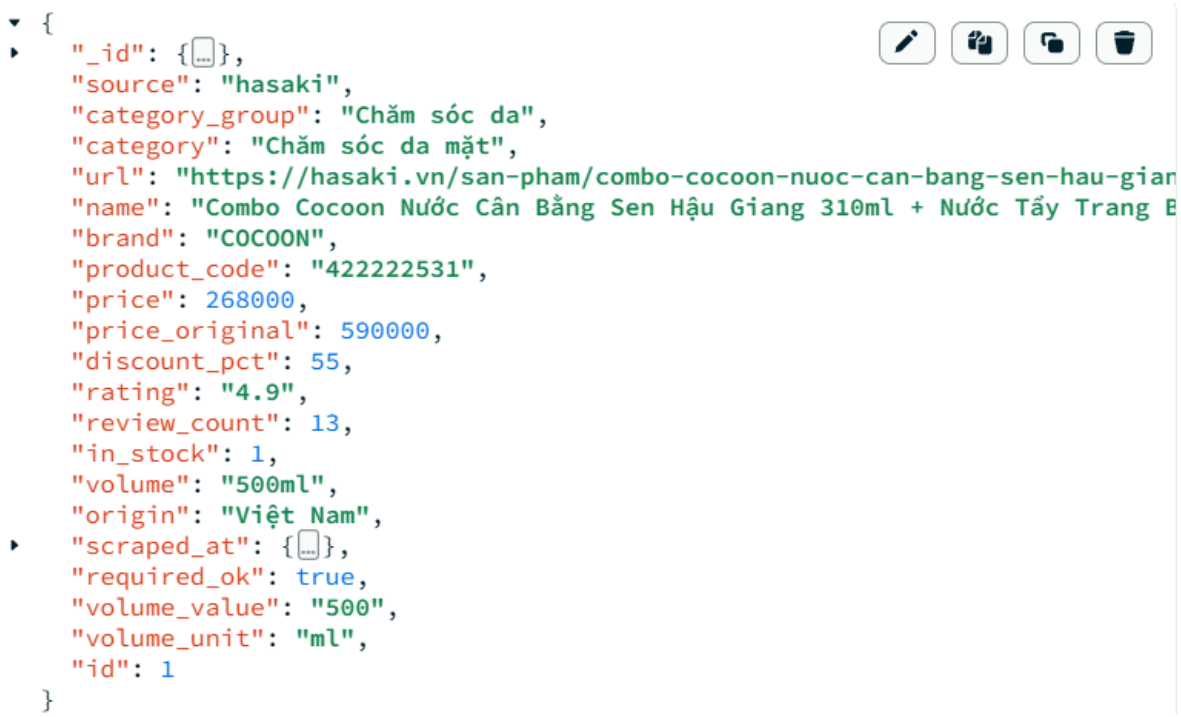
- Công cụ dòng lệnh: mongosh (chạy truy vấn, aggregation) và mongodump, mongorestore (sao lưu, phục hồi).

- Kết nối: BIGDATA_CUOIKI, cơ sở dữ liệu DATA, collection chính product_clean.



Hình 4.1. Giao diện MongoDB lưu trữ dữ liệu của nhóm

Nguồn: Tác giả tự tổng hợp



Hình 4.2. Ví dụ về 1 document

Nguồn: Tác giả tự tổng hợp

Bảng 4.2. Bảng mô tả cấu trúc các trường dữ liệu và kiểu dữ liệu trong collection sản phẩm

Trường	Kiểu trong MongoDB	Ý nghĩa	Ghi chú
_id	ObjectId	Khóa chính do MongoDB sinh	Tự động
source	String	Nguồn dữ liệu	hasaki hoặc cocolux
category_group	String	Nhóm sản phẩm	5 giá trị
category	String	Danh mục chi tiết	9 giá trị
url	String	Đường dẫn trang sản phẩm	Duy nhất
name	String	Tên sản phẩm	
brand	String	Thương hiệu	488 giá trị
product_code	String	Mã sản phẩm	Lưu dạng chuỗi vì Cocolux dùng mã vạch 13 chữ số
price	Int32	Giá bán (VND)	
price_original	Int32	Giá gốc (VND)	

discount_pct	Int32	Phần trăm giảm giá	0 đến 99
rating	String	Điểm đánh giá	
review_count	Int32	Số lượt đánh giá	
in_stock	Int	Còn hàng (1) hoặc hết hàng (0)	
volume	String	Dung tích gốc, ví dụ 60ml	
volume_value	String	Giá trị dung tích	Tách từ volume
volume_unit	String	Đơn vị: ml, g, l	
origin	String	Xuất xứ	Thiếu 27,5%
scraped_at	Date	Thời điểm thu thập	24–25/10/2026
required_ok	Boolean	Cờ đạt các trường bắt buộc	Tất cả đều true

Nguồn: Tác giả tự tổng hợp

4.3 Nhập dữ liệu

- Quy trình

+ Kết nối: lấy connection string trong Atlas (Data Explorer, Connect, Compass), điền mật khẩu người dùng cơ sở dữ liệu, rồi Save và Connect trong Compass.

+ Chuẩn bị file: xuất products_clean sang CSV (UTF-8) hoặc JSON để giữ đúng tiếng Việt.

+ Tạo collection: trong database DATA, tạo collection product_clean.

+ Import: vào collection, chọn Add Data, Import JSON or CSV file, trỏ tới file, kiểm tra kiểu từng trường (xem mục 4.2.4) rồi bấm Import.

+ Kiểm tra: so sánh số lượng và kiểu dữ liệu với file gốc.

Kết quả: Compass hiển thị 9,4K document trong product_clean, khớp với 9.404 dòng của file nguồn.

4.4 Truy vấn minh họa

- Xem toàn bộ và đếm số sản phẩm

db.product_clean.find()

db.product_clean.countDocuments()

```
> db.product_clean.countDocuments()
< 9404
```

Hình 4.3. Kết quả thực thi câu lệnh đếm tổng số lượng bản ghi trong collection product_clean

Nguồn: Tác giả tự tổng hợp

- Số sản phẩm theo nhóm

db.product_clean.aggregate([

{ $group: { _id: '$category_group', total: { $sum: 1 } } },

{ $sort: { total: -1 } }])

```
> db.product_clean.aggregate([
    { $group: { _id: '$category_group', total: { $sum: 1 } } },
    { $sort: { total: -1 } }
  ])
< {
    _id: 'Chăm sóc da',
    total: 4130
  }
  {
    _id: 'Trang điểm',
    total: 3007
  }
  {
    _id: 'Chăm sóc cơ thể',
    total: 1132
  }
  {
    _id: 'Chăm sóc tóc',
    total: 823
  }
  {
    _id: 'Nước hoa',
    total: 312
  }
```

Hình 4.4. Kết quả thống kê số lượng sản phẩm theo từng nhóm danh mục

Nguồn: Tác giả tự tổng hợp

- Giá trung bình, giảm giá trung bình và tỉ lệ còn hàng theo nhóm

```
db.product_clean.aggregate([
  { $group: {
      _id: '$category_group',
      total: { $sum: 1 },
      avgPrice: { avg:'price' },
      avgDiscount: { avg:'discount_pct' },
      inStockRate: { avg:'in_stock' }
  } },
  { $sort: { avgPrice: -1 } }])
```

```
{
  _id: 'Nước hoa',
  total: 312,
  avgPrice: 1210192.3076923077,
  avgDiscount: 23.91346153846154,
  inStockRate: 0.7211538461538461
}
{
  _id: 'Chăm sóc da',
  total: 4130,
  avgPrice: 275044.54116222763,
  avgDiscount: 28.999273607748183,
  inStockRate: 0.8188861985472154
}
{
  _id: 'Trang điểm',
  total: 3007,
  avgPrice: 228627.50249418025,
  avgDiscount: 25.11040904556036,
  inStockRate: 0.8144329896907216
}
{
  _id: 'Chăm sóc tóc',
  total: 823,
  avgPrice: 195931.80194410693,
  avgDiscount: 26.560145808019442,
  inStockRate: 0.8238153098420413
}
{
  _id: 'Chăm sóc cơ thể',
  total: 1132,
  avgPrice: 174721.02473498232,
  avgDiscount: 22.104240282685513,
  inStockRate: 0.8250883392226148
}
```


Hình 4.5. Kết quả thống kê giá trung bình, giảm giá trung bình và tỉ lệ còn hàng theo nhóm

Nguồn: Tác giả tự tổng hợp

- So sánh hai nguồn Hasaki và Cocolux

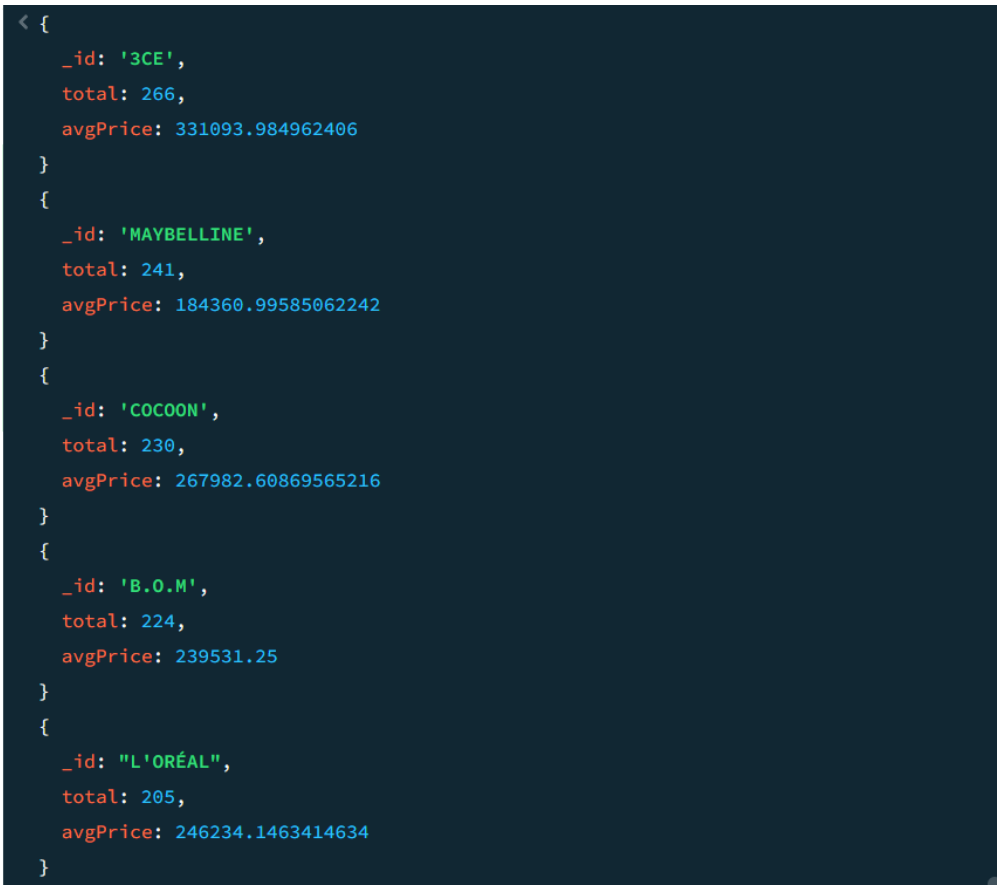
```
db.product_clean.aggregate([
  { $group: {
```

```
    _id: '$source',
    total: { $sum: 1 },
    avgPrice: { avg:'price' },
    avgDiscount: { avg:'discount_pct' }
  } }
])
```

Kết quả: Hasaki có nhiều sản phẩm hơn, giá trung bình thấp hơn và giảm giá sâu hơn rõ rệt.

- Top 10 thương hiệu có nhiều sản phẩm nhất

```
db.product_clean.aggregate([
  { $group: { _id: '$brand', total: { $sum: 1 }, avgPrice: { avg:'price' } } },
  { $sort: { total: -1 } },
  { $limit: 10 }
])
```



Hình 4.6. Kết quả thống kê tổng số lượng và giá trung bình theo các thương hiệu hàng đầu

Nguồn: Tác giả tự tổng hợp

```
{
  _id: 'JUDYDOLL',
  total: 171,
  avgPrice: 187298.24561403508
}
{
  _id: 'COLORKEY',
  total: 159,
  avgPrice: 129933.96226415095
}
{
  _id: 'VACOSI',
  total: 152,
  avgPrice: 71769.73684210527
}
{
  _id: 'GARNIER',
  total: 132,
  avgPrice: 156840.9090909091
}
{
  _id: 'SILKYGIRL',
  total: 128,
  avgPrice: 128039.0625
}
```


Hình 4.7. Kết quả thống kê tổng số lượng và giá trung bình theo các thương hiệu hàng đầu

Nguồn: Tác giả tự tổng hợp

Kết quả: 3CE (266), MAYBELLINE (241), COCOON (230), B.O.M (224), L'ORÉAL (205), JUDYDOLL (171), COLORKEY (159), VACOSI (152), GARNIER (132), SILKYGIRL (128).

- Phân bố theo xuất xứ (bỏ qua sản phẩm thiếu xuất xứ)

```
db.product_clean.aggregate([
  { $match: { origin: { $nin: [null, '', 'null'] } } },
  { $group: { _id: '$origin', total: { $sum: 1 }, avgPrice: { avg:'price' }, avgDiscount: { avg:'discount_pct' } } },
  { $sort: { total: -1 } },
  { $limit: 6 }
])
```

```
{
  _id: 'Hàn Quốc',
  total: 1953,
  avgPrice: 215410.1382488479,
  avgDiscount: 36.58832565284178
}
{
  _id: 'Mỹ',
  total: 954,
  avgPrice: 302962.5503144654,
  avgDiscount: 28.79454926624738
}
{
  _id: 'Việt Nam',
  total: 950,
  avgPrice: 162856.84210526315,
  avgDiscount: 34.67263157894737
}
{
  _id: 'Pháp',
  total: 686,
  avgPrice: 414775.51020408166,
  avgDiscount: 31.84985422740525
}
```

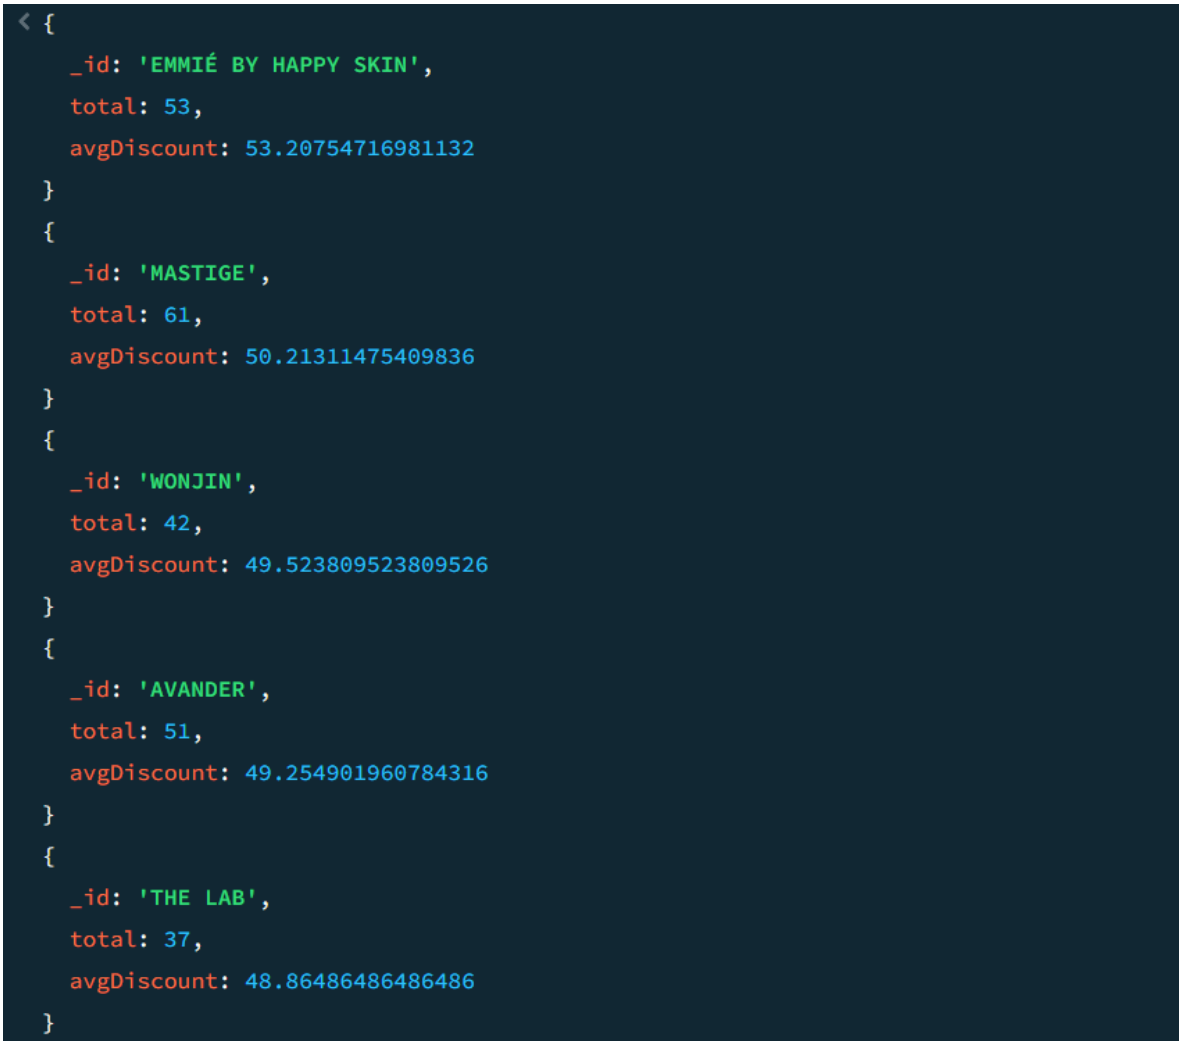
```
{
  _id: 'Pháp',
  total: 686,
  avgPrice: 414775.51020408166,
  avgDiscount: 31.84985422740525
}
{
  _id: 'Nhật Bản',
  total: 680,
  avgPrice: 233864.11764705883,
  avgDiscount: 27.014705882352942
}
{
  _id: 'Trung Quốc',
  total: 498,
  avgPrice: 160808.83534136545,
  avgDiscount: 36.37550200803213
}
```


Hình 4.8. Kết quả thống kê tổng số lượng, giá trung bình và giảm giá trung bình theo xuất xứ sản phẩm

Nguồn: Tác giả tự tổng hợp

- Top 10 thương hiệu giảm giá sâu nhất (thương hiệu từ 30 sản phẩm trở lên)

```
db.product_clean.aggregate([
  { $group: { _id: '$brand', total: { $sum: 1 }, avgDiscount: { avg:'discount_pct' } } },
  { $match: { total: { $gte: 30 } } },
  { $sort: { avgDiscount: -1 } },
  { $limit: 10 }
])
```



Hình 4.9. Lệnh truy vấn và kết quả thống kê Top 10 thương hiệu có tỷ lệ giảm giá sâu nhất (từ 30 sản phẩm trở lên)

Nguồn: Tác giả tự tổng hợp



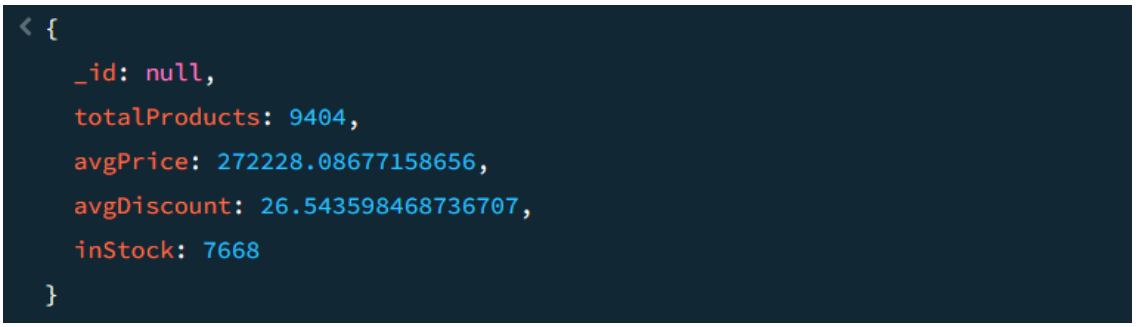
Hình 4.10. Lệnh truy vấn và kết quả thống kê Top 10 thương hiệu có tỷ lệ giảm giá sâu nhất (từ 30 sản phẩm trở lên)

Nguồn: Tác giả tự tổng hợp

- Tổng quan cho toàn bộ collection

```
db.product_clean.aggregate([
  { $group: {
      _id: null,
      totalProducts: { $sum: 1 },
      avgPrice: { avg:'price' },
      avgDiscount: { avg:'discount_pct' },
      inStock: { sum:'in_stock' }
  } }

])
```



Hình 4.11. Lệnh truy vấn và kết quả tổng quan thống kê cho toàn bộ collection

Nguồn: Tác giả tự tổng hợp

Thêm sản phẩm

```
db.product_clean.insertOne({
  source: 'hasaki',
  category_group: 'Chăm sóc da',
  category: 'Chăm sóc da mặt',
  name: 'Sản phẩm thử nghiệm',
  brand: 'TEST',
  product_code: '000000001',
  price: 150000,
  price_original: 200000,
  discount_pct: 25,
  in_stock: 1,
  url: 'https://example.com/test-1',
  scraped_at: new Date()
})
db.product_clean.insertMany([
  {name: 'Thử nghiệm 2', brand: 'TEST', category_group: 'Trang điểm', price: 99000, in_stock: 1, url: 'https://example.com/test-2' },
  {name: 'Thử nghiệm 3', brand: 'TEST', category_group: 'Trang điểm', price: 120000, in_stock: 0, url: 'https://example.com/test-3' }
])
```

Xóa dữ liệu

```
db.product_clean.deleteOne({ url: 'https://example.com/test-1' })
db.product_clean.deleteMany({brand:'TEST'})
```

4.5 Sao lưu và phục hồi dữ liệu

Nhóm thực hiện bảo vệ dữ liệu của nhóm thông qua quy trình sao lưu (backup) và phục hồi (restore) trên MongoDB:

- Sao lưu database DATA (chứa collection product_clean và các collection liên quan) từ MongoDB Atlas về máy tính bằng công cụ mongodump.

- Phục hồi bản sao lưu vào một database thử nghiệm products_test trên MongoDB cục bộ bằng công cụ mongorestore, tránh ghi đè lên dữ liệu thật của nhóm.

- Đối chiếu số lượng document và chỉ mục trước và sau khi phục hồi để đánh giá bản sao lưu có đầy đủ hay không.

Bảng 4.3. Bảng tổng hợp môi trường và thông số kỹ thuật thực hiện sao lưu, phục hồi dữ liệu

Hạng mục	Thông tin
Hệ điều hành	Microsoft Windows 11 (Version 10.0.26200.9711)
Công cụ sao lưu	mongodump version 100.20.0
Công cụ phục hồi	mongorestore version 100.20.0
Giao diện quản trị	MongoDB Compass
Nguồn dữ liệu	MongoDB Atlas, cluster0.4rjebel.mongodb.net
Database nguồn	DATA
Nơi lưu bản sao lưu	C:\Users\Acer\backup1\lan1
Nơi phục hồi	MongoDB cục bộ, 127.0.0.1:27017, database products_test

Nguồn: Tác giả tự tổng hợp

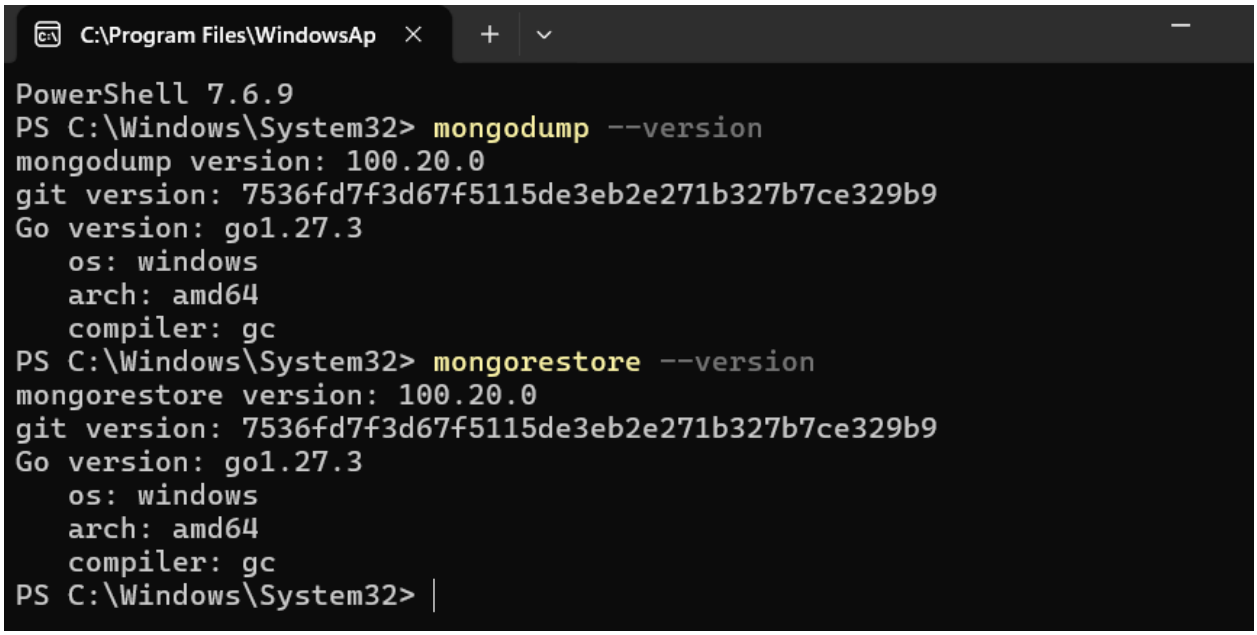
Cài đặt và kiểm tra công cụ

Bộ công cụ MongoDB Database Tools được cài đặt trên Windows. Để xác nhận cài đặt thành công, chạy hai lệnh kiểm tra phiên bản trong Command Prompt:

mongodump --version

mongorestore --version

Kết quả cả hai lệnh đều hiển thị phiên bản **100.20.0** (hệ điều hành windows, kiến trúc amd64), chứng tỏ hai công cụ đã sẵn sàng sử dụng.



Hình 4.12. Lệnh chạy hai lệnh kiểm tra phiên bản trong Command Prompt

Nguồn: Tác giả tự tổng hợp

Dữ liệu gốc trước khi sao lưu

Trong MongoDB Compass, kết nối BIGDATA_CUOIKI chứa database **DATA** gồm 5 collection:

Bảng 4.4. Bảng dữ liệu databasse DATA

Collection	Số document
app_metadata	1
audit_log	17
counters	4
product_clean	9.404
users	9
Tổng	9.435

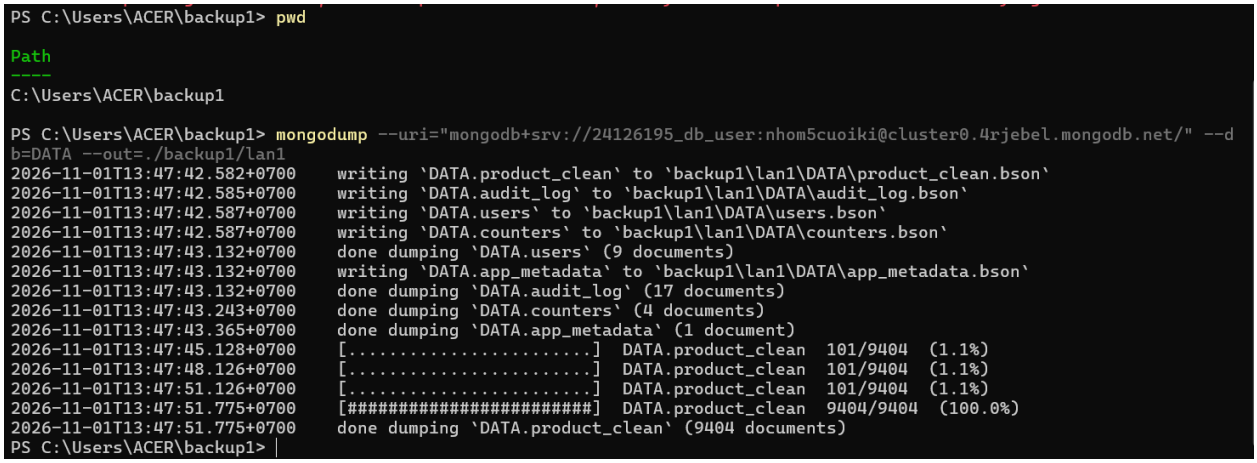
Nguồn: Tác giả tự tổng hợp

Thực hiện sao lưu (Backup)

- *Tạo thư mục lưu bản sao:* mkdir backup1

- Chạy lệnh mongodump

mongodump --uri="mongodb+srv://24126195_db_user:nhom5cuoiki@cluster0.4rjebel.mongodb.net/" --db=DATA --out=./backup1/lan1



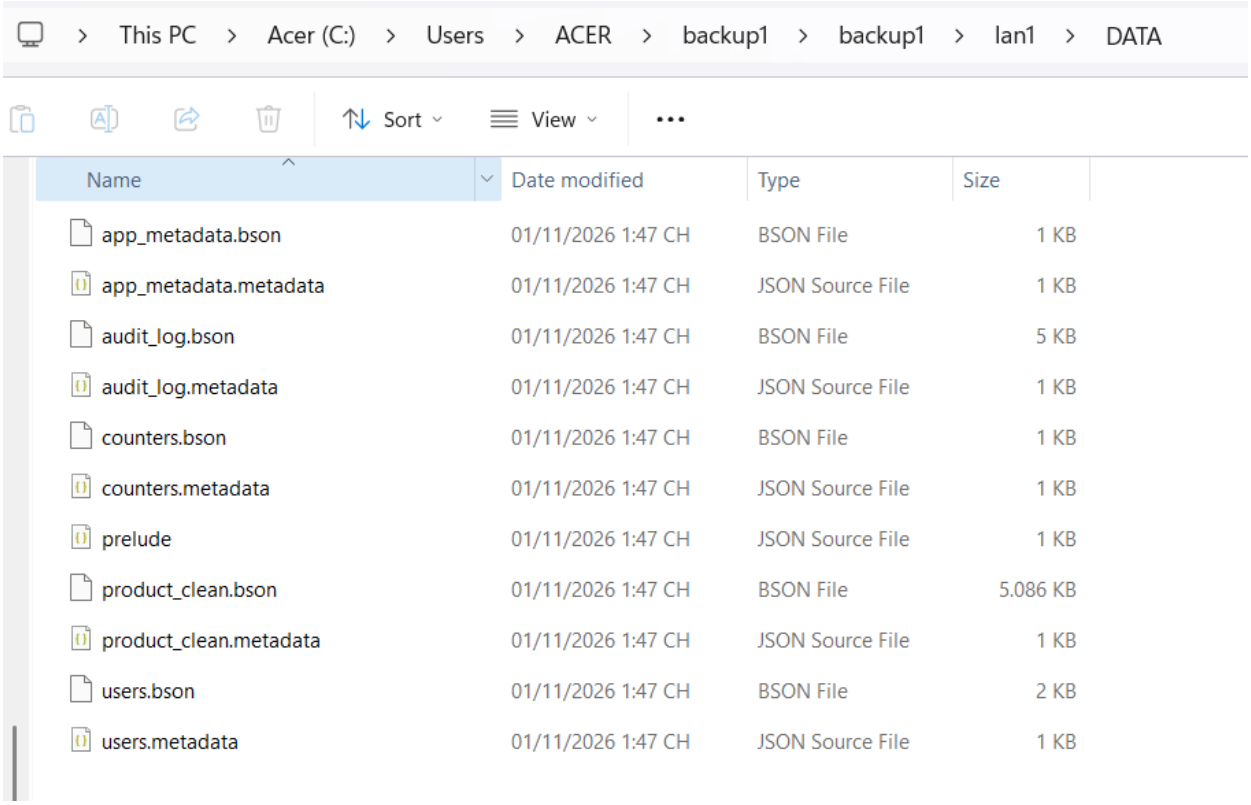
Hình 4.13. Lệnh chạy hai lệnh kiểm tra phiên bản trong Command Prompt

Nguồn: Tác giả tự tổng hợp

Bảng 4.5. Mô tả ý nghĩa các tham số trong câu lệnh mongodump

Tham số	Ý nghĩa
mongodump	Công cụ sao lưu
--uri	Chuỗi kết nối tới MongoDB Atlas
--db=DATA	Chỉ sao lưu database DATA
--out=./backup1/lan1	Thư mục lưu bản sao lưu lần thứ nhất

Nguồn: Tác giả tự tổng hợp



Hình 4.14. Cấu trúc thư mục chứa các tệp sao lưu dữ liệu (.bson và .metadata.json) sau khi chạy script

Nguồn: Tác giả tự tổng hợp

Bảng 4.6. Thống kê số lượng document và tệp dữ liệu tương ứng sau khi thực hiện sao lưu

Collection	Số document đã dump	File tạo ra
audit_log	17	audit_log.bson
users	9	users.bson
counters	4	counters.bson
app_metadata	1	app_metadata.bson
product_clean	9.405 (tiến độ 100%)	product_clean.bson

Nguồn: Tác giả tự tổng hợp

Mỗi collection sinh ra hai loại file trong thư mục `backup1\lan1\DATA`:

`.bson`: chứa dữ liệu các document đã sao lưu.

`.metadata.json`: chứa thông tin cấu trúc và chỉ mục của collection.

Ngoài ra còn có file `prelude.json` do mongodump tạo ra để ghi thông tin chung của bản dump.

Giả lập sự cố mất dữ liệu

Để kiểm tra khả năng phục hồi, nhóm mô phỏng việc mất collection trên database thử nghiệm product_test(kết nối mongodb://127.0.0.1:27017), tuyệt đối không xóa trên database DATA của Atlas.

use products_test

db.product_clean.countDocuments() // trước khi xóa: 9404

db.product_clean.drop()

db.product_clean.countDocuments() // sau khi xóa: 0

Kết quả sau khi xóa là 0 document, nghĩa là collection thử nghiệm đã mất dữ liệu.

Thực hiện phục hồi (Restore)

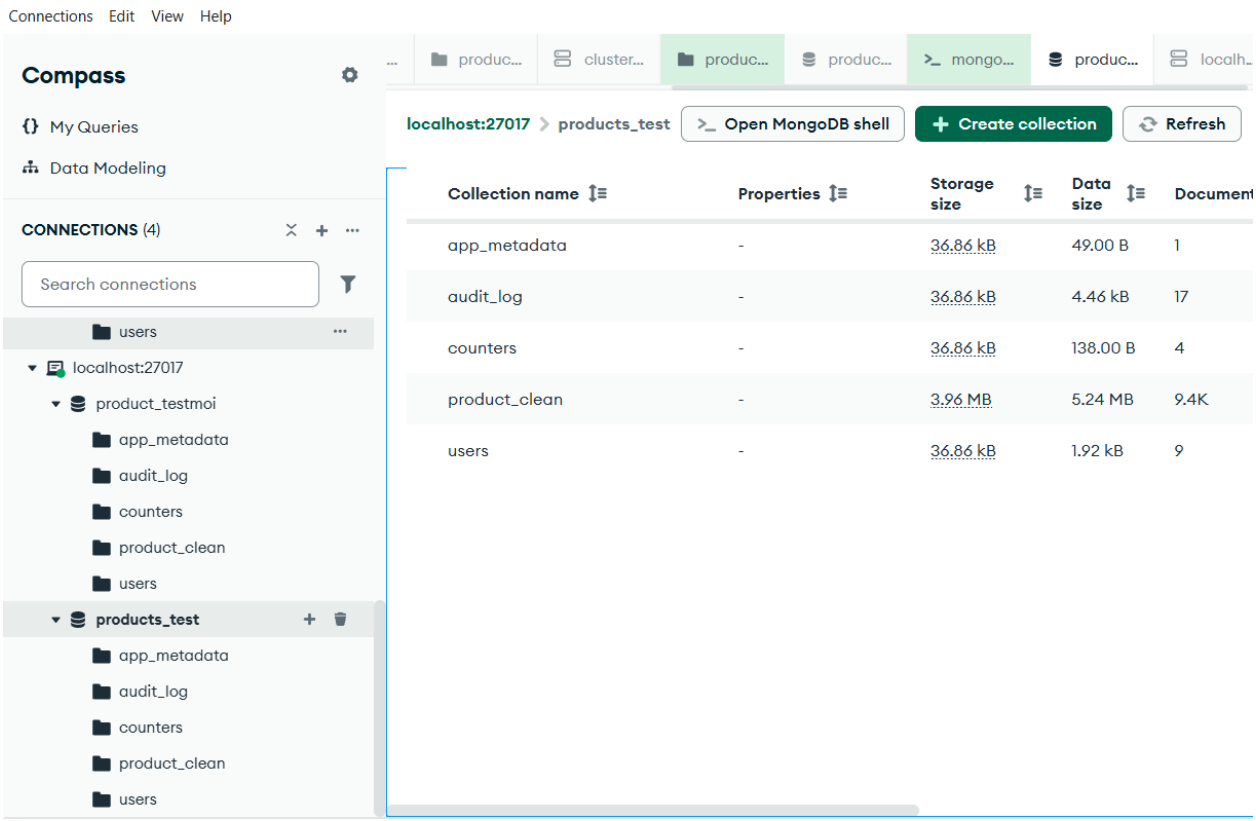
```
mongorestore --uri="mongodb://127.0.0.1:27017" --db=products_test "C:\Users\Acer\backup1\lan1\DATA"
```

Thêm kết nối Localhost mới

Ở góc trên cùng bên phải của mục CONNECTIONS, bấm vào dấu + (hoặc chữ Add connection nếu có) để tạo kết nối mới. Tại ô URI kết nối, nhập chính xác đường dẫn đến máy cục bộ:

mongodb://localhost:27017

->Bấm nút Save & Connect (hoặc Connect)



Hình 4.15. Giao diện hiển thị các collection sau khi khôi phục dữ liệu

Nguồn: Tác giả tự tổng hợp

Bảng 4.7. Mô tả ý nghĩa các tham số trong câu lệnh mongorestore

Thành phần	Ý nghĩa
mongorestore	Công cụ phục hồi
--uri	Địa chỉ MongoDB cục bộ dùng để phục hồi
--db=products_test	Database đích (database thử nghiệm)
Đường dẫn cuối	Thư mục chứa các file backup của database DATA

Nguồn: Tác giả tự tổng hợp

Dòng kết quả cuối cùng: 9435 document(s) restored successfully. 0 document(s) failed to restore.

Bảng 4.8. Thống kê số lượng document và lỗi phát sinh sau khi khôi phục dữ liệu vào cơ sở dữ liệu đích

Collection phục hồi	Số document	Số lỗi
products_test.audit_log	17	0
products_test.users	9	0
products_test.counters	4	0
products_test.app_metadata	1	0
products_test.product_clean	9.404	0
Tổng	9.435	0

Nguồn: Tác giả tự tổng hợp

Các chỉ mục cũng được tạo lại từ file metadata: product_clean có id_1 (duy nhất) và category_group_1; audit_log có at_1; users có id_1 (duy nhất) và username_1 (duy nhất).

- Kiểm tra dữ liệu sau khi phục hồi

Trong MONGOSH, nhóm đếm lại số document, xem một document mẫu và kiểm tra chỉ mục:

```
use products_test
db.product_clean.countDocuments()
```

db.product_clean.findOne()

db.product_clean.getIndexes()

Bảng 4.9. So sánh dữ liệu trước và sau khi phục hồi

Nội dung	Trước backup (DATA, Atlas)	Sau restore (products_test)
Số document product_clean	9.404	9.404
Tổng số document toàn database	9.435	9.435
Số collection	5	5
Chỉ mục product_clean	id_1, category_group_1	id_1, category_group_1
Số document lỗi	0	0
Trạng thái	Bình thường	Đã phục hồi

Nguồn: Tác giả tự tổng hợp

Kết luận kiểm tra: số document và chỉ mục sau phục hồi khớp với dữ liệu gốc nên quy trình thành công. Lưu ý số lượng bằng nhau chưa chứng minh từng giá trị giống hệt nhau; để kiểm chứng chặt hơn có thể so sánh thêm một số document mẫu và các trường quan trọng.

- Tự động sao lưu bằng Python (tùy chọn)

Để không phải nhập lệnh thủ công mỗi lần, nhóm tạo file backup.py gọi mongodump và đặt tên thư mục theo ngày giờ. Chuỗi kết nối được đọc từ biến môi trường

Mỗi lần chạy python backup.py tạo một thư mục mới dạng:

backup1\20261101_1204\DATA, giúp lưu nhiều phiên bản sao lưu theo thời gian. Mã lệnh Python tự động thực hiện sao lưu dữ liệu theo thời gian (backup.py):

```
import subprocess
import datetime
from pathlib import Path

# Lấy ngày giờ hiện tại theo định dạng YYYYMMDD_HHMM
ngay = datetime.datetime.now().strftime("%Y%m%d_%H%M")

# Tạo đường dẫn thư mục lưu trữ backup
thu_muc = Path("./backup1") / ngay

# Tạo thư mục nếu chưa tồn tại
thu_muc.mkdir(parents=True, exist_ok=True)
```

```
        # Cấu hình danh sách lệnh mongodump
        lenh = [
            "mongodump",
            "--
uri=mongodb+srv://24126195_db_user:nhom5cuoiki@cluster0.4rjebel.mongodb.net
/DATA",
            "--db=DATA",
            f"--out={thu_muc}"
        ]

        try:
            # Chạy lệnh hệ thống
            subprocess.run(lenh, check=True)
            print("Sao lưu thành công!")
            print("Đường dẫn thư mục lưu trữ:", thu_muc.resolve())

        except subprocess.CalledProcessError as e:
            print("Sao lưu thất bại!")
            print("Chi tiết lỗi:", e)
```

Kết quả sau khi chạy:

PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI> & 'C:\Program Files\Python314\python.exe' 'c:\Users\ACER\.vscode\extensions\ms-python.debugpy-2026.6.0-win32-x64\bundled\libs\debugpy\launcher' '50218' '--' 'C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI\packup.py'

2026-11-01T11:57:35.961+0700 writing `DATA.product_clean` to `backup1\20261101_1157\DATA\product_clean.bson`

2026-11-01T11:57:35.962+0700 writing `DATA.audit_log` to `backup1\20261101_1157\DATA\audit_log.bson`

2026-11-01T11:57:35.962+0700 writing `DATA.users` to `backup1\20261101_1157\DATA\users.bson`

2026-11-01T11:57:35.962+0700 writing `DATA.counters` to `backup1\20261101_1157\DATA\counters.bson`

2026-11-01T11:57:36.220+0700 done dumping `DATA.audit_log` (17 documents)

2026-11-01T11:57:36.221+0700 writing `DATA.app_metadata` to `backup1\20261101_1157\DATA\app_metadata.bson`

2026-11-01T11:57:36.234+0700 done dumping `DATA.users` (9 documents)

2026-11-01T11:57:36.243+0700 done dumping `DATA.counters` (4 documents)

2026-11-01T11:57:36.299+0700 done dumping `DATA.app_metadata` (1 document)

2026-11-01T11:57:36.766+0700 done dumping `DATA.product_clean` (9404 documents)

Sao lưu thành công!

Đường dẫn thư mục lưu trữ: C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI\backup1\20261101_1157

PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI> python backup.py

```
C:\Program Files\Python314\python.exe: can't open file
'C:\\Users\\ACER\\Downloads\\NĂM 3\\HK1\\BIG
DATA\\BIGDATA_CUOIKI\\backup.py': [Errno 2] No such file or directory
PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
ls

    Directory: C:\Users\ACER\Downloads\NĂM 3\HK1\BIG
DATA\BIGDATA_CUOIKI

Mode                 LastWriteTime         Length Name
----                 -------------         ------ ----
d----          01/11/2026 11:57 SA              backup1
-a---          29/10/2026 10:54 SA           4728 clean_data.py
-a---          31/10/2026  9:15 CH        6707858 DATA.product_clean.json
-a---          31/10/2026  9:33 CH          82002 MongoShell.docx
-a---          01/11/2026 11:56 SA            886 packup.py
-a---          29/10/2026 11:42 SA        1412397 product_clean_mới.xlsx
-a---          30/10/2026  3:55 CH        1465544 products_clean (1).xlsx
-a---          31/10/2026  6:30 CH        1465544 products_clean (NC).xlsx
-a---          30/10/2026  3:37 CH        1452354 products_clean.xlsx
-a---          29/10/2026  1:08 CH        2590041 products_clean(1).csv
-a---          29/10/2026  1:03 CH        1449811 products_clean(1).xlsx
-a---          31/10/2026  8:26 CH        2531399 products_final.csv
-a---          29/10/2026  6:06 SA        1341023 products_final.xlsx

PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
python backup1/backup.py
C:\Program Files\Python314\python.exe: can't open file
'C:\\Users\\ACER\\Downloads\\NĂM 3\\HK1\\BIG
DATA\\BIGDATA_CUOIKI\\backup1\\backup.py': [Errno 2] No such file or directory
PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
python packup.py
2026-11-01T12:03:50.512+0700    writing `DATA.product_clean` to
`backup1\20261101_1203\DATA\product_clean.bson`
2026-11-01T12:03:50.513+0700    writing `DATA.audit_log` to
`backup1\20261101_1203\DATA\audit_log.bson`
2026-11-01T12:03:50.513+0700    writing `DATA.users` to
`backup1\20261101_1203\DATA\users.bson`
2026-11-01T12:03:50.513+0700    writing `DATA.counters` to
`backup1\20261101_1203\DATA\counters.bson`
2026-11-01T12:03:50.995+0700    done dumping `DATA.counters` (4 documents)
2026-11-01T12:03:50.997+0700    done dumping `DATA.audit_log` (17
documents)
2026-11-01T12:03:50.997+0700    writing `DATA.app_metadata` to
`backup1\20261101_1203\DATA\app_metadata.bson`
2026-11-01T12:03:51.085+0700    done dumping `DATA.users` (9 documents)
2026-11-01T12:03:51.148+0700    done dumping `DATA.app_metadata` (1
document)
2026-11-
01T12:03:51.255+0700    [.....................]  DATA.product_clean  101/9404  (1.1%)
```

```
        2026-11-
01T12:03:52.937+0700    [########################]  DATA.product_clean  9404/94
04  (100.0%)
        2026-11-01T12:03:52.939+0700    done dumping `DATA.product_clean` (9404
documents)
        Sao lưu thành công!
        Đường dẫn thư mục lưu trữ: C:\Users\ACER\Downloads\NĂM 3\HK1\BIG
DATA\BIGDATA_CUOIKI\backup1\20261101_1203
        PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
Rename-Item packup.py backup.py
        PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
python backup.py
        2026-11-01T12:04:58.074+0700    writing `DATA.product_clean` to
`backup1\20261101_1204\DATA\product_clean.bson`
        2026-11-01T12:04:58.074+0700    writing `DATA.audit_log` to
`backup1\20261101_1204\DATA\audit_log.bson`
        2026-11-01T12:04:58.074+0700    writing `DATA.users` to
`backup1\20261101_1204\DATA\users.bson`
        2026-11-01T12:04:58.075+0700    writing `DATA.counters` to
`backup1\20261101_1204\DATA\counters.bson`
        2026-11-01T12:04:58.323+0700    done dumping `DATA.audit_log` (17
documents)
        2026-11-01T12:04:58.323+0700    writing `DATA.app_metadata` to
`backup1\20261101_1204\DATA\app_metadata.bson`
        2026-11-01T12:04:58.329+0700    done dumping `DATA.users` (9 documents)
        2026-11-01T12:04:58.347+0700    done dumping `DATA.counters` (4 documents)
        2026-11-01T12:04:58.409+0700    done dumping `DATA.app_metadata` (1
document)
        2026-11-01T12:04:59.044+0700    done dumping `DATA.product_clean` (9404
documents)
        Sao lưu thành công!
        Đường dẫn thư mục lưu trữ: C:\Users\ACER\Downloads\NĂM 3\HK1\BIG
DATA\BIGDATA_CUOIKI\backup1\20261101_1204
        PS C:\Users\ACER\Downloads\NĂM 3\HK1\BIG DATA\BIGDATA_CUOIKI>
```

KẾT LUẬN: Nhóm đã thực hiện đầy đủ quy trình sao lưu và phục hồi cho database DATA (5 collection, 9.435 document, trong đó `product_clean` có 9.404 document) và đạt các kết quả sau:

- Sao lưu thành công. `mongodump` sao lưu toàn bộ database DATA từ MongoDB Atlas về máy trong chưa đến 2 giây. Mỗi collection tạo ra một file `.bson` (dữ liệu) và một file `.metadata.json` (cấu trúc, chỉ mục). Số document ghi nhận khớp với số liệu trong Compass.

- Phục hồi thành công. `mongorestore` phục hồi vào database thử nghiệm `products_test` trên MongoDB cục bộ với kết quả **9.435 document, 0 lỗi**. Các chỉ mục

(`id_1`, `category_group_1`, `at_1`, `username_1`) được tạo lại từ file metadata. Số document, số collection và chỉ mục đều khớp với dữ liệu gốc.

- Tự động hóa được việc sao lưu. Chương trình `backup.py` gọi `mongodump` và đặt tên thư mục theo ngày giờ. Chương trình chạy thành công 3 lần, mỗi lần tạo một thư mục riêng (`20261101_1157`, `20261101_1203`, `20261101_1204`) và đều sao lưu đủ 9.404 document của `product_clean`, nên các bản sao lưu không ghi đè lên nhau.

CHƯƠNG 5. TRỰC QUAN HÓA DỮ LIỆU VÀ DASHBOARD

5.1 Các chỉ số thống kê và giá trị min–max

5.1.1. Mục đích thống kê dữ liệu

Sau khi hoàn thành quá trình thu thập, làm sạch và chuẩn hóa dữ liệu, nhóm tiến hành thống kê mô tả nhằm khái quát đặc điểm của thị trường mỹ phẩm và chăm sóc cá nhân trên hai nền tảng thương mại điện tử Hasaki và Cocolux. Việc thống kê giúp nhóm xác định quy mô sản phẩm, mức giá phổ biến, tỷ lệ giảm giá, mức độ đánh giá của khách hàng, tình trạng tồn kho cũng như sự phân bố sản phẩm theo thương hiệu, ngành hàng và quốc gia xuất xứ.

Các chỉ số thống kê được sử dụng gồm:

- Count: tổng số lượng sản phẩm hoặc số bản ghi hợp lệ.
- Mean: giá trị trung bình của một biến dữ liệu.
- Median: giá trị trung vị, thể hiện mức nằm giữa của tập dữ liệu sau khi sắp xếp.
- Min, Max: giá trị nhỏ nhất và lớn nhất của biến dữ liệu.
- Percentage: tỷ lệ phần trăm của một nhóm so với tổng thể.
- Sum: tổng giá trị của một biến, chẳng hạn tổng lượt đánh giá.

5.1.2 Thống kê tổng quan bộ dữ liệu

Bộ dữ liệu sau khi làm sạch gồm 9.404 sản phẩm thuộc 488 thương hiệu, được thu thập từ Hasaki và Cocolux. Từ các trường price, price_original, discount_pct, rating, review_count, in_stock, brand, origin và category_group, nhóm xác định bộ chỉ số phục vụ phân tích như Bảng 5.1.

Bảng 5.1. Các chỉ số thống kê tổng quan

Chỉ số	Giá trị	Cách tính	Ý nghĩa
Tổng sản phẩm	9.404	Đếm số dòng	Quy mô tập dữ liệu
Tổng thương hiệu	488	Đếm brand khác nhau	Mức độ đa dạng thương hiệu
Giá trung bình	272.228 đ	Trung bình price	Mặt bằng giá (bị kéo lên bởi nước hoa cao cấp)
Giá trung vị	189.000 đ	Trung vị price	Mức giá điển hình của một sản phẩm
Chiết khấu trung bình	26,5%	Trung bình discount_pct	Mức độ khuyến mãi chung

Đánh giá trung bình	4,90 / 5	Trung bình rating (chỉ sản phẩm có đánh giá)	Mức hài lòng của khách hàng
Tổng lượt đánh giá	270.470	Tổng review_count	Mức độ tương tác
Tỷ lệ hàng có sẵn	81,5% (0,82)	Trung bình in_stock	Tình trạng tồn kho
Tỷ lệ có đánh giá (Rating coverage)	40,6%	Số sản phẩm có rating / tổng	Độ phủ của dữ liệu đánh giá

Nguồn: Kết quả thống kê từ bộ dữ liệu products_clean

Qua bảng thống kê có thể nhận thấy: bộ dữ liệu đủ đa dạng về sản phẩm và thương hiệu để so sánh hai nhà bán lẻ; tỷ lệ giảm giá trung bình 26,54% cho thấy khuyến mãi khá phổ biến; điểm đánh giá trung bình 4,90/5 rất cao nhưng chỉ 40,59% sản phẩm có dữ liệu đánh giá; và 81,54% sản phẩm còn hàng, tương ứng 18,46% (1.736 sản phẩm) hết hàng tại thời điểm thu thập.

Giá trung bình (272 nghìn đồng) cao hơn giá trung vị (189 nghìn đồng) khoảng 44%. Phân phối giá lệch phải mạnh (hệ số bất đối xứng khoảng 5,7): 75% sản phẩm có giá dưới 319.000 đ, 90% dưới 499.000 đ, trong khi 1% sản phẩm đắt nhất vượt 1,95 triệu đồng. Vì vậy báo cáo ưu tiên dùng giá trung vị khi so sánh giữa các nhóm.

5.1.2 Thống kê theo nguồn dữ liệu

Bảng 5.2. So sánh các chỉ số giữa Hasaki và Cocolux

Chỉ số	Hasaki	Cocolux
Số sản phẩm (tỷ trọng)	6.481 (68,9%)	2.923 (31,1%)
Số thương hiệu	367	273
Giá trung bình	220.167 đ	387.661 đ
Giá trung vị	159.000 đ	259.000 đ
Chiết khấu trung bình	34,7%	8,4%
Tỷ lệ sản phẩm có giảm giá	98,9%	45,7%
Tổng lượt đánh giá	57.587	212.883
Lượt đánh giá / sản phẩm	8,9	72,8
Tỷ lệ sản phẩm có đánh giá	44,2%	32,6%
Đánh giá trung bình	4,89	4,95
Tỷ lệ còn hàng	73,2%	99,97%

Nguồn: Kết quả thống kê từ bộ dữ liệu products_clean

5.1.3 Giá trị min–max

Để xác định phạm vi biến động của các thuộc tính quan trọng, nhóm thống kê giá trị nhỏ nhất và lớn nhất, thể hiện trong trang dashboard "Thống kê và Min-Max". Kết quả được tổng hợp ở Bảng 5.3.

Bảng 5.3. Các giá trị nhỏ nhất và lớn nhất

Chỉ tiêu	Giá trị	Sản phẩm / đối tượng	Nguồn
Giá thấp nhất	2.000 đ	[HSD 01/2027] Mặt Nạ Klairs Làm Dịu Da & Kiểm Soát Dầu Nhờn 25ml (giảm 97%)	Hasaki
Giá cao nhất	5.450.000 đ	Nước Hoa Dolce & Gabbana The Only One EDP 100ml	Cocolux
Chiết khấu cao nhất	99%	[HSD 02/2027] Mặt Nạ GoodnDoc Dưỡng Ẩm, Tái Tạo Da 25ml (6.000 đ); có 2 sản phẩm đạt 99%	Hasaki
Chiết khấu thấp nhất	0%	1.658 sản phẩm không giảm giá (17,6%)	Cả hai
Nhiều đánh giá nhất	989 lượt	Mặt Nạ Banobagi Vita Genic Jelly Mask (nhiều phiên bản cùng mức 989)	Cocolux
Đánh giá thấp nhất	3,0 sao	1 sản phẩm	–
Thương hiệu nhiều sản phẩm nhất	3CE – 266 sản phẩm	Hasaki 142, Cocolux 124	Cả hai
Thương hiệu nhiều đánh giá nhất	CLIO – 33.988 lượt	99 sản phẩm, đánh giá 4,99	Cả hai

Nguồn: Kết quả thống kê từ bộ dữ liệu products_clean

Nhìn chung, giá bán dao động từ 2.000 đ đến 5.450.000 đ (giá gốc từ 8.000 đ đến 5.555.000 đ), cho thấy thị trường có cả sản phẩm giá rất thấp lẫn phân khúc cao cấp, đặc biệt

là nước hoa. Tỷ lệ giảm giá trải rộng từ 0% đến 99%, phản ánh chính sách khuyến mãi không đồng nhất: có sản phẩm bán đúng giá niêm yết, có sản phẩm giảm rất sâu. Điểm đánh giá nằm trong khoảng 3,0-5,0 và số lượt đánh giá từ 0 đến 989, cho thấy mức độ quan tâm của khách hàng đối với từng sản phẩm chênh lệch đáng kể.

Các sản phẩm đắt nhất đều là nước hoa của Cocolux (10 sản phẩm đầu bảng có giá từ 3,9 đến 5,45 triệu đồng), trong khi các sản phẩm rẻ nhất đều là mặt nạ cận date của Hasaki. Các giá trị min-max vì vậy còn giúp phát hiện những trường hợp giá hoặc mức giảm bất thường cần kiểm tra thêm trước khi đưa vào phân tích.

5.1.4 Thống kê theo nhóm ngành và nguồn

Dữ liệu được chia thành năm nhóm ngành hàng: Chăm sóc da (4.130 sản phẩm, 43,92%), Trang điểm (3.007 sản phẩm, 31,98%), Chăm sóc cơ thể (1.132 sản phẩm), Chăm sóc tóc (823 sản phẩm) và Nước hoa (312 sản phẩm, 3,32%). Chăm sóc da và Trang điểm chiếm gần 76% tổng số sản phẩm. Bảng 5.4 trình bày chi tiết theo từng nhóm ngành và nguồn dữ liệu.

Bảng 5.4. Thống kê theo nhóm ngành hàng và nguồn dữ liệu

Nhóm ngành	Nguồn	Số SP	Giá min	Giá trung vị	Giá max	% giảm TB	Rating TB	Tổng review
Chăm sóc da	Cocolux	1.090	8.000	297.000	3.299.000	7,3%	4,95	77.621
Chăm sóc da	Hasaki	3.040	2.000	186.000	2.625.000	36,8%	4,90	41.012
Trang điểm	Cocolux	1.280	32.000	265.000	1.999.000	10,6%	4,95	114.864
Trang điểm	Hasaki	1.727	9.000	144.000	814.000	35,9%	4,88	6.467
Chăm sóc cơ thể	Cocolux	311	21.000	199.000	1.404.000	3,6%	4,95	16.951
Chăm sóc cơ thể	Hasaki	821	9.000	140.000	1.268.000	29,1%	4,88	6.828
Chăm sóc tóc	Cocolux	110	48.000	176.000	624.000	3,1%	4,93	3.447

Chăm sóc tóc	Hasaki	713	10.000	159.000	1.499.000	30,2%	4,86	2.716
Nước hoa	Cocolux	132	118.000	1.950.000	5.450.000	11,0%	–	0
Nước hoa	Hasaki	180	10.000	322.500	3.359.000	33,4%	4,90	564

Ghi chú: nhóm Nước hoa của Cocolux chưa có lượt đánh giá nào nên không có điểm đánh giá trung bình.

5.2 Thiết kế dashboard

5.2.1 Nguyên tắc thiết kế

Dashboard được xây dựng bằng Power BI Desktop trên bảng dữ liệu đã làm sạch. Mỗi trang áp dụng cùng một bố cục: tiêu đề trang ở trên cùng, hàng bộ lọc (slicer), hàng chỉ số hoặc biểu đồ tổng quan, rồi đến các biểu đồ chi tiết. Các nguyên tắc chung gồm:

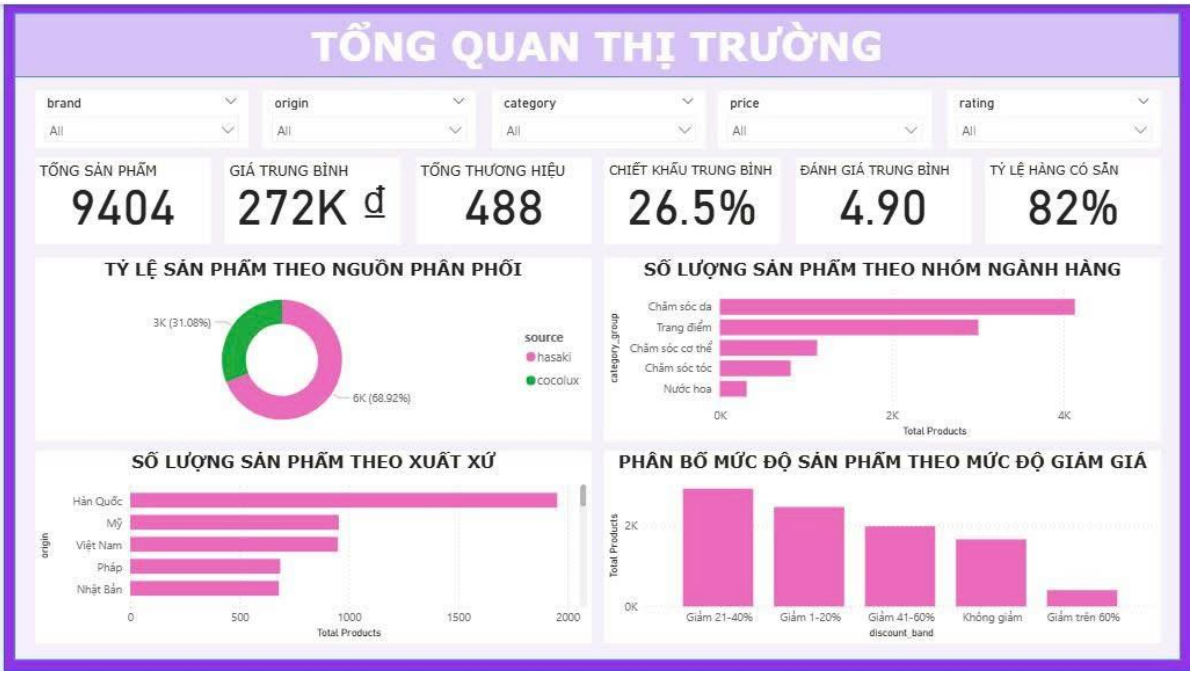
- Hài hòa: dùng nền tím nhạt và tiêu đề đồng nhất; màu hồng đại diện Hasaki và màu xanh lá đại diện Cocolux ở mọi biểu đồ có chia theo nguồn.

- Đầy đủ thông tin: mỗi biểu đồ có tiêu đề tiếng Việt, tên trục, nhãn dữ liệu hoặc tooltip.

- Tương tác: các slicer (brand, origin, category, price, rating, source, discount_pct, review_count, stock_status) và cơ chế lọc chéo giữa các biểu đồ cho phép người dùng khoanh vùng phân tích mà không cần viết truy vấn.

- Từ tổng quan đến chi tiết: trang 1 cho cái nhìn toàn cảnh, trang 2 đáp ứng yêu cầu min-max, trang 3 so sánh hai sàn, các trang 4 - 6 đi sâu vào từng chủ đề.

5.2.2 Trang 1 - Tổng quan thị trường



Hình 5.1. Dashboard tổng quan thị trường sản phẩm mỹ phẩm và chăm sóc cá nhân

Nguồn: Nhóm tác giả thực hiện

- Mục đích: cung cấp bức tranh chung về quy mô và cơ cấu dữ liệu.

- Bộ lọc: brand, origin, category, price, rating.

- Biểu đồ: sáu thẻ KPI (tổng sản phẩm, giá trung bình, tổng thương hiệu, chiết khấu trung bình, đánh giá trung bình, tỷ lệ hàng có sẵn); biểu đồ vành khuyên (donut) thể hiện tỷ lệ theo nguồn; biểu đồ thanh ngang cho số sản phẩm theo nhóm ngành và theo xuất xứ; biểu đồ cột cho phân bố mức giảm giá. Donut phù hợp vì chỉ có hai phần của một tổng; thanh ngang giúp đọc tên nhóm dài dễ hơn.

- Nhận xét: Hasaki chiếm 68,9% và Cocolux 31,1% số sản phẩm. Chăm sóc da (4.130 sản phẩm, 43,9%) và Trang điểm (3.007 sản phẩm, 32,0%) chiếm gần 76% toàn bộ dữ liệu. Về giảm giá, nhóm 21-40% đông nhất (2.908 sản phẩm, 30,9%), tiếp theo là 1-20% (2.456), 41-60% (1.980), không giảm (1.658) và trên 60% (402).

5.2.3 Trang 2 – Thống kê và Min–Max



source	cocolux								hasaki				
category_group	Min Price	Avg Rating	Total Reviews	Avg Discount %	Median Price	Max Price	Max Discount	Total Products	Min Price	Avg Rating	Total Reviews	Avg Discount %	Median Pr
Chăm sóc cơ thể	21,000 ₫	4.95	16951	3.6%	199,000 ₫	1,404,000 ₫	0.78	311	9,000 ₫	4.88	6828	29.1%	140,00
Chăm sóc da	8,000 ₫	4.95	77621	7.3%	297,000 ₫	3,299,000 ₫	0.42	1090	2,000 ₫	4.90	41012	36.8%	186,00
Chăm sóc tóc	48,000 ₫	4.93	3447	3.1%	176,000 ₫	624,000 ₫	0.32	110	10,000 ₫	4.86	2716	30.2%	159,00
Nước hoa	118,000 ₫		0	11.0%	1,950,000 ₫	5,450,000 ₫	0.30	132	10,000 ₫	4.90	564	33.4%	322,50
Total	**8,000 ₫**	**4.95**	**212883**	**8.4%**	**259,000 ₫**	**5,450,000 ₫**	**0.78**	**2923**	**2,000 ₫**	**4.89**	**57587**	**34.7%**	**159,00**

Hình 5.2. Dashboard thống kê và xác định giá trị Min – Max của sản phẩm

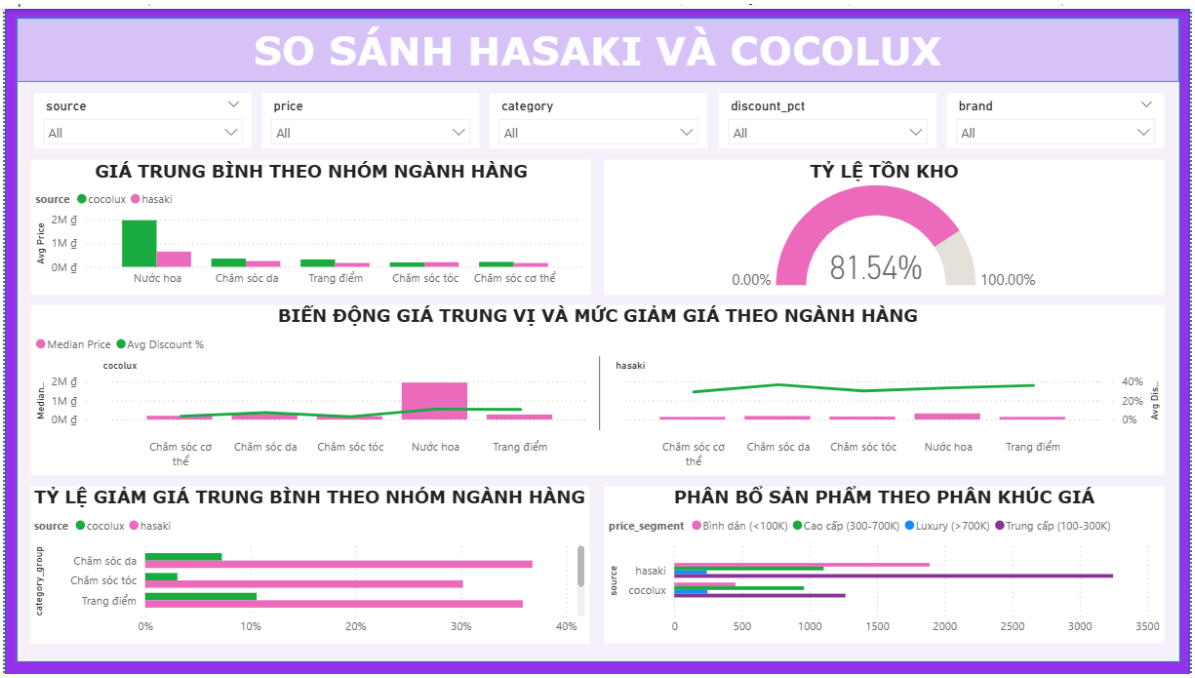
Nguồn: Nhóm tác giả thực hiện

- Mục đích: liệt kê giá trị min–max của sản phẩm.

- Biểu đồ: một thẻ nhiều dòng (multi-row card) ở đầu trang tóm tắt thương hiệu đứng đầu, số review lớn nhất, giá nhỏ nhất và lớn nhất, mức giảm sâu nhất; bốn biểu đồ thanh xếp hạng Top 10 (đắt nhất, giảm sâu nhất, rẻ nhất, nhiều đánh giá nhất); một bảng ma trận (matrix) thống kê theo nhóm ngành và nguồn gồm giá nhỏ nhất, đánh giá trung bình, tổng review, % giảm trung bình, giá trung vị, giá lớn nhất.

- Nhận xét: nhóm đắt nhất toàn là nước hoa của Cocolux, nhóm rẻ nhất và giảm sâu nhất chủ yếu là mặt nạ cận date của Hasaki. Trong 48 sản phẩm giảm từ 90% trở lên, khoảng 65% có nhãn HSD (hạn sử dụng).

5.2.4 Trang 3 – So sánh Hasaki và Cocolux



Hình 5.3. Dashboard so sánh sản phẩm giữa hai nền tảng Hasaki và Cocolux

Nguồn: Nhóm tác giả thực hiện

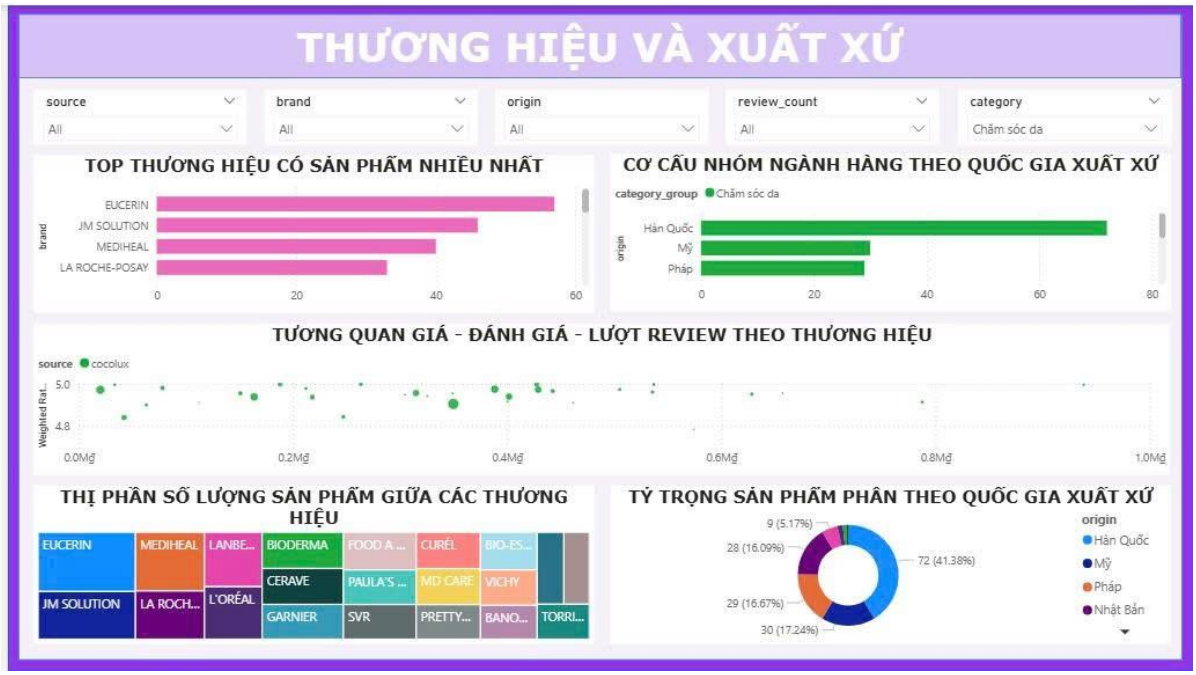
- Mục đích: đối sánh trực tiếp hai sàn theo giá, khuyến mãi, phân khúc và tồn kho.

- Bộ lọc: source, price, category, discount_pct, brand.

- Biểu đồ: cột nhóm (clustered column) cho giá trung bình theo nhóm ngành; biểu đồ kết hợp cột và đường (combo) cho giá trung vị và % giảm giá trung bình theo nhóm ngành, tách riêng từng sàn; thanh nhóm cho tỷ lệ giảm giá; thanh nhóm cho phân khúc giá; đồng hồ đo (gauge) cho tỷ lệ tồn kho. Biểu đồ combo cho phép nhìn đồng thời hai thang đo khác nhau (giá bằng đồng và mức giảm bằng phần trăm).

- Nhận xét: Cocolux có giá trung bình cao hơn Hasaki ở hầu hết các nhóm, chênh lệch lớn nhất ở nước hoa (khoảng 1,98 triệu so với 0,65 triệu đồng, gấp hơn 3 lần). Ngược lại, Hasaki giảm giá sâu hơn rõ rệt ở mọi nhóm ngành. Đồng hồ đo cho thấy tỷ lệ hàng có sẵn chung là 0,82 (81,5%).

5.2.5 Trang 4 - Thương hiệu và Xuất xứ



Hình 5.4. Dashboard phân tích thương hiệu và xuất xứ sản phẩm

Nguồn: Nhóm tác giả thực hiện

- Mục đích: phân tích cấu trúc thương hiệu và nguồn gốc hàng hóa.

- Bộ lọc: source, brand, origin, review_count, category.

- Biểu đồ: thanh ngang cho top thương hiệu có nhiều sản phẩm nhất; treemap thể hiện thị phần số lượng sản phẩm giữa các thương hiệu; biểu đồ bong bóng (scatter) thể hiện tương quan giá, đánh giá và lượt review theo thương hiệu (kích thước bóng là số review, màu theo nguồn); thanh nhóm cho cơ cấu nhóm ngành theo quốc gia xuất xứ; donut cho tỷ trọng sản phẩm theo quốc gia. Treemap phù hợp với danh sách thương hiệu dài vì thể hiện được tỷ trọng mà không cần nhiều không gian.

- Nhận xét: thị trường phân tán, 10 thương hiệu lớn nhất chỉ chiếm 20,3% số sản phẩm, trong khi 213 trong 488 thương hiệu (43,6%) có không quá 5 sản phẩm. Hàn Quốc dẫn đầu xuất xứ (28,6% trong các sản phẩm có xuất xứ), tiếp theo là Mỹ (14,0%) và Việt Nam (13,9%). Phần lớn thương hiệu có đánh giá rất gần 5 sao nên các bong bóng xếp thành một dải ngang sát mức 4,5–5,0.

5.2.6 Trang 5 - Giá và Khuyến mãi



Hình 5.5. Dashboard phân tích giá bán và chương trình khuyến mãi

Nguồn: Nhóm tác giả thực hiện

- Mục đích: phân tích cách định giá và chiến lược chiết khấu.

- Bộ lọc: source, origin, price (bins), discount_pct, category, cùng hai thanh trượt khoảng giá và khoảng chiết khấu.

- Biểu đồ: scatter giữa giá bán và tỷ lệ chiết khấu của từng sản phẩm; cột cho % giảm giá trung bình theo danh mục; cột tần suất phân bố giá (histogram); cột chồng (stacked column) cho cơ cấu sản phẩm theo phân khúc giá và theo nguồn.

- Nhận xét: histogram có đuôi dài bên phải: phần lớn sản phẩm tập trung dưới 500.000 đ. Scatter cho thấy sản phẩm càng đắt càng ít được giảm sâu: 85 sản phẩm giá từ 2 triệu đồng trở lên chỉ giảm trung bình 13,9% và không sản phẩm nào vượt 47%, trong khi nhóm dưới 100.000 đ giảm trung bình 32,1%.

5.2.7 Trang 6 – Đánh giá và Tồn kho



Hình 5.6. Dashboard phân tích đánh giá khách hàng và tình trạng tồn kho

Nguồn: Nhóm tác giả thực hiện

- Mục đích: đánh giá chất lượng dữ liệu đánh giá và tình trạng còn hàng.

- Bộ lọc: source, origin, review_count, stock_status, category.

- Biểu đồ: thẻ Rating coverage (40,6%); cột phân bố sản phẩm theo phân khúc đánh giá; thanh cho tổng lượt đánh giá theo sản phẩm; thanh chồng 100% (100% stacked bar) cho tỷ lệ còn hàng và hết hàng theo nhóm ngành; thanh xếp hạng sản phẩm hết hàng có nhiều đánh giá nhất; cột so sánh tổng lượt đánh giá theo nguồn bán.

- Nhận xét: 5.587 sản phẩm (59,4%) chưa có đánh giá nào. Trong 3.817 sản phẩm có đánh giá, 54,9% đạt đúng 5,0 sao. Cocolux chiếm 212.883 lượt (78,7% tổng lượt đánh giá), gấp hơn 3,6 lần Hasaki dù chỉ có 31,1% số sản phẩm.

5.2.8 Tổng hợp các loại biểu đồ đã sử dụng

Bảng 5.5. Các loại biểu đồ và mục đích sử dụng

Loại biểu đồ	Trang	Mục đích
Card, Multi-row card	1, 2, 6	Hiển thị KPI và giá trị min–max
Donut	1, 4	Tỷ lệ theo nguồn và xuất xứ
Bar / Clustered bar	1, 2, 3, 4, 6	So sánh giá trị giữa các nhóm, xếp hạng Top 10
Column / Clustered column	1, 3, 5, 6	So sánh phân bố, histogram giá

Stacked column, 100% stacked bar	5, 6	Cơ cấu thành phần
Line and clustered column (combo)	3	Kết hợp giá trung vị và % giảm giá
Gauge	3	Tỷ lệ tồn kho
Scatter / Bubble	4, 5	Quan hệ giữa các biến số
Treemap	4	Thị phần thương hiệu
Matrix	2	Bảng thống kê đa chiều theo nhóm ngành và nguồn
Slicer (danh sách thả xuống, thanh trượt)	1, 3, 4, 5, 6	Lọc tương tác

Nguồn: Tổng hợp từ dashboard Power BI

5.3 Các phát hiện chính

Dữ liệu tập trung vào chăm sóc da và trang điểm, Hasaki chiếm ưu thế về số lượng: Hasaki có 6.481 sản phẩm (68,9%), Cocolux có 2.923 (31,1%). Chăm sóc da và trang điểm chiếm 75,9% tổng số sản phẩm, trong khi nước hoa chỉ chiếm 3,3% (312 sản phẩm). Danh mục da và trang điểm là nơi cạnh tranh gay gắt nhất và cũng là nơi có nhiều dữ liệu nhất để phân tích sâu.

Hasaki cạnh tranh bằng giá, Cocolux giữ giá: Chiết khấu trung bình của Hasaki là 34,7% và 98,9% sản phẩm có giảm giá, so với 8,4% và 45,7% của Cocolux (54,3% sản phẩm Cocolux không giảm giá). Khoảng cách này xuất hiện ở mọi nhóm ngành, rõ nhất ở chăm sóc da (36,8% so với 7,3%). Hai sàn theo đuổi hai chiến lược giá khác nhau, một bên dựa vào khuyến mãi sâu, một bên giữ giá niêm yết.

Cocolux định vị cao cấp hơn: Giá trung vị của Cocolux là 259.000 đ, cao hơn 63% so với 159.000 đ của Hasaki. Ở phân khúc giá: Hasaki có 29,1% sản phẩm bình dân (dưới 100.000 đ) và 3,7% luxury (trên 700.000 đ), còn Cocolux là 15,5% và 8,4%. Nhóm trung cấp (100.000–300.000 đ) là lớn nhất ở cả hai sàn (50,2% và 43,4%). Nước hoa là điểm khác biệt rõ nhất: giá trung vị của Cocolux là 1,95 triệu đồng, gấp hơn 6 lần Hasaki (322.500 đ). Cocolux phù hợp với thương hiệu cao cấp và nước hoa, Hasaki phù hợp với sản phẩm phổ thông, nhạy cảm về giá.

Sản phẩm giảm cực sâu phần lớn là hàng cận date: Có 1.272 sản phẩm gắn nhãn HSD (13,5% dữ liệu), gần như toàn bộ thuộc Hasaki (1.246 sản phẩm, tức 19,2% danh mục của sàn này). Mức giảm trung bình của nhóm HSD là 46,5%, so với 23,4% ở nhóm còn lại. Trong số

sản phẩm giảm từ 60% trở lên, 61% là hàng HSD. Nếu loại hàng HSD, chiết khấu trung bình của Hasaki vẫn đạt 31,7%, cho thấy mức giảm cao của sàn này không chỉ do xả hàng cận date. Khi đánh giá khuyến mãi cần tách riêng hàng cận date để không đánh giá quá cao mức giảm thông thường.

Sản phẩm càng đắt càng ít được giảm giá: Nhóm trên 2 triệu đồng (85 sản phẩm, 70 thuộc Cocolux) giảm trung bình 13,9%, tối đa 47%; nhóm dưới 100.000 đ giảm trung bình 32,1%. Hàng cao cấp giữ giá tốt hơn, khuyến mãi tập trung ở phân khúc giá thấp.

Hàn Quốc dẫn đầu xuất xứ, mỗi nước có thế mạnh riêng: Trong 6.822 sản phẩm có thông tin xuất xứ, Hàn Quốc chiếm 28,6% (1.953 sản phẩm), sau đó là Mỹ 14,0%, Việt Nam 13,9%, Pháp 10,1%, Nhật Bản 10,0% và Trung Quốc 7,3%. Sản phẩm Hàn Quốc tập trung ở chăm sóc da (1.090) và trang điểm (715). Pháp mạnh ở chăm sóc da (470/686 sản phẩm) và có giá trung vị cao nhất (285.500 đ). Trung Quốc gần như chỉ ở trang điểm (375/498 sản phẩm) với giá trung vị thấp (124.500 đ). Mỹ và Việt Nam phân bố đều hơn giữa các nhóm.

Thị trường phân tán nhiều thương hiệu: 3CE (266 sản phẩm), Maybelline (241), Cocoon (230), B.O.M (224) và L'Oréal (205) dẫn đầu, nhưng 10 thương hiệu đầu chỉ chiếm 20,3% số sản phẩm; 213 thương hiệu có không quá 5 sản phẩm và 65 thương hiệu chỉ có 1 sản phẩm. Về mức độ quan tâm của khách hàng, CLIO (33.988 lượt), Peripera (27.155) và Black Rouge (22.290) dẫn đầu, tức nhiều review không đồng nghĩa với nhiều sản phẩm. Quy mô danh mục và sức hút với khách hàng là hai chỉ số khác nhau khi đánh giá thương hiệu.

Đánh giá cao nhưng ít phân biệt, tương tác tập trung ở Cocolux: Điểm đánh giá trung bình là 4,90, trong đó 54,9% sản phẩm có đánh giá đạt đúng 5,0 sao và chỉ 4,2% dưới 4,5 sao. Do điểm số dồn sát mức tối đa, rating khó dùng để phân biệt chất lượng giữa các sản phẩm. Lượt đánh giá trên mỗi sản phẩm của Cocolux (72,8) cao gấp 8 lần Hasaki (8,9) và có 466 sản phẩm (5,0%) vượt 100 lượt trong khi 59,4% chưa có đánh giá nào. Nên kết hợp số lượt đánh giá với điểm số khi xếp hạng sản phẩm.

Tồn kho Hasaki có nhiều sản phẩm hết hàng, Cocolux gần như đầy đủ: Toàn bộ dữ liệu có 81,5% sản phẩm còn hàng (1.736 sản phẩm hết hàng). Hasaki còn hàng 73,2% (1.735 sản phẩm hết hàng), còn Cocolux đạt 99,97% (chỉ 1 sản phẩm hết hàng). Theo nhóm ngành, nước hoa có tỷ lệ còn hàng thấp nhất (72,1%), các nhóm còn lại dao động 81-83%. Trong số sản phẩm hết hàng, 16,5% có lượt đánh giá, nổi bật là [Mini] Nước Hoa Hồng Klairs Không Mùi (148 lượt) và nhóm sản phẩm Skin1004 Rau Má (102 lượt), cho thấy nhu cầu thực tế đối với các sản phẩm này.

CHƯƠNG 6: MÔ HÌNH HỌC MÁY

Tổng quan bốn mô hình

Bảng 6.1. Tổng quan bốn mô hình học máy trong chương

Mô hình	Loại học	Câu hỏi kinh doanh	Thuật toán	Kết quả chính
Phân khúc thương hiệu	Không giám sát	Các thương hiệu chia thành những nhóm nào?	K-Means (K = 4, chạy riêng từng sàn)	Silhouette 0,179 (Hasaki) và 0,299 (Cocolux)
Dự đoán giá niêm yết	Có giám sát (hồi quy)	Một sản phẩm nên niêm yết bao nhiêu?	Random Forest	R^2 kiểm định chéo 0,839; sai lệch trung vị 14,6%
Dự đoán hết hàng	Có giám sát (phân loại)	Sản phẩm Hasaki nào dễ hết hàng?	Random Forest	AUC kiểm định chéo 0,813; recall 0,724
Phát hiện bất thường	Không giám sát	Giá hoặc mức giảm nào bất thường?	IQR, Isolation Forest, LOF	68 sản phẩm bị từ 2 phương pháp trở lên gắn cờ

Nguồn: Tác giả tự tổng hợp.

Các chỉ số dùng trong chương

Bảng 6.2. Các chỉ số đánh giá dùng trong chương

Chỉ số	Ý nghĩa bằng lời thường	Đọc thế nào
R^2	Mô hình giải thích được bao nhiêu phần biến động của giá	0 là không hơn đoán trung bình, 1 là hoàn hảo
Sai lệch trung vị	Giá đoán lệch bao nhiêu phần trăm so với giá thật ở sản phẩm "giữa bảng"	Càng thấp càng tốt
MAE	Số tiền lệch trung bình (đồng)	Càng thấp càng tốt; bị kéo lên bởi vài sản phẩm rất đắt
AUC	Khả năng xếp sản phẩm sẽ hết hàng lên trước sản phẩm còn hàng	0,5 là đoán bừa, 1 là hoàn hảo
Precision	Trong số sản phẩm mô hình báo "sẽ hết", bao nhiêu thật sự hết	Cao nghĩa là ít báo động giả

Recall	Trong số sản phẩm thật sự hết, mô hình bắt được bao nhiêu	Cao nghĩa là ít bỏ sót
Silhouette	Một thương hiệu nằm gần nhóm của nó hơn các nhóm khác đến đâu	Từ -1 đến 1; trên 0,25 là tách khá, dưới 0,2 là các nhóm chồng lấn
Davies-Bouldin	Mức chồng lấn giữa các nhóm	Càng thấp càng tốt
ARI	Mức đồng thuận giữa hai cách phân cụm	0 là ngẫu nhiên, 1 là trùng khớp

Nguồn: Tác giả tự tổng hợp.

Mã nguồn và trình tự chạy

Mã nằm ở `source-code/ml/` (kèm `models/` chứa mô hình đã huấn luyện và `figures/` chứa hình), dữ liệu và kết quả nằm riêng ở `dataset/ml/` để không lẫn với phần khác của dự án.

Bảng 6.3. Các tệp mã nguồn và trình tự chạy

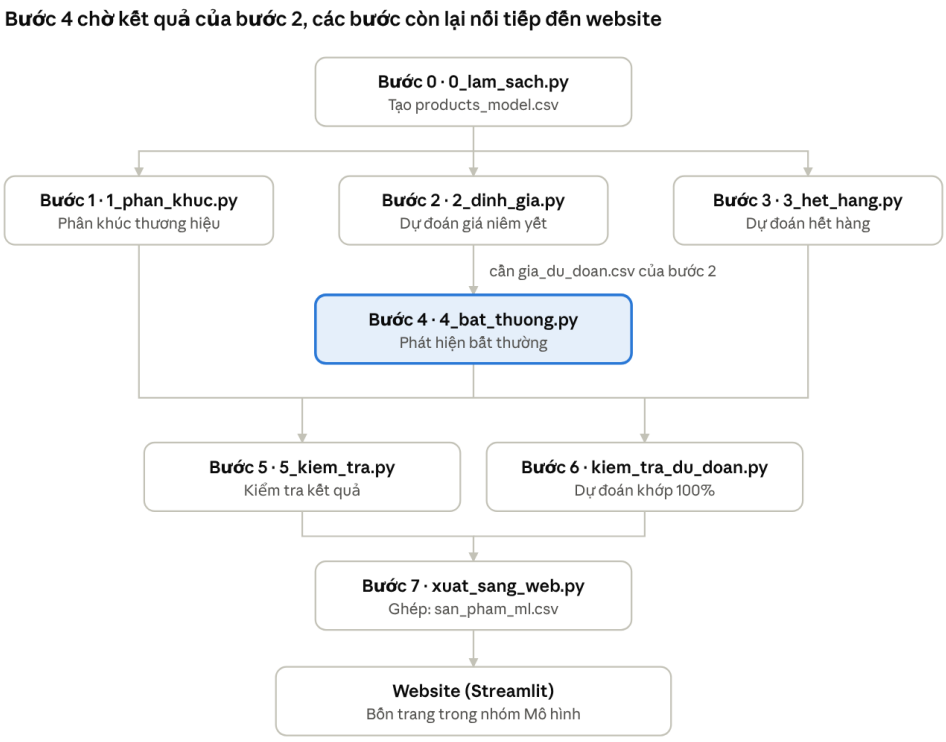
Bước	File	Chức năng	Phần làm việc chính	Kết quả tạo ra
0	0_lam_sach.py	Chuẩn bị dữ liệu cho mô hình	Bỏ 12 dòng trùng tên, đổi lít sang ml, tạo cờ HSD, combo, mini, giá trên 1 ml hoặc 1 g, các cột log	products_model.csv (9.392 dòng)
1	1_phan_khuc.py	Phân khúc thương hiệu	Gộp theo thương hiệu, chuẩn hóa, chọn K, chạy K-Means từng sàn, so với Hierarchical và DBSCAN	phan_cum_thuong_hieu_hasaki.csv, phan_cum_thuong_hieu_cocolux.csv
2	2_dinh_gia.py	Dự đoán giá niêm yết	Huấn luyện 3 mô hình, chọn theo kiểm định chéo, tính phần dư	model_dinh_gia.joblib, gia_du_doan.csv, gia_bat_thuong.csv

3	3_het_hang.py	Dự đoán hết hàng (Hasaki)	Tách hàng cận hạn, huấn luyện, chọn ngưỡng theo recall	model_het_hang.joblib, het_hang_du_doan.csv
4	4_bat_thuong.py	Phát hiện bất thường	IQR, Isolation Forest, LOF; dùng giá dự đoán của bước 2	anomalies.csv, kiem_tra_thu_cong.csv
5	5_kiem_tra.py	Kiểm tra kết quả	Đối chiếu số liệu và quy tắc	Báo cáo kiểm tra trên màn hình
6	kiem_tra_du_doan.py	Kiểm tra hàm dự đoán của website	Dự đoán lại từ dữ liệu thô, phải khớp 100% với lúc huấn luyện	Kết quả khớp 100%
7	xuat_sang_web.py	Ghép kết quả cho website	Gộp mọi kết quả theo url	san_pham_ml.csv
Dùng chung	du_doan.py	Dự đoán sản phẩm mới	Hàm du_doan_gia, du_doan_het_hang cho website	(hàm, không tạo tệp)
Dùng chung	chay_tat_ca.py	Chạy toàn bộ	Chạy bước 0 đến 7 theo thứ tự, ghi nhật ký; khoảng 5 phút	Thư mục logs/

Nguồn: Tác giả tự tổng hợp.

Các tệp `quy_tac.py` (tham số và luật chung) và `dac_trung.py` (tạo đặc trưng, website dùng lại đúng hàm này) hỗ trợ các bước trên.

Sơ đồ trình tự chạy các bước được thể hiện ở Hình 6.1.



Hình 6.1. Sơ đồ trình tự chạy các bước, từ bước 0 đến website

Nguồn: Tác giả tự tổng hợp.

Bước 0 chạy trước; bước 1, 2, 3 không phụ thuộc nhau; bước 4 phải chờ kết quả bước 2; hai bước kiểm tra (5, 6) chạy sau khi có đủ kết quả; bước 7 ghép kết quả cho website.

6.1 Mô hình học không giám sát: phân khúc thương hiệu (K-Means)

Cách đánh giá mô hình

Học không giám sát không có đáp án sẵn; mô hình tự tìm cấu trúc trong dữ liệu, ví dụ gom các thương hiệu giống nhau. Mô hình này học không có đáp án nên được đánh giá bằng độ tách nhóm (silhouette) và đối chiếu thủ công. Mọi phép chia dùng cùng hạt ngẫu nhiên 42 nên chạy lại cho kết quả giống hệt.

K-Means chia 213 thương hiệu Hasaki và 132 thương hiệu Cocolux thành 4 nhóm mỗi sàn; nhóm tách rõ ở Cocolux (silhouette 0,299), còn ở Hasaki chồng lấn nhiều (silhouette 0,179).

Bài toán kinh doanh

Hasaki có 213 thương hiệu và Cocolux có 132, quá nhiều để theo dõi từng cái. Bài toán: gom các thương hiệu có cách bán giống nhau (mức giá, mức giảm, số đánh giá, độ phủ sản phẩm) thành vài nhóm để đặt tên và so sánh. Phân cụm chạy riêng từng sàn vì hai sàn khác nhau rõ về chính sách giảm giá, lượng đánh giá và tình trạng hết hàng.

Dữ liệu dùng

Mỗi dòng là một thương hiệu có từ 5 sản phẩm trở lên, được tổng hợp từ bảng sản phẩm. Hasaki bỏ hàng cận hạn [HSD] vì giảm 95–99% là xả kho; Cocolux dùng toàn bộ. Nhóm đặc trưng gồm:

Bảng 6.4. Các đặc trưng dùng để phân khúc thương hiệu

Đặc trưng	Cách tính cho mỗi thương hiệu	Hasaki	Cocolux
log_so_sp	Logarit số sản phẩm	Có	Có
log_gia	Logarit giá niêm yết trung vị	Có	Có
giam_gia	Mức giảm giá trung bình (%)	Có	Có
het_hang	Tỷ lệ sản phẩm hết hàng	Có	Không (99,97% còn hàng)
log_danh_gia	Logarit số đánh giá trung bình	Có	Có
combo	Tỷ lệ sản phẩm là combo	Có	Có

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Sáu đặc trưng mô tả "cách bán" của một thương hiệu: quy mô (số sản phẩm), mức giá, mức giảm giá, tình trạng hết hàng, độ quen thuộc với khách (số đánh giá) và mức độ dùng combo. Cocolux không dùng đặc trưng hết hàng vì gần như mọi sản phẩm đều còn hàng, đặc trưng này không giúp phân biệt các thương hiệu.

Các đặc trưng được chuẩn hóa về cùng thang đo để không đặc trưng nào lán át nhờ đơn vị lớn.

Thuật toán

K-Means chọn trước K điểm "tâm", gán mỗi thương hiệu vào tâm gần nhất, rồi dịch tâm về giữa nhóm và lặp lại đến khi ổn định. Số nhóm K được chọn bằng cách thử K từ 2 đến 8 và xem ba thước đo: inertia (nhóm càng chặt càng thấp), silhouette và Davies-Bouldin. Để kiểm chứng, kết quả được so với hai thuật toán khác: phân cụm phân cấp (Hierarchical) và DBSCAN (tìm vùng dữ liệu dày, điểm lẻ coi là nhiễu).

Code rút gọn

```
# 1. Gộp theo thương hiệu, chỉ giữ thương hiệu có từ 5 sản phẩm
brand = h.groupby("brand").agg(so_san_pham=("name", "size"),
                               gia_tb=("price_original", "median"),
                               giam_gia_tb=("discount_pct", "mean"))
brand = brand[brand.so_san_pham >= 5]

# 2. Log hóa cột lệch rồi chuẩn hóa về cùng thang đo
X = pd.DataFrame({"log_so_sp": np.log(brand.so_san_pham),
                  "log_gia": np.log(brand.gia_tb),
                  "giam_gia": brand.giam_gia_tb}, index=brand.index)
Xs = StandardScaler().fit_transform(X)

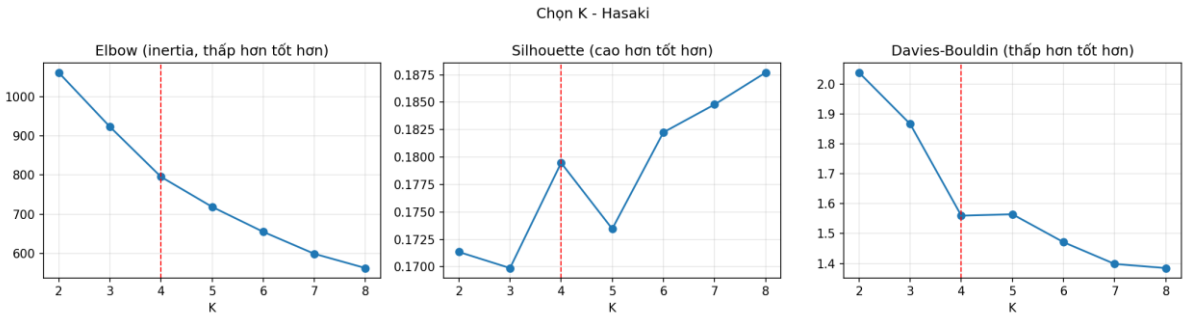
# 3. Thử K = 2..8, chấm bằng silhouette và Davies-Bouldin
for k in range(2, 9):
    km = KMeans(n_clusters=k, n_init=10, random_state=42).fit(Xs)
    print(k, silhouette_score(Xs, km.labels_), davies_bouldin_score(Xs, km.labels_))

# 4. Chạy với K = 4 và gán nhãn cụm cho từng thương hiệu
brand["cum"] = KMeans(n_clusters=4, n_init=10, random_state=42).fit(Xs).labels_
```

Code đầy đủ (6 đặc trưng, vẽ hình, đặt tên cụm tự động) ở `1_phan_khuc.py`.

Kết quả

Chọn K. Ở Cocolux K = 4 cho silhouette cao nhất (0,299) và Davies-Bouldin 1,092. Ở Hasaki silhouette gần như phẳng (0,170 đến 0,188 khi K từ 2 đến 8) nên không có K tối ưu rõ; K = 4 được giữ vì Davies-Bouldin giảm từ 1,867 (K = 3) xuống 1,560 và 4 nhóm dễ đặt tên nhất.

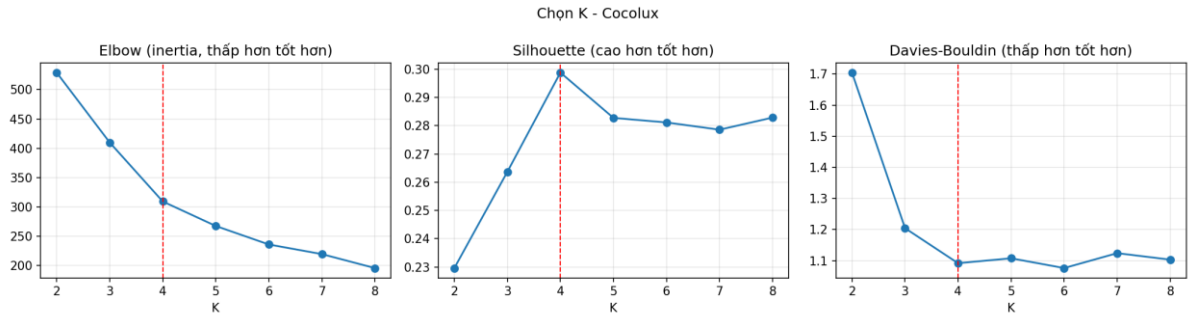


Hình 6.2. Chọn số nhóm K cho Hasaki theo ba thước đo

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Đường inertia (trái) giảm đều, không có "khuỷu tay" rõ. Silhouette (giữa) chỉ dao động trong khoảng 0,170–0,188, gần như phẳng, nghĩa là không có K nào tách nhóm tốt

hẳn. Davies-Bouldin (phải) giảm mạnh từ K = 3 xuống K = 4 rồi chững lại, nên K = 4 (đường đỏ) được chọn như điểm cân bằng giữa chất lượng và khả năng đặt tên nhóm.



Hình 6.3. Chọn số nhóm K cho Cocolux theo ba thước đo

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Khác với Hasaki, ba thước đo của Cocolux cùng chỉ về K = 4: silhouette đạt đỉnh 0,299, Davies-Bouldin xuống mức thấp (1,092) và inertia bắt đầu giảm chậm lại sau K = 4. Đây là căn cứ khá chắc chắn để chọn 4 nhóm.

Hasaki: 213 thương hiệu, 4 nhóm.

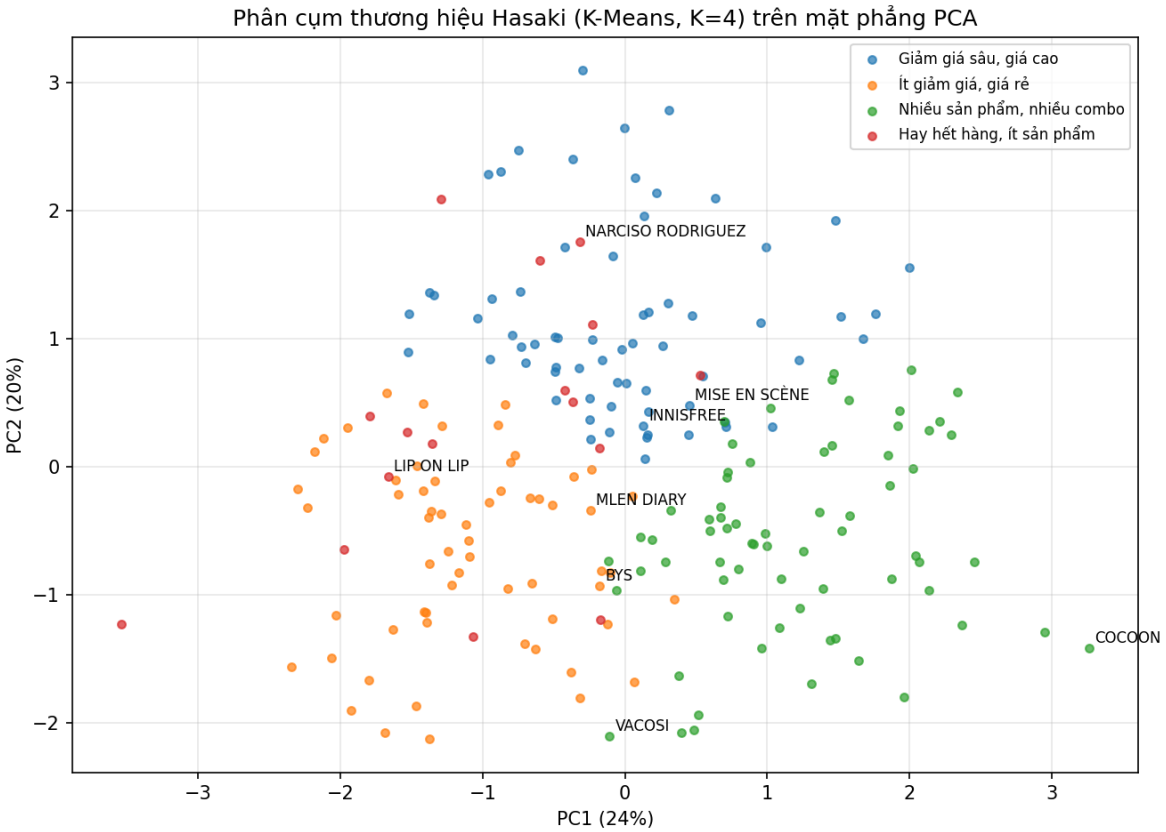
Bảng 6.5. Đặc điểm 4 nhóm thương hiệu Hasaki

Nhóm	Số thương hiệu	Sản phẩm (trung vị)	Giá niêm yết (trung vị, đ)	Giảm giá (trung vị, %)	Thương hiệu tiêu biểu
Nhiều sản phẩm, nhiều combo	69	38	247.000	32,3	COCOON, VACOSI, B.O.M, L'ORÉAL
Giảm giá sâu, giá cao	67	10	390.000	37,4	INNISFREE, MISE EN SCÈNE, NOOKOI, LEMONADE
Ít giảm giá, giá rẻ	61	10	169.000	20,0	MLEN DIARY, BYS, BIORÉ, ROMANO
Hay hết hàng, ít sản phẩm	16	5,5	212.000	28,6	NARCISO RODRIGUEZ, LIP ON LIP, NATURE REPUBLIC, FIXDERMA

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Bốn nhóm khác nhau rõ ở quy mô và chính sách giá: nhóm "Nhiều sản phẩm, nhiều combo" có trung vị 38 sản phẩm, gấp gần 4 lần các nhóm khác; nhóm "Giảm giá sâu, giá cao" có giá niêm yết trung vị cao nhất (390.000 đ) và cũng giảm sâu nhất (37,4%), cho thấy giá niêm yết cao thường đi kèm khuyến mãi lớn; nhóm "Ít giảm giá, giá rẻ" bán giá thấp và ít khuyến mãi; nhóm "Hay hết hàng" nhỏ (16 thương hiệu) nhưng cần chú ý về tồn kho.

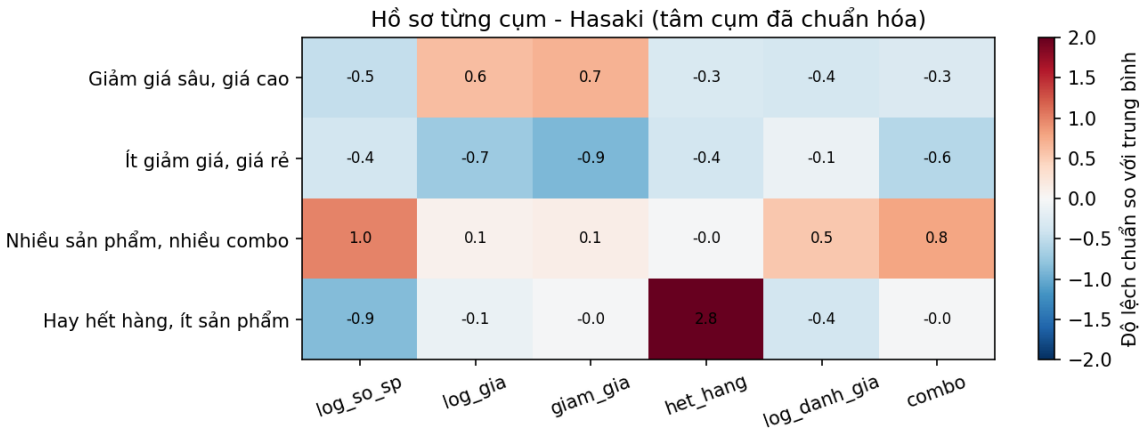
Nhóm "Hay hết hàng" có trung vị 50% sản phẩm hết hàng, trong khi hai nhóm "Giảm giá sâu" và "Ít giảm giá" có trung vị 0% (nhóm nhiều combo là 8%).



Hình 6.4. Phân bố thương hiệu Hasaki theo 4 nhóm trên mặt phẳng PCA

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: PCA nén 6 đặc trưng xuống 2 trục để vẽ được trên mặt phẳng (hai trục giữ khoảng 44% thông tin). Nhóm "Giảm giá sâu, giá cao" (xanh dương) nằm phía trên, nhóm "Nhiều sản phẩm, nhiều combo" (xanh lá) lệch về bên phải, nhóm "Ít giảm giá, giá rẻ" (cam) ở góc dưới bên trái. Các điểm đỏ (hay hết hàng) rải rác khắp nơi và các nhóm chạm vào nhau ở vùng giữa, khớp với silhouette thấp 0,179.



Hình 6.5. Hồ sơ đặc trưng của 4 nhóm thương hiệu Hasaki

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Mỗi ô là giá trị tâm nhóm sau chuẩn hóa: màu đỏ là cao hơn trung bình, màu xanh là thấp hơn trung bình. Nhóm "Hay hết hàng" nổi bật với het_hang = 2,8 độ lệch chuẩn; nhóm "Nhiều sản phẩm, nhiều combo" cao ở log_so_sp (1,0) và combo (0,8); hai nhóm còn lại đối lập nhau ở giá và mức giảm giá. Hình này giải thích vì sao mỗi nhóm được đặt tên như trong Bảng 6.5.

Cocolux: 132 thương hiệu, 4 nhóm.

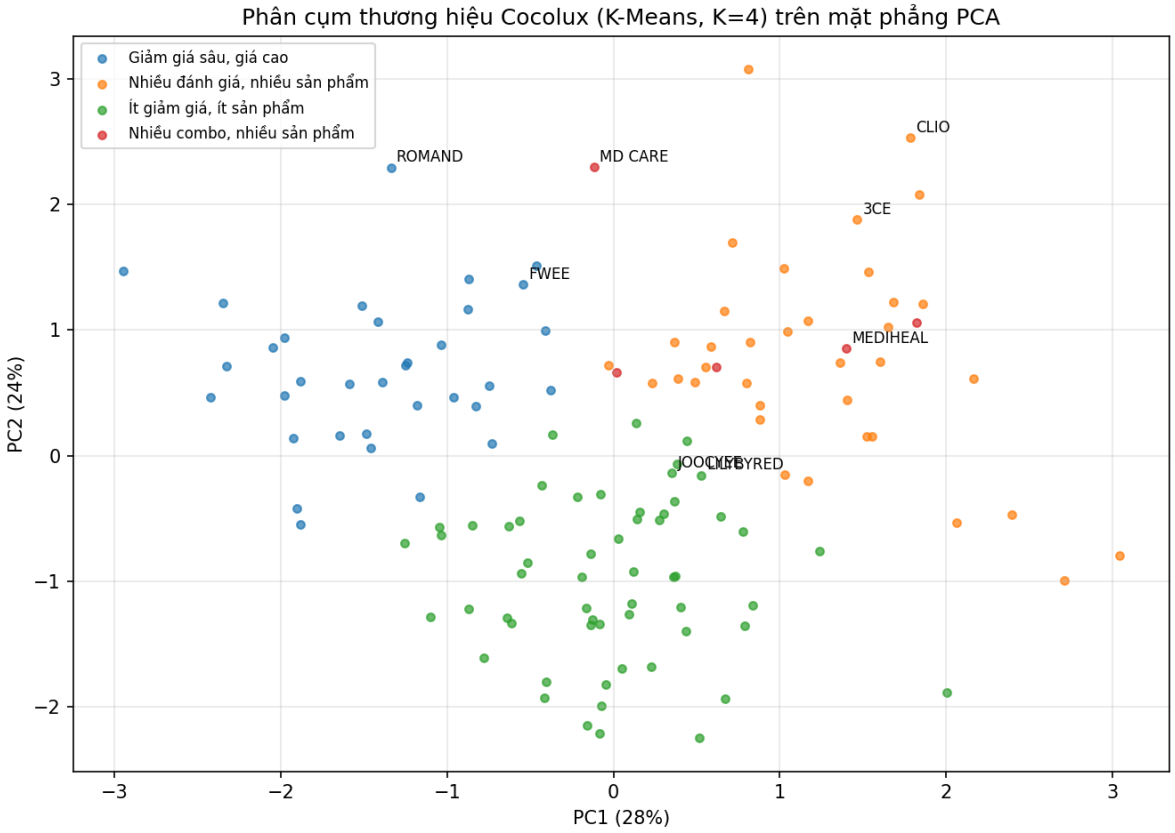
Bảng 6.6. Đặc điểm 4 nhóm thương hiệu Cocolux

Nhóm	Số thương hiệu	Sản phẩm (trung vị)	Giá niêm yết (trung vị, đ)	Giảm giá (trung vị, %)	Đánh giá (trung vị)	Thương hiệu tiêu biểu
Ít giảm giá, ít sản phẩm	57	9	176.000	1,8	0	LILYBYRED, JOOCYEE, LANBENA, FOOD A HOLIC
Nhiều đánh giá, nhiều sản phẩm	36	28,5	269.000	4,7	81,3	3CE, CLIO, MAYBELLINE, COLORKEY
Giảm giá sâu, giá cao	34	10,5	564.000	18,2	0	FWEE, ROMAND, DASIQUE, CARSLAN

Nhiều combo, nhiều sản phẩm	5	21	364.000	6,2	2,1	MEDIHEAL, MD CARE, BIO-ESSENCE, SIMPLE

Nguồn: Tác giả tự tổng hợp.

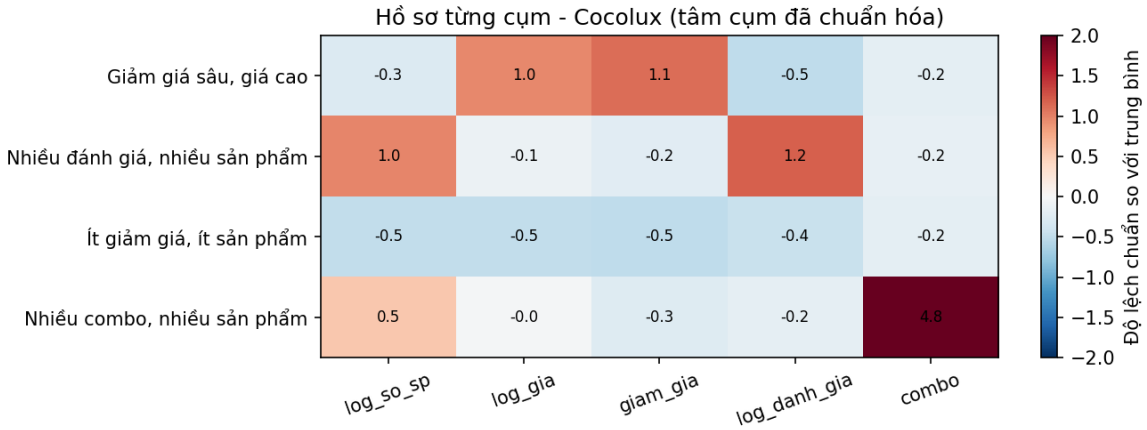
Ý nghĩa: Ở Cocolux, đặc trưng tách nhóm mạnh nhất là số đánh giá và mức giá. Nhóm "Nhiều đánh giá, nhiều sản phẩm" (3CE, CLIO, MAYBELLINE) là các thương hiệu khách đã quen, với trung vị 81 đánh giá; nhóm "Giảm giá sâu, giá cao" có giá trung vị 564.000 đ, cao gấp hơn 3 lần nhóm "Ít giảm giá". Mức giảm giá của Cocolux nhìn chung thấp hơn nhiều so với Hasaki (trung vị cao nhất chỉ 18,2%).



Hình 6.6. Phân bố thương hiệu Cocolux theo 4 nhóm trên mặt phẳng PCA

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Các nhóm Cocolux tách nhau rõ hơn Hasaki: nhóm "Giảm giá sâu, giá cao" (xanh dương) nằm gọn bên trái, nhóm "Nhiều đánh giá" (cam) bên phải, nhóm "Ít giảm giá, ít sản phẩm" (xanh lá) ở phía dưới. Nhóm "Nhiều combo" (đỏ) chỉ có 5 thương hiệu nên nằm xen giữa các nhóm khác.



Hình 6.7. Hồ sơ đặc trưng của 4 nhóm thương hiệu Cocolux

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Nhóm "Nhiều combo" có tỷ lệ combo cao vượt trội (4,8 độ lệch chuẩn), nhóm "Nhiều đánh giá" cao ở số đánh giá (1,2) và số sản phẩm (1,0), nhóm "Giảm giá sâu, giá cao" cao ở giá (1,0) và giảm giá (1,1). Nhóm "Ít giảm giá, ít sản phẩm" thấp hơn trung bình ở mọi đặc trưng, tức là nhóm thương hiệu nhỏ, chưa nổi bật.

Đối chiếu với thuật toán khác.

Bảng 6.7. So sánh K-Means với các thuật toán phân cụm khác

Chỉ số	Hasaki	Cocolux
Silhouette K-Means	0,179	0,299
Silhouette Hierarchical	0,162	0,270
ARI giữa K-Means và Hierarchical	0,415	0,661
Điểm DBSCAN coi là nhiễu	66	16

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Ở cả hai sàn, K-Means cho silhouette cao hơn phân cụm phân cấp, nên được chọn làm thuật toán chính. ARI 0,661 ở Cocolux cho thấy hai thuật toán khác nhau vẫn chia nhóm khá giống nhau, tức các nhóm Cocolux là có thật; ở Hasaki ARI chỉ 0,415 và DBSCAN coi 66 thương hiệu là điểm lẻ, chứng tỏ ranh giới các nhóm Hasaki không rõ.

Ý nghĩa kinh doanh

Mỗi nhóm gợi ý một cách làm việc riêng khi đàm phán với nhãn hàng: nhóm nhiều sản phẩm, nhiều combo là đối tác lớn đủ để lên chương trình combo; nhóm giảm giá sâu, giá cao phụ thuộc khuyến mãi để bán; nhóm hay hết hàng cần rà soát tồn kho. Ở Cocolux, nhóm

"nhiều đánh giá" (trung vị 81 đánh giá) là các thương hiệu khách đã quen, còn nhóm "ít giảm giá, ít sản phẩm" là nhóm đông nhất (57 thương hiệu) nhưng chưa có đánh giá nào.

Mức độ tin cậy và hạn chế

- Cocolux tách nhóm khá rõ (silhouette 0,299, ARI 0,661 với cách phân cấp).

- Hasaki chồng lấn: silhouette 0,179 dưới 0,25 và ARI 0,415 cho thấy nhãn cụm chỉ nên dùng để mô tả, không phải ranh giới cứng; 66 thương hiệu bị DBSCAN coi là lẻ.

- Ranh giới giữa hai sàn không so trực tiếp được vì Hasaki có thêm đặc trưng hết hàng.

- Tên nhóm được đặt tự động từ hai đặc điểm nổi bật nhất của tâm cụm, chỉ là gợi ý cần người đọc lại.

6.2 Mô hình học có giám sát

Cách đánh giá mô hình

Học có giám sát là học từ dữ liệu đã có đáp án (giá thật, còn hay hết hàng) để đoán đáp án cho sản phẩm mới. Với hai mô hình có giám sát, nhóm áp dụng bốn nguyên tắc để kết quả đáng tin:

- Chia 80% học, 20% kiểm tra. Mô hình chỉ học trên 80%; 20% còn lại chưa từng thấy, dùng để chấm điểm cuối.

- Kiểm định chéo 5 phần. Phần 80% được chia thành 5 phần, lần lượt giữ 1 phần làm bài kiểm tra và học trên 4 phần còn lại, rồi lấy trung bình 5 lần.

- So với mô hình mốc đơn giản. Hồi quy Ridge (giá) và hồi quy Logistic (hết hàng) là mốc; mô hình phức tạp chỉ đáng dùng khi hơn mốc rõ rệt.

- Chọn mô hình theo điểm kiểm định chéo, không theo điểm trên tập kiểm tra, để tập kiểm tra không bị "nhìn trộm".

Hai mô hình dự đoán dùng cùng thuật toán Random Forest: Random Forest gồm 300 cây quyết định, mỗi cây hỏi liên tiếp các câu hỏi có hay không ("thương hiệu này có giá trung bình cao không? dung tích trên 100 ml không?") rồi đưa ra một đáp án; kết quả cuối là trung bình (với giá) hoặc bỏ phiếu (với hết hàng) của 300 cây. Nhiều cây cùng đoán cho kết quả ổn định hơn một cây duy nhất.

6.2.1 Dự đoán giá niêm yết

Random Forest đoán giá niêm yết với sai lệch trung vị 14,6% và $R^2 = 0,863$ trên tập kiểm tra, tốt hơn rõ mô hình mốc Ridge (23,8%; $R^2 = 0,771$).

Bài toán kinh doanh

Một sản phẩm với thương hiệu, loại hàng và dung tích nhất định thì "nên" niêm yết bao nhiêu? Mô hình cho giá tham chiếu để kiểm tra giá sản phẩm mới và là nền để phát hiện giá lạ ở mục 6.3.

Dữ liệu dùng

8.152 sản phẩm không phải hàng cận hạn (6.521 để học, 1.631 để kiểm tra). Biến cần đoán là logarit giá niêm yết `price_original`, vì giá lệch rất mạnh giữa sản phẩm rẻ và đắt. Đặc trưng đầu vào:

Thương hiệu: mã hóa thành giá log trung bình của thương hiệu (`brand_te`, có co về trung bình chung và tính chéo để không "nhìn trộm" đáp án), và cờ 150 thương hiệu lớn nhất (`brand_top`).

Loại sản phẩm (`loai_sp`, 21 loại như serum, son, kem, nước hoa) suy ra từ tên sản phẩm bằng từ khóa.

Dung tích (`log_vol`) và số lượng trong gói (`log_sl`), cờ combo, cờ mini, đơn vị, nhóm ngành, danh mục, xuất xứ và sàn bán.

Thuật toán

Ba mô hình được đặt cạnh nhau: Ridge (công thức cộng đơn giản, làm mốc), Gradient Boosting (nhiều cây nhỏ nối tiếp, cây sau sửa lỗi cây trước) và Random Forest (300 cây học song song). Mô hình được chọn theo R^2 kiểm định chéo 5 phần.

Code rút gọn

```
        y = np.log(df.price_original)                          # đoán log giá, không đoán giá
trực tiếp
        X_train,   X_test,   y_train,   y_test   =   train_test_split(X,   y,   test_size=0.2,
random_state=42)


        prep = ColumnTransformer([
            ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols),   # cột chữ -> cột 0/1
            ("num", StandardScaler(), num_cols),               # cột số -> cùng thang đo
            ("te",  TargetEncoder(cv=kf), ["brand_te"]),       # thương hiệu -> giá log trung
bình
        ])
        models = {"Ridge": Ridge(alpha=1.0),
                  "GradientBoosting": HistGradientBoostingRegressor(random_state=42),
                  "RandomForest":  RandomForestRegressor(n_estimators=300,  min_samples_leaf=2,
random_state=42)}


        for ten, m in models.items():
            pipe = Pipeline([("prep", prep), ("model", m)])
            cv_r2 = cross_val_score(pipe, X_train, y_train, scoring="r2", cv=kf).mean()
                                                               # kiểm định chéo 5 phần
            pipe.fit(X_train, y_train)
            pred = np.exp(pipe.predict(X_test))                # đổi log về đồng
            sai_lech = np.median(np.abs(pred / np.exp(y_test) - 1)) * 100
```

```
        best = max(ket_qua, key=lambda k: ket_qua[k]["cv_r2"])  # chọn theo CV, không theo tập
test
```

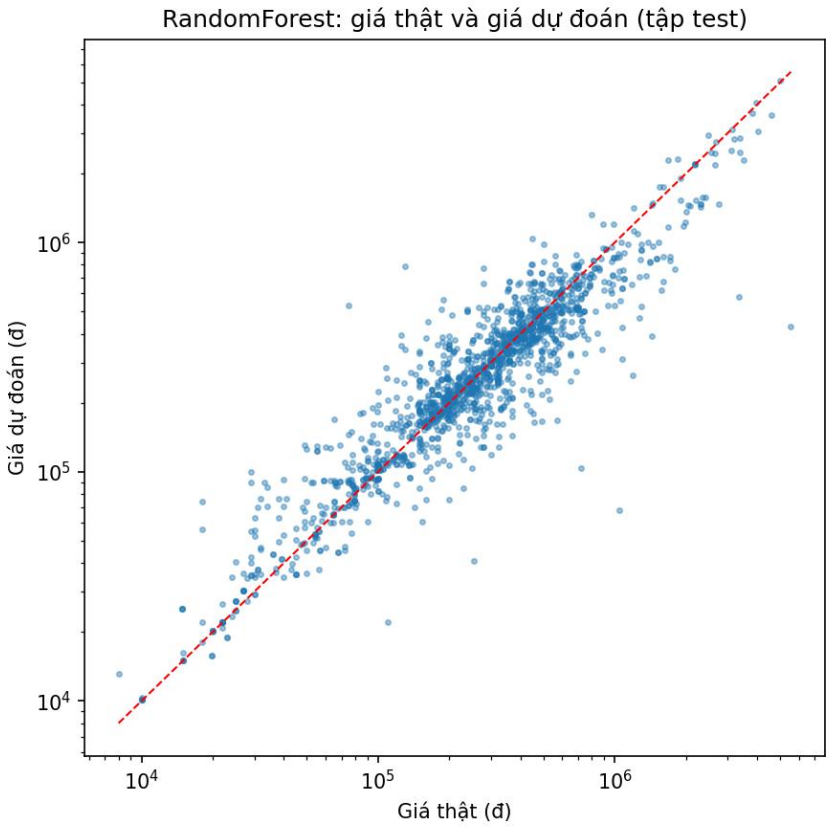
Bảng 6.8. Kết quả ba mô hình dự đoán giá niêm yết

Mô hình	R^2 kiểm định chéo	R^2 tập học	R^2 tập kiểm tra	MAE (đ)	Sai lệch trung vị (%)
Ridge (mốc)	0,765	0,803	0,771	119.087	23,8
Gradient Boosting	0,829	0,886	0,842	100.258	19,7
Random Forest (chọn)	0,839	0,921	0,863	90.849	14,6

Nguồn: Tác giả tự tổng hợp.

Qua bảng kết quả cho thấy Random Forest tốt nhất ở mọi chỉ số trên tập kiểm tra và cả điểm kiểm định chéo. So với mốc Ridge, sai lệch trung vị giảm từ 23,8% xuống 14,6% và MAE giảm gần 28.000 đ. Chênh lệch giữa R^2 tập học (0,921) và tập kiểm tra (0,863) cho thấy mô hình có học thuộc nhẹ nhưng vẫn ở mức chấp nhận được.

Random Forest thắng ở cả bốn chỉ số, giảm sai lệch trung vị từ 23,8% xuống 14,6% so với mốc. R^2 tập học (0,921) cao hơn tập kiểm tra (0,863) khoảng 0,06 nên mô hình có học thuộc ở mức vừa phải, nhưng R^2 kiểm định chéo và R^2 tập kiểm tra gần nhau (0,839 và 0,863) cho thấy kết quả không phải do may mắn.

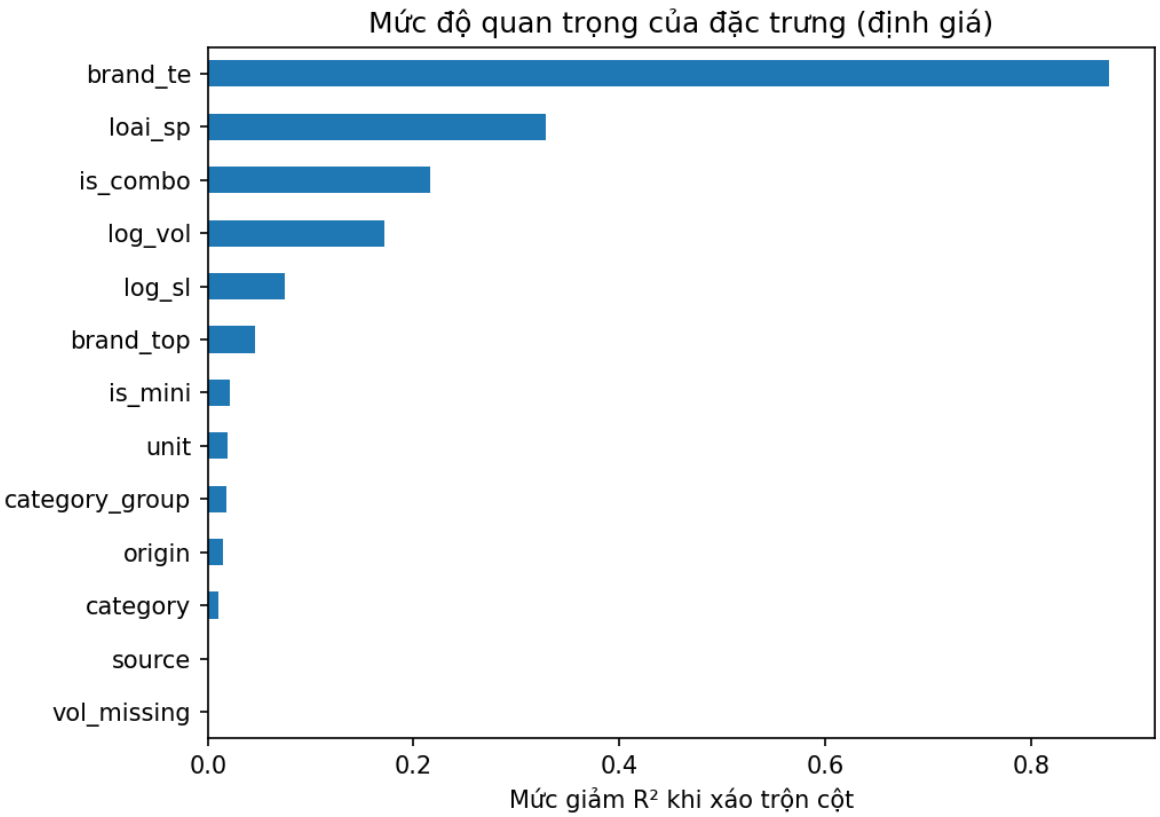


Hình 6.8. Giá thật và giá dự đoán của Random Forest trên tập kiểm tra

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Mỗi điểm là một sản phẩm; hai trục dùng thang logarit. Điểm càng gần đường chéo đỏ thì dự đoán càng sát giá thật. Đa số điểm bám quanh đường chéo trên dải giá từ 10.000 đ đến vài triệu đồng; một số ít điểm nằm xa phía dưới bên phải là sản phẩm đắt bị đoán thấp, đây cũng là nguồn ứng viên cho danh sách bất thường ở mục 6.3.

Mức quan trọng của đặc trưng (mức giảm R^2 khi xáo trộn cột): thương hiệu dẫn đầu rõ (0,876), sau đó loại sản phẩm (0,329), cờ combo (0,216), dung tích (0,172) và số lượng trong gói (0,074); sàn bán gần như không đóng góp (0,0006).

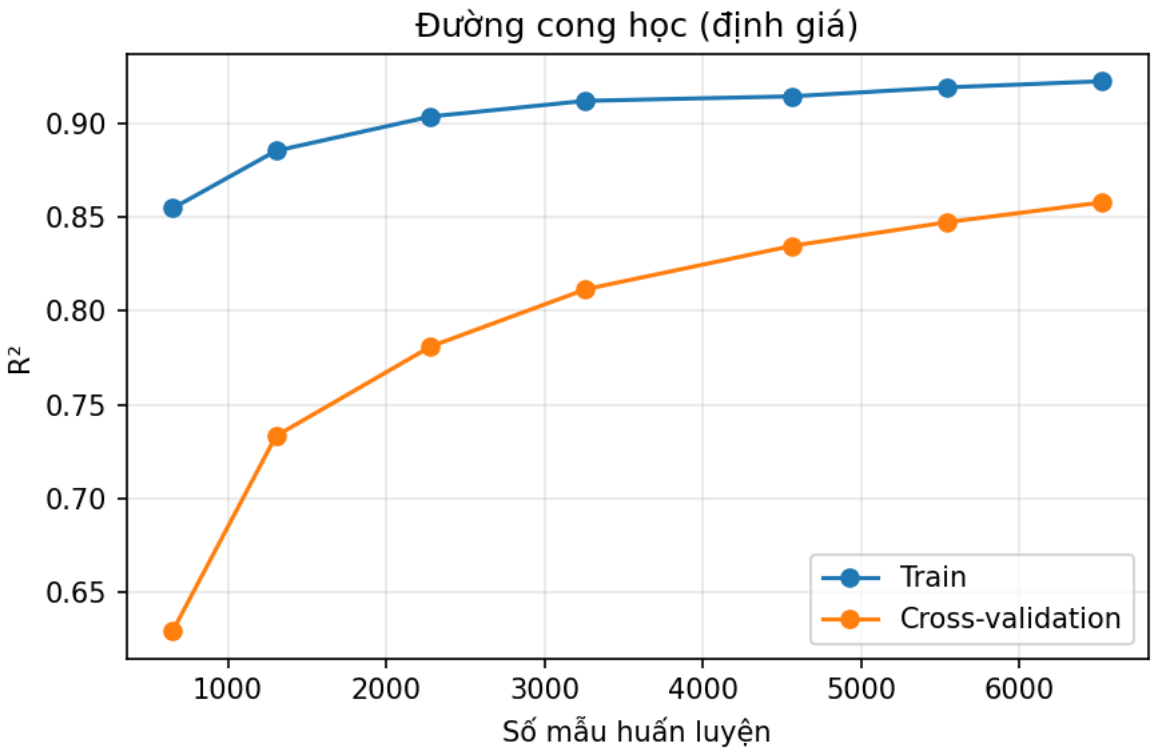


Hình 6.9. Mức quan trọng của các đặc trưng trong mô hình dự đoán giá

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Độ dài thanh là mức R^2 giảm đi khi xáo trộn ngẫu nhiên cột đó. Thương hiệu (brand_te) có ảnh hưởng vượt trội (0,876), tiếp theo là loại sản phẩm, cờ combo và dung tích. Sàn bán (source) gần như bằng 0, nghĩa là cùng một sản phẩm thì giá niêm yết ở Hasaki và Cocolux không khác nhau đáng kể.

Đường cong học. R^2 kiểm định chéo tăng từ 0,629 (652 mẫu) lên 0,858 (6.521 mẫu) và vẫn đang nhích lên, nên thêm dữ liệu sẽ cải thiện thêm.

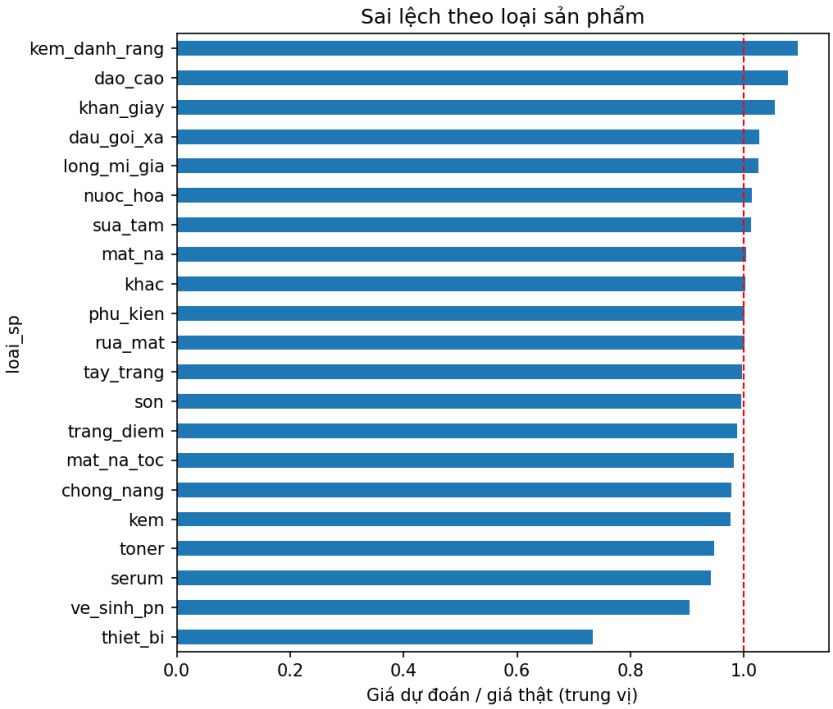


Hình 6.10. Đường cong học của mô hình dự đoán giá

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Đường xanh là R^2 trên dữ liệu đã học, đường cam là R^2 kiểm định chéo. Khoảng cách giữa hai đường thu hẹp dần khi số mẫu tăng (từ khoảng 0,23 xuống 0,06), và đường cam vẫn còn đi lên ở 6.521 mẫu. Điều này cho thấy mô hình chưa bão hòa: thu thập thêm dữ liệu sẽ còn cải thiện độ chính xác.

Sai lệch theo loại sản phẩm (giá dự đoán chia giá thật, trung vị; 1 là đúng): mô hình đoán thấp nhất ở thiết bị (0,73), vệ sinh phụ nữ (0,90), serum (0,94) và toner (0,95); đoán cao nhất ở kem đánh răng (1,09) và dao cạo (1,08). Hầu hết loại còn lại nằm trong khoảng 0,97 đến 1,05.



Hình 6.11. Tỷ lệ giá dự đoán so với giá thật theo loại sản phẩm

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Đường đỏ ở mức 1,0 là dự đoán đúng; thanh dài hơn đường đỏ là đoán cao, ngắn hơn là đoán thấp. Phần lớn loại sản phẩm nằm sát mức 1,0; riêng thiết bị (0,73) bị đoán thấp rõ rệt, có thể do giá thiết bị phụ thuộc vào tính năng kỹ thuật mà dữ liệu không có. Vì vậy cần thận trọng khi dùng giá dự đoán cho nhóm thiết bị, serum và toner.

Ý nghĩa kinh doanh

Có một mức giá tham chiếu cho 21 loại hàng mà không cần người so sánh thủ công; website dùng mô hình này để gợi ý giá khi thêm sản phẩm mới. Vì thương hiệu giải thích phần lớn giá, thương hiệu là yếu tố định giá chính trong dữ liệu.

Mức độ tin cậy và hạn chế

- Sai lệch trung vị 14,6% nghĩa là một nửa sản phẩm lệch hơn 14,6%; với sản phẩm rất đắt hoặc lạ, sai số còn lớn hơn nhiều (MAE 90.849 đ).

- Mô hình đoán thấp thiết bị và serum, nên không dùng giá dự đoán cho các nhóm này một cách máy móc.

- Hàng cận hạn [HSD] không đưa vào vì giá niêm yết của chúng không phản ánh thị trường.

6.2.2 Dự đoán hết hàng

Random Forest xếp hạng sản phẩm Hasaki theo nguy cơ hết hàng với AUC kiểm định chéo 0,813 và bắt được 72,4% sản phẩm thật sự hết trong tập kiểm tra, nhưng cảnh báo còn nhiều báo động giả.

Bài toán kinh doanh

Sản phẩm nào của Hasaki có nguy cơ hết hàng để bộ phận tồn kho ưu tiên kiểm tra? Chỉ dự đoán cho Hasaki vì Cocolux gần như không có hàng hết (99,97% sản phẩm còn hàng), không đủ mẫu để học.

Dữ liệu dùng

Có 6.477 sản phẩm Hasaki, gồm 1.214 hàng cận hạn [HSD] và 5.263 hàng thường. Hàng cận hạn được xử lý bằng quy tắc riêng: 90,5% trong số đó đã hết hàng (hàng xả kho), nên sản phẩm [HSD] luôn được báo có nguy cơ cao. Nếu gộp cả hai loại, AUC kiểm định chéo lên 0,917 nhưng là con số "ảo" vì mô hình chỉ cần nhìn chữ [HSD]. Vì vậy mô hình chỉ học trên 5.263 hàng thường (4.210 để học, 1.053 để kiểm tra; 12,1% kiểm tra là hết hàng).

Đặc trưng đầu vào: thương hiệu (`brand_te`, `brand_top`), mức giảm giá, số đánh giá, giá niêm yết, dung tích, nhóm ngành, đơn vị, xuất xứ, cờ combo và mini.

Thuật toán

Cấu trúc giống mục 6.2.1 nhưng là bài toán phân loại: mỗi trong 300 cây bỏ phiếu "còn" hoặc "hết", tỷ lệ phiếu "hết" là xác suất hết hàng. Vì chỉ 12% sản phẩm hết hàng, mô hình được tăng trọng số cho lớp hiếm (`class_weight="balanced"`). So sánh với mốc Logistic và Gradient Boosting, chọn theo AUC kiểm định chéo.

Mô hình đưa ra xác suất, cần một ngưỡng để báo "sẽ hết". Ngưỡng 0,5 bỏ sót quá nhiều vì hiếm, nên nhóm chọn ngưỡng cao nhất mà recall trên dự đoán kiểm định chéo của tập học vẫn từ 0,8 trở lên. Kết quả là 0,376, và ngưỡng này chọn mà không nhìn tập kiểm tra.

Code rút gọn

```
        h = df[df.source == "hasaki"]
        h["het_hang"] = 1 - h["in_stock"]                       # 1 = hết hàng
        hsd = h[h.is_hsd == 1]            # hàng cận hạn: xử lý bằng quy tắc, không cho mô hình
học
        h = h[h.is_hsd == 0]
        X_train, X_test, y_train, y_test = train_test_split(X, h.het_hang, test_size=0.2,
                                                            stratify=h.het_hang,
random_state=42)


        rf = RandomForestClassifier(n_estimators=300, min_samples_leaf=3,
                                    class_weight="balanced", random_state=42)
                                                             # tăng trọng số lớp hiếm
```

```
        pipe = Pipeline([("prep", prep), ("model", rf)])
        cv_auc = cross_val_score(pipe, X_train, y_train, scoring="roc_auc", cv=skf).mean()
        pipe.fit(X_train, y_train)


        # Ngưỡng: cao nhất mà recall (dự đoán chéo trên tập học) vẫn >= 0,8
        proba_cv = cross_val_predict(pipe, X_train, y_train, cv=skf, method="predict_proba")[:,
1]
        pr, rc, th = precision_recall_curve(y_train, proba_cv)
        nguong = th[rc[:-1] >= 0.8].max()                       # = 0,376
        du_doan = pipe.predict_proba(X_test)[:, 1] >= nguong
```

Bảng 6.9. Kết quả ba mô hình dự đoán hết hàng

Mô hình	AUC kiểm định chéo	AUC tập kiểm tra
Logistic (mốc)	0,786	0,781
Gradient Boosting	0,808	0,817
Random Forest (chọn)	0,813	0,821

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Random Forest có AUC cao nhất ở cả kiểm định chéo và tập kiểm tra, nhưng chỉ hơn mốc Logistic khoảng 0,03. Khoảng cách nhỏ này cho thấy giới hạn nằm ở dữ liệu (thiếu thông tin tồn kho và doanh số) hơn là ở thuật toán.

Random Forest nhỉnh hơn mốc Logistic 0,027 điểm AUC; khoảng cách không lớn như mô hình giá, có thể vì hết hàng phụ thuộc vào yếu tố không có trong dữ liệu (tồn kho thật, doanh số bán).

Tại ngưỡng 0,376 trên tập kiểm tra (1.053 sản phẩm):

Bảng 6.10. Ma trận nhầm lẫn của mô hình hết hàng tại ngưỡng 0,376 (tập kiểm tra)

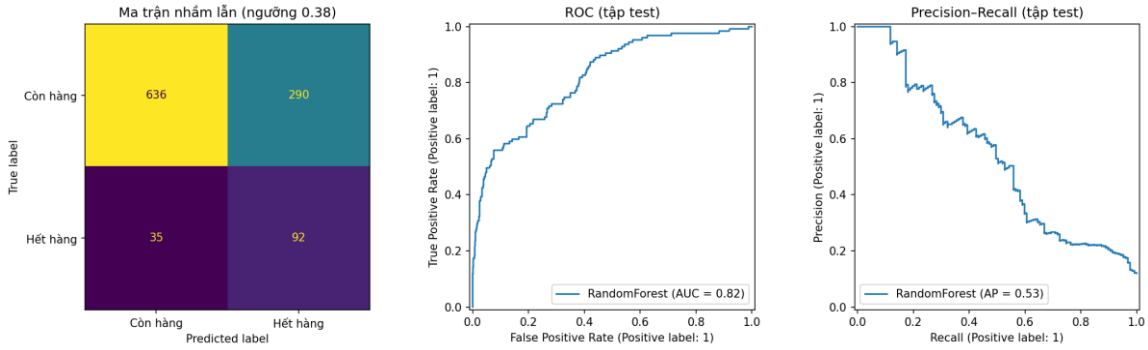
	Dự đoán còn hàng	Dự đoán hết hàng
Thực tế còn hàng	636	290
Thực tế hết hàng	35	92

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Đường chéo (636 và 92) là các dự đoán đúng. Ô 290 là báo động giả (còn hàng nhưng bị báo sẽ hết), ô 35 là bỏ sót (hết hàng nhưng không được báo). Vì ngưỡng được

chọn để ưu tiên recall, số bỏ sót thấp nhưng số báo động giả cao: cứ khoảng 4 cảnh báo mới có 1 cảnh báo đúng.

Precision = 0,241, recall = 0,724, F1 = 0,361. Mô hình bắt được 92 trong 127 sản phẩm thật sự hết, với giá phải trả là 290 cảnh báo nhầm. Nếu đoán ngẫu nhiên, precision chỉ bằng tỷ lệ hết hàng, khoảng 0,12, nên 0,241 gấp khoảng hai lần mốc ngẫu nhiên.

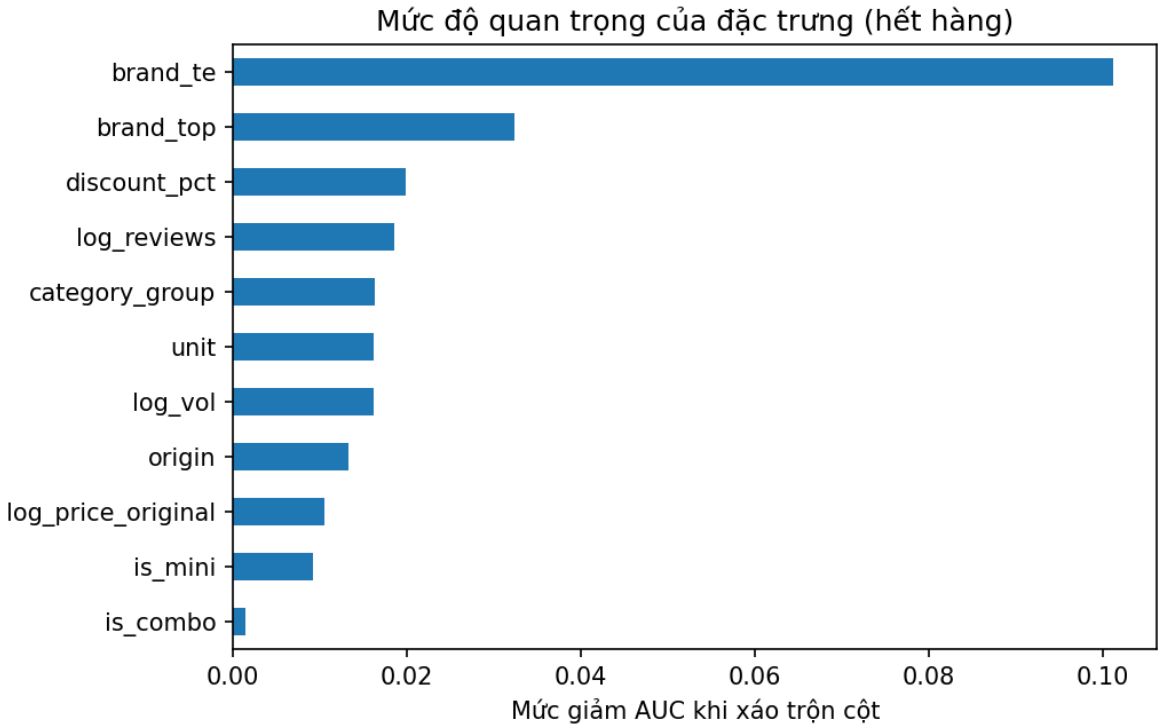


Hình 6.12. Ma trận nhầm lẫn, đường ROC và đường Precision-Recall của mô hình hết hàng

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Ma trận nhầm lẫn (trái) là hình ảnh của Bảng 6.10. Đường ROC (giữa) cong lên phía góc trên bên trái với AUC 0,82, tốt hơn rõ so với đường chéo của đoán ngẫu nhiên. Đường Precision-Recall (phải) cho thấy sự đánh đổi: muốn bắt được nhiều sản phẩm hết hàng hơn (recall cao) thì precision giảm, ở recall khoảng 0,7–0,8 precision chỉ còn khoảng 0,2–0,25.

Mức quan trọng của đặc trưng (mức giảm AUC khi xáo trộn cột): thương hiệu dẫn đầu (0,101), các đặc trưng còn lại đều dưới 0,035 (thương hiệu lớn, mức giảm giá, số đánh giá).



Hình 6.13. Mức quan trọng của các đặc trưng trong mô hình dự đoán hết hàng

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Thương hiệu tiếp tục là đặc trưng quan trọng nhất (AUC giảm 0,101 khi xáo trộn), tức là tình trạng hết hàng phụ thuộc nhiều vào việc nhập hàng của từng thương hiệu. Các đặc trưng khác đều dưới 0,035 và có mức đóng góp tương đương nhau, không có yếu tố đơn lẻ nào ngoài thương hiệu quyết định khả năng hết hàng.

Ý nghĩa kinh doanh

Danh sách sản phẩm có nguy cơ giúp ưu tiên kiểm tra tồn kho thay vì rà toàn bộ 5.263 sản phẩm; đánh đổi đã chọn là ưu tiên không bỏ sót (recall) hơn là ít báo nhầm.

Mức độ tin cậy và hạn chế

- Recall trên tập kiểm tra (0,724) thấp hơn mục tiêu 0,8 đã đặt khi chọn ngưỡng, điều thường gặp khi ngưỡng chọn trên dữ liệu học.

- Precision 0,241 nghĩa là chỉ khoảng 1 trong 4 cảnh báo đúng; kết quả nên xem là danh sách cần rà soát, không phải kết luận.

- Chỉ phủ Hasaki. Dữ liệu là ảnh chụp một thời điểm, nên mô hình không biết xu hướng tồn kho theo thời gian.

6.3 Mô hình thứ ba: phát hiện bất thường (IQR + Isolation Forest + LOF)

Trên 5.172 sản phẩm, ba phương pháp cùng gắn cờ 12 sản phẩm và ít nhất hai phương pháp đồng ý ở 68 sản phẩm, đây là danh sách "bất thường chắc chắn" cần người kiểm tra.

Bài toán kinh doanh

Tìm các sản phẩm có giá hoặc mức giảm bất thường để phân biệt hai trường hợp: lỗi dữ liệu (gõ sai giá, đơn vị sai) và giá lạ nhưng có thật (khuyến mãi sốc). Không có nhãn đúng/sai cho việc này nên dùng học không giám sát.

Dữ liệu dùng

5.172 sản phẩm không phải hàng cận hạn (3.479 Hasaki, 1.693 Cocolux) và có giá trên mỗi ml hoặc g. Hàng cận hạn bị loại vì giảm 95–99% là xả kho thật, không phải bất thường. Bốn đặc trưng đưa vào mô hình:

Bảng 6.11. Các đặc trưng dùng để phát hiện bất thường

Đặc trưng	Ý nghĩa
log_ppu	Logarit giá trên 1 ml hoặc 1 g
discount_pct	Mức giảm giá (%)
log_reviews	Logarit số đánh giá
lech	Phần dư của mô hình giá (mục 6.2.1): log(giá thật / giá dự đoán)

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Bốn đặc trưng nhìn sản phẩm từ bốn góc: đắt hay rẻ trên mỗi đơn vị dung tích, giảm giá nhiều hay ít, được quan tâm nhiều hay ít, và giá có lệch so với mức mô hình dự đoán hay không. Đặc trưng "lech" lấy từ mô hình giá nên bước phát hiện bất thường phải chạy sau bước dự đoán giá.

Chính vì có cột `lech`, bước 4 phải chạy sau bước 2.

Thuật toán

Ba phương pháp nhìn dữ liệu theo ba cách khác nhau:

- IQR: so giá trên mỗi ml với các sản phẩm cùng nhóm ngành và đơn vị, và so mức giảm với cùng sàn; gắn cờ nếu nằm ngoài khoảng giữa cộng trừ 1,5 lần độ rộng của nửa giữa dữ liệu.

- Isolation Forest: xây nhiều cây chia dữ liệu ngẫu nhiên; điểm lạ thường bị cô lập chỉ sau vài lần chia nên điểm bất thường cao.

- LOF: so mật độ xung quanh mỗi sản phẩm với mật độ của 20 sản phẩm gần nhất; lạ khi nằm trong vùng thưa hơn hẳn hàng xóm.

Hai mô hình sau dùng tỷ lệ bất thường kỳ vọng 2%. Sản phẩm được gắn cờ bởi ít nhất hai phương pháp là "bất thường chắc chắn".

Code rút gọn

```
        # 1. IQR theo nhóm ngành và đơn vị
        def iqr_flag(s):
            q1, q3 = s.quantile([0.25, 0.75]); k = 1.5 * (q3 - q1)
            return (s < q1 - k) | (s > q3 + k)
        d["iqr_gia"] = d.groupby(["category_group", "unit"])["log_ppu"].transform(iqr_flag)
        d["iqr_giam"] = d.groupby("source")["discount_pct"].transform(iqr_flag)
        d["iqr"] = d.iqr_gia | d.iqr_giam


        # 2. Isolation Forest và 3. LOF trên 4 đặc trưng đã chuẩn hóa
        Xs  =  StandardScaler().fit_transform(d[["log_ppu",  "discount_pct",  "log_reviews",
"lech"]])
        d["iso"]        =        IsolationForest(n_estimators=300,        contamination=0.02,
random_state=42).fit_predict(Xs) == -1
        d["lof"] = LocalOutlierFactor(n_neighbors=20, contamination=0.02).fit_predict(Xs) == -
1

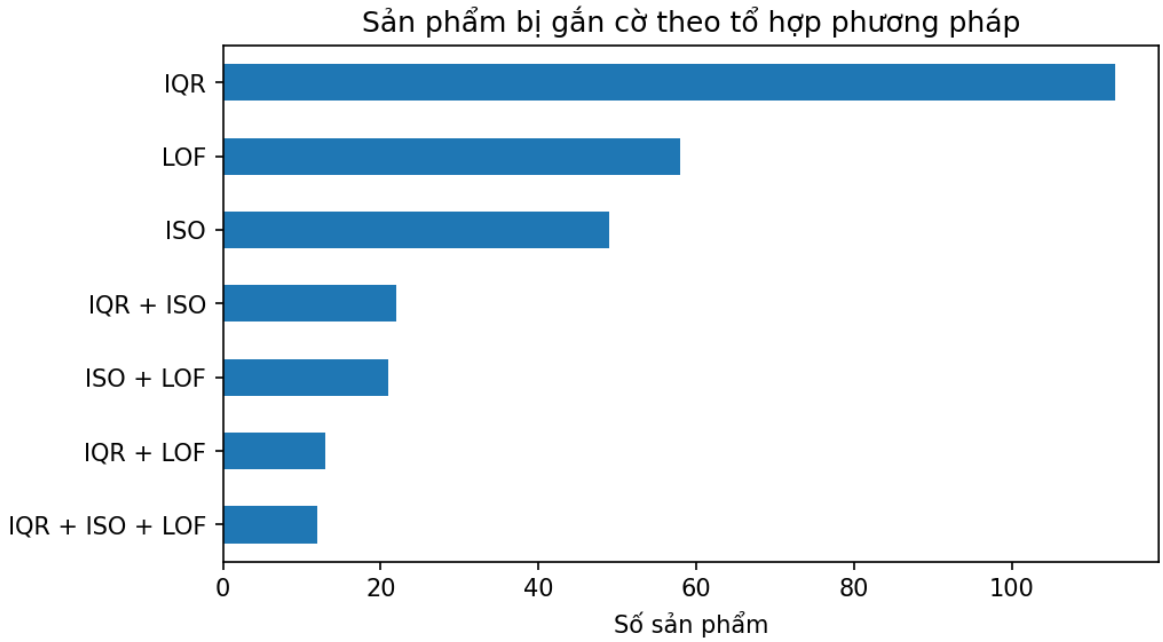

        # 4. Bất thường chắc chắn: ít nhất 2 phương pháp cùng gắn cờ
        d["so_phuong_phap"] = d[["iqr", "iso", "lof"]].sum(axis=1)
        chac_chan = d[d.so_phuong_phap >= 2]
```

Bảng 6.12. Số sản phẩm bị gắn cờ theo từng phương pháp

Phương pháp	Số sản phẩm bị gắn cờ
IQR (giá hoặc mức giảm)	160
Isolation Forest	104
LOF	104
Từ 2 phương pháp trở lên	68 (48 Hasaki, 20 Cocolux)
Cả 3 phương pháp	12

Nguồn: Tác giả tự tổng hợp.

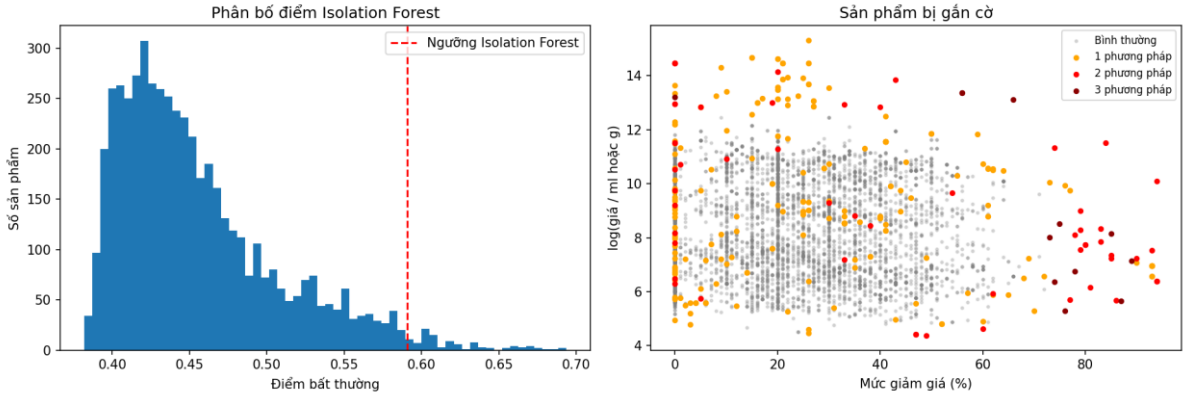
Ý nghĩa: IQR gắn cờ nhiều nhất (160) vì xét riêng từng đặc trưng; Isolation Forest và LOF cùng gắn cờ đúng 104 sản phẩm do cùng đặt tỷ lệ kỳ vọng 2%. Khi yêu cầu ít nhất hai phương pháp đồng ý, danh sách thu hẹp còn 68 sản phẩm, và chỉ 12 sản phẩm bị cả ba phương pháp gắn cờ; đây là nhóm nên kiểm tra trước.



Hình 6.14. Số sản phẩm bị gắn cờ theo tổ hợp phương pháp

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Mỗi thanh đếm số sản phẩm bị gắn cờ bởi đúng tổ hợp phương pháp đó. Phần lớn cờ chỉ đến từ một phương pháp (IQR khoảng 113, LOF khoảng 58, Isolation Forest khoảng 49), nghĩa là các phương pháp thường không đồng ý với nhau. Cộng các tổ hợp từ hai phương pháp trở lên (22 + 21 + 13 + 12) ra đúng 68 sản phẩm bất thường chắc chắn.



Hình 6.15. Phân bố điểm Isolation Forest và vị trí các sản phẩm bị gắn cờ

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Biểu đồ trái: phần lớn sản phẩm có điểm bất thường 0,40–0,50; chỉ phần đuôi bên phải đường ngưỡng đỏ (khoảng 0,59) bị gắn cờ. Biểu đồ phải: các sản phẩm bị nhiều phương pháp gắn cờ (đỏ, đỏ sẫm) tập trung ở vùng giảm giá trên 70% hoặc ở rìa trên, rìa dưới của giá trên mỗi ml/g, đúng là những vùng có giá hoặc mức giảm khác thường so với số đông.

Ngoài ba phương pháp trên, **mô hình giá (mục 6.2.1)** cho thêm một cách bắt bất thường riêng: sản phẩm có giá niêm yết lệch quá 3 độ lệch chuẩn so với giá dự đoán. Có 154 sản phẩm như vậy trên 8.152 sản phẩm (94 Hasaki, 60 Cocolux): 80 sản phẩm đắt hơn dự đoán và 74 sản phẩm rẻ hơn.

Năm sản phẩm có điểm Isolation Forest cao nhất, đều nằm trong danh sách bất thường chắc chắn:

Bảng 6.13. Năm sản phẩm có điểm Isolation Forest cao nhất

Sản phẩm	Giá bán (đ)	Giá niêm yết (đ)	Giá dự đoán (đ)	Giảm (%)	Số phương pháp
Xịt Thơm Toàn Thân Bodymiss Hương Hide & Seek 35ml	10.000	79.000	329.634	87	3
Mặt Nạ Nature Republic Chiết Xuất Hoa Hồng Cấp Ẩm Da 23ml	29.000	255.000	28.319	89	3
[Mini] Mặt Nạ Đất Sét Colorkey Bùn Khoáng Sạch Mịn Màng 10g	35.000	229.000	17.019	85	3
Mặt Nạ Garnier Tinh Chất Sữa Tươi & Vitamin C Sáng Da 28g	39.000	255.000	43.496	85	2
[Mini] Nước Tẩy Trang Simple Cho Da Dầu Mụn 100ml	29.000	200.000	58.297	86	2

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Điểm chung của năm sản phẩm là mức giảm giá 85–89%, cao hơn nhiều so với mức thông thường. Ba sản phẩm mặt nạ có giá niêm yết cao gấp 6–13 lần giá mô hình dự đoán, gợi ý giá niêm yết có thể bị đẩy lên để tạo cảm giác giảm sâu, hoặc là lỗi dữ liệu; cần mở trang sản phẩm để xác nhận.

Cả năm sản phẩm đều giảm 85–89% so với giá niêm yết, và giá niêm yết của ba sản phẩm mặt nạ cao gấp 6 đến 13 lần giá mô hình dự đoán. File `kiem_tra_thu_cong.csv` liệt

kê 10 sản phẩm điểm cao nhất kèm đường dẫn để người mở trang và ghi kết luận (lỗi dữ liệu, giá lạ thật hay báo nhầm).

Ý nghĩa kinh doanh

Danh sách 68 sản phẩm (và 154 sản phẩm lệch giá so với mô hình) cho nhóm dữ liệu biết nên kiểm tra sản phẩm nào trước khi phân tích tiếp, thay vì rà hơn 5.000 dòng. Website hiển thị cả hai danh sách ở trang "Phát hiện bất thường".

Mức độ tin cậy và hạn chế

- Không có đáp án đúng/sai nên chưa đo được độ chính xác; đây là danh sách để kiểm tra, không phải kết luận. Nhóm chưa ghi kết luận vào file kiểm tra thủ công.

- Tỷ lệ kỳ vọng 2% do nhóm chọn trước, nên Isolation Forest và LOF luôn gắn cờ gần 2% (104 trong 5.172) dù dữ liệu sạch hay bẩn.

- Đặc trưng `lech` phụ thuộc vào mô hình giá: nếu mô hình giá sai ở loại nào (ví dụ thiết bị), sản phẩm loại đó dễ bị gắn cờ oan.

6.4 Đánh giá và so sánh kết quả

Trong bốn mô hình, mô hình dự đoán giá đáng tin nhất (R^2 kiểm định chéo 0,839), mô hình hết hàng chỉ dùng được để sàng danh sách cần kiểm tra (AUC 0,813; precision 0,241), còn phân khúc và bất thường là công cụ khám phá không có đáp án để chấm điểm tuyệt đối.

Bảng 6.14. So sánh tổng hợp bốn mô hình

Mô hình	Thuật toán	Số mẫu	Thước đo chính	Kết quả	So với mốc	Độ tin cậy
Phân khúc thương hiệu	K-Means, K = 4	213 (Hasaki), 132 (Cocolux)	Silhouette	0,179 (Hasaki), 0,299 (Cocolux)	So với Hierarchical: 0,162 và 0,270	Trung bình (Cocolux), thấp (Hasaki)
Dự đoán giá niêm yết	Random Forest	8.152	R^2, sai lệch trung vị	R^2 kiểm định chéo 0,839; test 0,863; sai lệch 14,6%	Ridge: 0,765; 23,8%	Khá cao
Dự đoán hết hàng	Random Forest + quy tắc hàng cận hạn	5.263 hàng thường (Hasaki)	AUC, recall, precision	AUC 0,813; recall 0,724; precision 0,241	Logistic: AUC 0,786; ngẫu nhiên: precision 0,12	Trung bình thấp

Phát hiện bất thường	IQR, Isolation Forest, LOF	5.172	Số phương pháp đồng ý	68 sản phẩm (≥ 2 phương pháp); 12 sản phẩm (cả 3)	Không có	Chưa kiểm chứng thủ công

Nguồn: Tác giả tự tổng hợp.

Ý nghĩa: Bảng đặt bốn mô hình cạnh nhau để thấy mức độ tin cậy khác nhau: mô hình giá có kết quả tốt và vượt mốc rõ nên có thể dùng làm giá tham chiếu; mô hình hết hàng chỉ nên dùng để sàng lọc danh sách cần kiểm tra; phân khúc và phát hiện bất thường là công cụ khám phá, kết quả cần người đọc lại và kiểm chứng.

Độ tin cậy của quy trình

Kết quả có thể chạy lại: mọi bước dùng hạt ngẫu nhiên 42, toàn bộ bước 0 đến 7 chạy mất khoảng 5 phút (316 giây khi chạy thử từ bản tải mới từ GitHub). Bước 6 kiểm tra hàm `du_doan.py` mà website gọi và thấy 100% dự đoán trùng với kết quả lúc huấn luyện, nên số trên website khớp với số trong chương này. Hai mô hình có giám sát chọn mô hình theo kiểm định chéo, và ngưỡng hết hàng cũng được chọn mà không nhìn tập kiểm tra.

Hạn chế chính

Dữ liệu là ảnh chụp một thời điểm, không có chuỗi thời gian, nên mô hình không dự báo xu hướng.

Thương hiệu gần như quyết định giá dự đoán; thương hiệu mới chưa từng xuất hiện sẽ được đoán kém hơn.

Mô hình hết hàng chỉ dùng cho Hasaki và còn nhiều báo động giả; phân khúc Hasaki chồng lấn; danh sách bất thường chưa được kiểm chứng thủ công.

CHƯƠNG 7. XÂY DỰNG HỆ THỐNG WEBSITE

7.1. Kiến trúc hệ thống

7.1.1. Mô hình kiến trúc tổng thể

Hệ thống được phát triển bằng ngôn ngữ Python và thư viện Streamlit theo kiến trúc phân lớp về mặt chức năng. Mặc dù Streamlit tổ chức giao diện và xử lý yêu cầu trong cùng ứng dụng Python thay vì tách riêng frontend và REST API, mã nguồn vẫn phân chia rõ các thành phần: lớp giao diện, lớp xử lý nghiệp vụ - phân tích và lớp truy cập dữ liệu. Cách thiết kế này phù hợp với mục tiêu xây dựng website phân tích dữ liệu trong phạm vi đồ án, đồng thời tạo điều kiện bảo trì, bổ sung chức năng và thay đổi nguồn lưu trữ.

Ở lớp giao diện, app.py là điểm khởi chạy ứng dụng, chịu trách nhiệm khởi tạo website, kiểm tra trạng thái đăng nhập, xây dựng thanh điều hướng và hiển thị trang tương ứng với vai trò người dùng. ui.py chứa quy tắc thiết kế giao diện, màu sắc, cách trình bày bảng, thẻ chỉ số và biểu đồ. Các trang dashboard được tổ chức trong dashboards.py; trang quản trị sản phẩm, tài khoản và sao lưu nằm trong admin_pages.py; chức năng học máy được tổ chức riêng trong ml_pages.py.

Ở lớp xử lý dữ liệu, data_loader.py nhận dữ liệu sản phẩm từ cơ sở dữ liệu, chuẩn hóa và tạo các biến phục vụ phân tích như tên nguồn hiển thị, xuất xứ, dung tích quy đổi, số tiền giảm giá, khoảng giá và mức giảm. dashboards.py sử dụng Pandas, NumPy và Plotly để tổng hợp số liệu, xây dựng chỉ tiêu và biểu đồ. Lớp truy cập dữ liệu do db.py đảm nhiệm, cung cấp các thao tác thống nhất với sản phẩm và người dùng; mongo_store.py hiện thực các thao tác lưu trữ trên MongoDB.

Luồng xử lý cơ bản được thực hiện như sau: người dùng truy cập website và đăng nhập; ứng dụng kiểm tra quyền; khi chọn một trang, chương trình đọc dữ liệu qua db.py, xử lý bằng Pandas và hiển thị kết quả dưới dạng bảng, thẻ KPI hoặc biểu đồ. Đối với thao tác thêm, sửa, xóa, dữ liệu nhập được kiểm tra điều kiện hợp lệ trước khi ghi vào cơ sở dữ liệu; khi thành công, giao diện được làm mới để phản ánh dữ liệu đã cập nhật.

7.1.2. Công nghệ và thư viện sử dụng

Bảng 7.1. Các công nghệ và thư viện được sử dụng trong hệ thống website phân tích dữ liệu mỹ phẩm Hasaki - Cocolux

Thành phần	Công nghệ	Vai trò trong hệ thống
Ngôn ngữ và framework	Python, Streamlit	Xây dựng website, biểu mẫu và điều hướng trang

Xử lý dữ liệu	Pandas, NumPy	Lọc, chuẩn hóa, tổng hợp và tính chỉ số
Trực quan hóa	Plotly	Biểu diễn dữ liệu bằng các biểu đồ tương tác
Cơ sở dữ liệu chính	MongoDB, PyMongo	Lưu trữ sản phẩm và người dùng; thực hiện CRUD
Xuất dữ liệu	CSV, Excel (openpyxl)	Cung cấp tệp tải xuống phục vụ báo cáo
Phân tích nâng cao	scikit-learn và mô-đun ML	Hỗ trợ các trang mô hình khi đủ tệp mô hình và dữ liệu

Nguồn: Tác giả tự tổng hợp.

Các thư viện được khai báo trong requirements.txt để thống nhất môi trường cài đặt. Trong cấu hình dự kiến, MongoDB Atlas đóng vai trò cơ sở dữ liệu trung tâm; các thông tin kết nối được đặt trong cấu hình riêng của Streamlit, gồm MONGO_URI, MONGO_DB và MONGO_PRODUCTS_COLLECTION. Khi không cấu hình MongoDB, mã nguồn có hỗ trợ lưu trữ bằng SQLite. Ngược lại, nếu đã cấu hình MongoDB nhưng kết nối thất bại, ứng dụng hiển thị lỗi và không tự ý chuyển sang SQLite, nhằm tránh tình trạng người dùng thao tác trên cơ sở dữ liệu không mong muốn.

7.1.3. Tổ chức dữ liệu và các mô-đun

Dữ liệu cốt lõi gồm hai nhóm: dữ liệu sản phẩm và dữ liệu tài khoản. Một sản phẩm có các thuộc tính như id, source, category_group, category, name, brand, product_code, price, price_original, discount_pct, rating, review_count, in_stock, volume, origin, url và scraped_at. Nhóm tài khoản gồm id, username, password_hash, full_name và role. Trong MongoDB, hai nhóm tương ứng với collection sản phẩm được cấu hình và collection users; hệ thống còn sử dụng các collection hỗ trợ như audit_log để lưu lịch sử thay đổi và counters để quản lý mã định danh.

Việc tách mô-đun giúp mỗi phần đảm nhiệm một nhiệm vụ cụ thể: app.py điều phối; dashboards.py trình bày các phân tích; data_loader.py chuẩn hóa dữ liệu; admin_pages.py quản trị; db.py và mongo_store.py kết nối và cập nhật CSDL; security.py kiểm tra hiệu lực phiên; ml_pages.py hiển thị kết quả mô hình. Cấu trúc này hạn chế phụ thuộc trực tiếp giữa giao diện với câu lệnh truy vấn và thuận lợi khi mở rộng.

Đoạn mã kết nối và xử lý dữ liệu

```
    def get_data():
if "_data_snapshot" not in st.session_state:
```

```
        st.session_state["_data_snapshot"] = enrich(db.get_products())
    return st.session_state["_data_snapshot"].copy()
```

Hàm get_data() trong data_loader.py là điểm trung gian giữa cơ sở dữ liệu và giao diện. Hàm gọi db.get_products() để lấy danh sách sản phẩm, sau đó dùng enrich() để tạo các thuộc tính phục vụ phân tích. Bản dữ liệu được lưu tạm trong st.session_state cho một lượt làm việc nhằm hạn chế việc đọc lặp lại; thao tác trả về .copy() giúp các trang xử lý dữ liệu mà không làm thay đổi trực tiếp bản lưu tạm.

7.1.4. Thiết kế cơ sở dữ liệu và quy trình lưu trữ

Website không lưu dữ liệu trực tiếp vào giao diện Streamlit. Dữ liệu sản phẩm, tài khoản người dùng và các bản ghi quản lý được lưu tại lớp cơ sở dữ liệu; website chỉ truy xuất khi cần. Mã nguồn tổ chức truy cập cơ sở dữ liệu qua db.py và mongo_store.py, giúp tách phần xử lý nghiệp vụ khỏi công nghệ lưu trữ cụ thể.

Lựa chọn cơ sở dữ liệu MongoDB và SQLite

MongoDB được sử dụng khi đã thiết lập MONGO_URI. Ứng dụng kết nối tới cơ sở dữ liệu được chỉ định bằng MONGO_DB; collection sản phẩm mặc định là product_clean. MongoDB thích hợp để lưu các bản ghi sản phẩm dưới dạng document linh hoạt, cho phép mở rộng trường dữ liệu mà vẫn hỗ trợ truy vấn, đánh chỉ mục và cập nhật theo ID.

SQLite được triển khai trong class SQLiteStore, lưu bảng users và products trong tệp app.db để phục vụ vận hành cục bộ khi chưa cấu hình MongoDB. SQLite không phải cơ chế tự động chuyển đổi khi MONGO DB bị mất kết nối. Hàm get_store(), nếu đã khai báo MONGO_URI nhưng kết nối MongoDB thất bại, chương trình phát sinh lỗi kết nối và yêu cầu kiểm tra cấu hình, nhằm tránh ghi dữ liệu nhầm vào cơ sở dữ liệu khác.

Cấu trúc dữ liệu lưu trữ

Collection product_clean lưu mã định danh id; nguồn source (Hasaki hoặc Cocolux); nhóm category_group, danh mục category; tên name, thương hiệu brand, mã product_code; giá bán price, giá niêm yết price_original, tỷ lệ giảm discount_pct; điểm rating, số lượt review_count; tình trạng in_stock; dung tích volume, xuất xứ origin, liên kết url và thời điểm scraped_at. Collection/bảng users lưu id, username, password_hash, full_name và role. Trong MongoDB còn có counters để cấp ID tăng dần và audit_log để ghi nhận lịch sử thao tác.

Quy trình lưu trữ và truy xuất

Nguồn dữ liệu được nhóm thu thập, làm sạch và chuẩn hóa trước khi đưa vào MongoDB. Website đọc dữ liệu từ collection đang cấu hình qua db.get_products(), tiếp tục áp dụng normalize_products() và enrich() để chuyển kiểu dữ liệu, tính trường dẫn xuất phục vụ

báo cáo. Khi người dùng thêm, sửa hoặc xóa, hệ thống kiểm tra tính hợp lệ, kiểm tra quyền rồi cập nhật trực tiếp vào cơ sở dữ liệu; đây không phải thao tác sửa ngược tệp Excel ban đầu.

Mã lựa chọn cơ sở dữ liệu trong db.py

```
        uri, db_name = _mongo_settings()
if uri:
    _store = MongoStore(uri, db_name)
else:
    _store = SQLiteStore()
```

Đoạn mã rút gọn cho thấy lựa chọn công nghệ lưu trữ phụ thuộc biến cấu hình MONGO_URI. Mã đầy đủ dùng cơ chế khóa để khởi tạo một đối tượng lưu trữ chung và phát sinh ConnectionError khi không thể kết nối MongoDB đã cấu hình; vì vậy giao diện và các chức năng CRUD có thể dùng chung lớp truy cập mà không cần gọi trực tiếp MongoClient ở mỗi trang.

Mã kết nối MongoDB và tạo chỉ mục trong mongo_store.py

```
        self.client = MongoClient(uri, serverSelectionTimeoutMS=5000,
connectTimeoutMS=5000)
self.client.admin.command("ping")
self.db = self.client[db_name]
self.collection("products").create_index("id", unique=True)
self.db.users.create_index("username", unique=True)
```

MongoClient khởi tạo kết nối thông qua chuỗi URI, còn ping kiểm tra khả năng tiếp cận máy chủ trước khi phục vụ yêu cầu. Chỉ mục unique trên id và username hỗ trợ truy vấn hiệu quả và tránh trùng mã định danh hoặc tên đăng nhập. Mã còn tạo chỉ mục category_group để hỗ trợ khai thác danh mục, cùng chỉ mục thời gian at cho lịch sử thay đổi.

Mã làm sạch và bổ sung dữ liệu trong data_loader.py

```
        df["nguon"]                          =                        df["source"].str.title()
df["giam_gia_vnd"]          =          df["price_original"]          -          df["price"]
df["dung_tich"]                        =                      df["volume"].map(_dung_tich)
df["scraped_at"] = pd.to_datetime(df["scraped_at"], errors="coerce")
```

Các trường tính toán phục vụ phân tích được tạo ở bộ nhớ, không bắt buộc ghi thêm vào MongoDB. Chẳng hạn giam_gia_vnd được tính từ hai mức giá; _dung_tich nhận diện đơn vị ml, g và quy đổi về số đo thống nhất theo từng nhóm đơn vị; scraped_at được chuyển sang dạng thời gian. Nhờ vậy, dữ liệu gốc và dữ liệu phục vụ trực quan hóa được phân tách.

Đồng bộ dữ liệu, sao lưu và an toàn ghi

Mỗi lượt chạy giao diện sử dụng một bản chụp dữ liệu trong st.session_state để các biểu đồ trên cùng lượt hiển thị nhất quán; khi người dùng tải lại trang hoặc thao tác thay đổi dữ liệu, bản chụp sẽ được làm mới. MongoStore sử dụng transaction để gộp thao tác ghi với

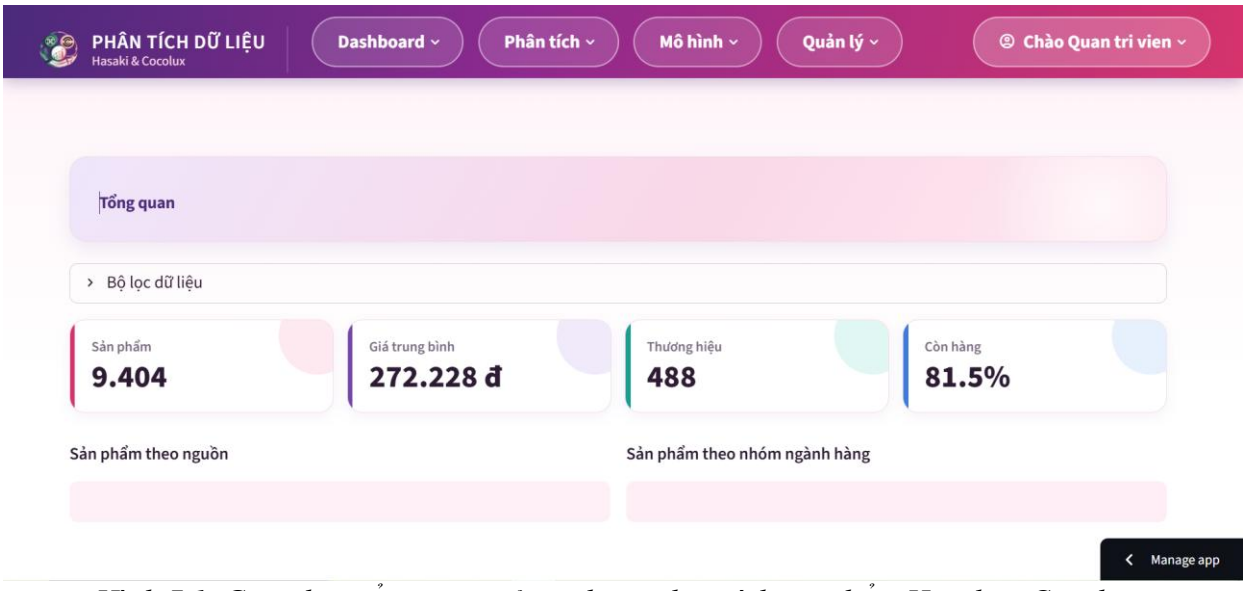
nhật ký audit_log; đồng thời kiểm tra trùng URL hoặc cặp nguồn–mã sản phẩm. Trang Sao lưu & phục hồi tạo bản sao định dạng .json.gz, kiểm tra cấu trúc trước khi phục hồi và duy trì ít nhất một tài khoản quản trị. Đây là tính năng quản lý dữ liệu khác với chức năng xuất báo cáo CSV/Excel.

7.2. Giao diện và chức năng chính

7.2.1. Nguyên tắc thiết kế giao diện

Giao diện được thiết kế theo hướng trực quan, nhất quán và dễ thao tác đối với người dùng không chuyên về lập trình. Website sử dụng thanh điều hướng ở phía trên, hiển thị tên hệ thống, các nhóm trang chức năng và thông tin tài khoản. Sau khi đăng nhập thành công, danh mục được tạo theo quyền của người dùng. Các thành phần hiển thị được thiết kế bằng Streamlit kết hợp CSS tùy chỉnh, sử dụng tông tím - hồng, thẻ thông tin, bảng dữ liệu và biểu đồ, đồng thời có điều chỉnh bố cục cho màn hình nhỏ.

Ở cấp trang, nội dung được tổ chức theo trình tự từ tổng quan đến chi tiết. Các thẻ KPI giúp nhận biết nhanh quy mô dữ liệu; bộ lọc hỗ trợ khoanh vùng thông tin; bảng cho phép quan sát từng sản phẩm; biểu đồ phục vụ so sánh, nhận diện cấu trúc và xu hướng trong bộ dữ liệu hiện có. Định dạng tiền Việt Nam đồng, số lượng và nhãn tiếng Việt giúp kết quả dễ hiểu và thuận lợi khi sử dụng trong báo cáo học phần.



Hình 7.1. Giao diện tổng quan của website phân tích mỹ phẩm Hasaki – Cocolux

Nguồn: Tác giả tự tổng hợp.

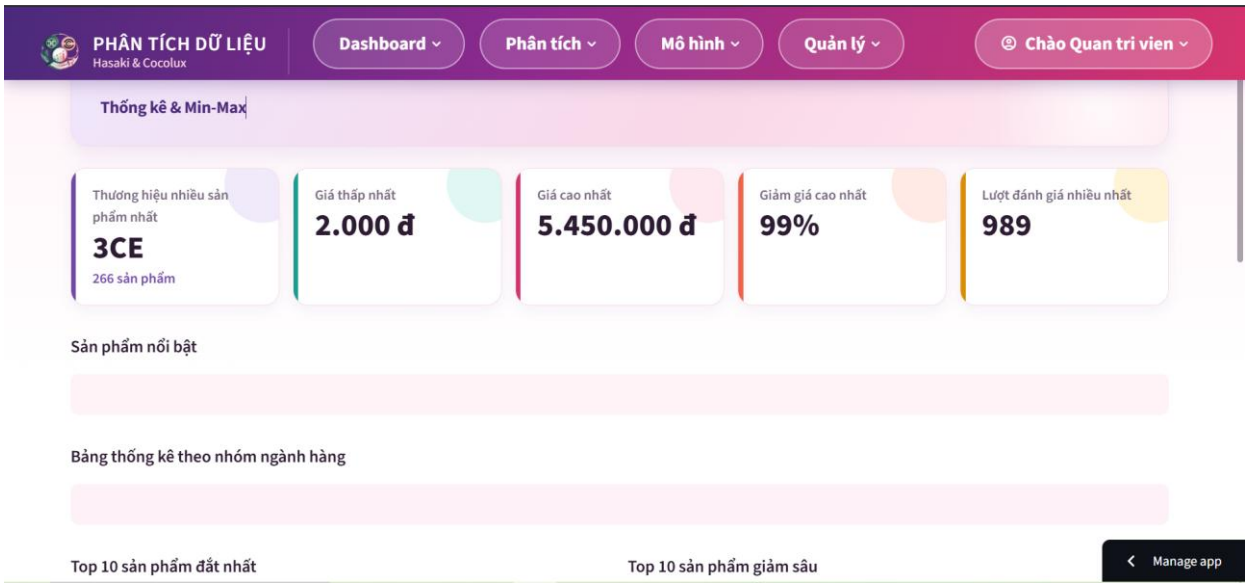
7.2.2. Các nhóm chức năng

Nhóm Dashboard gồm sáu trang: Tổng quan thị trường; Thống kê & Min-Max; So sánh Hasaki – Cocolux; Thương hiệu & Xuất xứ; Giá & Khuyến mãi; Đánh giá & Tồn kho. Các trang này thể hiện những góc nhìn khác nhau về danh mục sản phẩm, giá bán, chương

trình giảm giá, mức đánh giá và tình trạng còn hàng. Ví dụ, hệ thống tính tổng số sản phẩm, số thương hiệu, giá trung bình, trung vị, giá thấp nhất – cao nhất, tỷ lệ còn hàng và các chỉ số đánh giá để phục vụ mô tả thị trường.

Nhóm Phân tích bao gồm Khám phá dữ liệu, Chất lượng dữ liệu và Xuất báo cáo. Trang Khám phá dữ liệu cho phép tìm kiếm và kết hợp nhiều điều kiện lọc; trang Chất lượng dữ liệu thống kê tỷ lệ thiếu, sản phẩm có liên kết trùng, trường giá bất hợp lý và một số tình huống cần kiểm tra; trang Xuất báo cáo chuẩn bị các tệp kết quả ở định dạng CSV hoặc Excel. Đây là nhóm chức năng liên kết trực tiếp hoạt động đọc dữ liệu với yêu cầu khai thác và trình bày kết quả.

Nhóm Mô hình gồm Phân khúc thương hiệu, Dự đoán giá, Dự đoán hết hàng và Phát hiện bất thường. Các trang được triển khai trong ml_pages.py, sử dụng kết quả hoặc tệp mô hình ở thư mục liên quan. Vì vậy, việc sử dụng đầy đủ nhóm chức năng này phụ thuộc vào sự hiện diện của dữ liệu và các tệp mô hình đã được tạo trước đó. Nhóm Quản lý bao gồm Quản lý dữ liệu, Quản trị người dùng và Sao lưu & phục hồi; các trang chỉ được hiển thị cho vai trò phù hợp.



Hình 7.2. Giao diện dashboard trực quan hóa dữ liệu

Nguồn: Tác giả tự tổng hợp.

7.2.3. Luồng tương tác của người dùng

Khi mở website, người dùng trước tiên nhìn thấy giao diện đăng nhập hoặc đăng ký. Sau khi xác thực thành công, trang chủ hiển thị cùng các nhóm điều hướng được cấp phép. Người dùng lựa chọn dashboard để quan sát chỉ số, truy cập Khám phá dữ liệu để áp dụng điều kiện lọc hoặc chuyển sang Xuất báo cáo để tải dữ liệu. Đối với tài khoản có quyền quản lý, thanh điều hướng bổ sung các trang cập nhật sản phẩm; riêng quản trị viên có quyền quản

lý người dùng và dữ liệu sao lưu. Cách tổ chức luồng này tránh việc đưa quá nhiều chức năng lên một màn hình và làm rõ trách nhiệm từng vai trò.

Mã điều phối menu theo vai trò trong app.py

```
        TAT_CA = ("admin", "editor", "viewer")
QUAN_LY = ("admin", "editor")
PAGES = [
    ("Dashboard", "Tổng quan thị trường", page_tong_quan, "tong-quan", TAT_CA),
    ("Quản lý", "Quản lý dữ liệu", page_crud, "crud", QUAN_LY),]
```

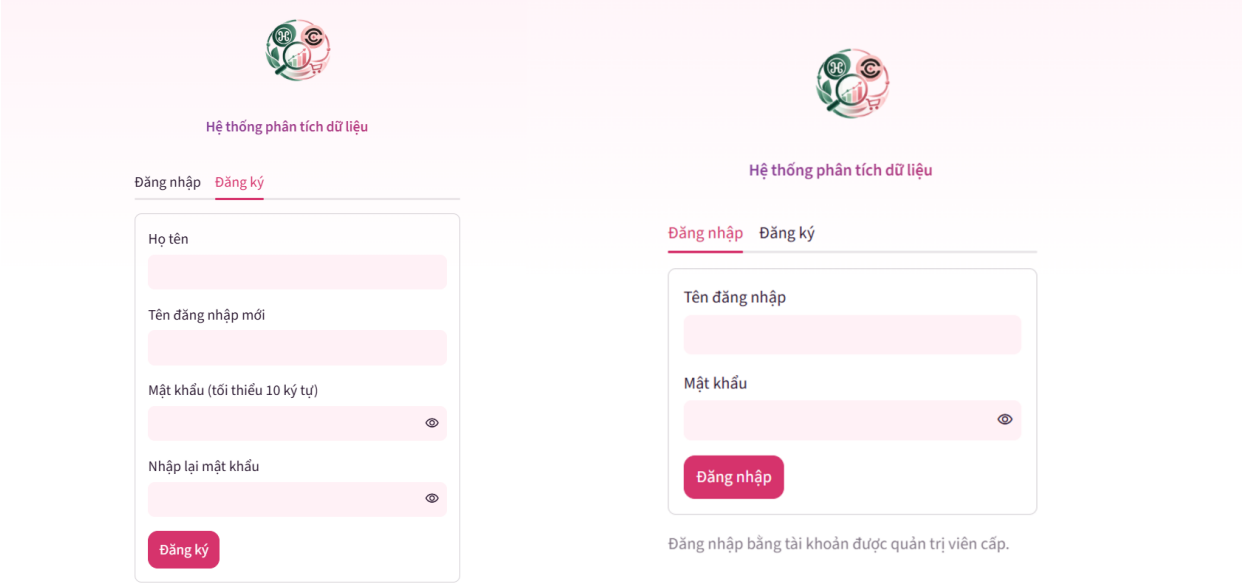
Mỗi mục trong PAGES gồm nhóm điều hướng, tên trang, hàm xử lý, đường dẫn và các vai trò được phép xem. Cách tổ chức này giúp bổ sung trang mới bằng cấu hình tập trung; đồng thời tạo sự nhất quán giữa menu hiển thị và quyền của tài khoản. Bên cạnh kiểm soát menu, hàm xử lý dữ liệu vẫn kiểm tra quyền trước thao tác ghi.

7.3. Đăng nhập và phân quyền người dùng

7.3.1. Quy trình đăng nhập và đăng ký

Website xây dựng giao diện xác thực với hai tab Đăng nhập và Đăng ký. Người dùng đăng nhập bằng tên tài khoản và mật khẩu; hệ thống gọi hàm verify_user() để tra cứu tài khoản và kiểm tra mật khẩu. Nếu thông tin không đúng, giao diện thông báo lỗi. Khi xác thực thành công, thông tin phiên được ghi vào st.session_state để duy trì trạng thái đăng nhập giữa các lần Streamlit chạy lại ứng dụng.

Ở chức năng đăng ký, người dùng nhập họ tên, tên đăng nhập, mật khẩu và xác nhận mật khẩu. Hệ thống kiểm tra việc nhập trùng khớp và yêu cầu mật khẩu có ít nhất 10 ký tự. Tài khoản tự đăng ký được cấp quyền viewer mặc định; việc nâng quyền lên editor hoặc admin chỉ do quản trị viên thực hiện. Tên đăng nhập được kiểm tra để hạn chế trùng lặp trong hệ thống.



Hình 7.3. Giao diện đăng nhập và đăng ký tài khoản

Nguồn: Tác giả tự tổng hợp.

7.3.2. Cơ chế bảo vệ tài khoản

Mật khẩu không được lưu dưới dạng văn bản thuần túy. Mã nguồn sử dụng hàm dẫn xuất khóa PBKDF2-HMAC-SHA256 với salt ngẫu nhiên, thực hiện 100.000 vòng lặp trước khi lưu giá trị băm. Khi đăng nhập, mật khẩu nhập vào được xử lý theo cùng cơ chế để so sánh với giá trị đã lưu. Hàm security.current_user() còn đối chiếu phiên hiện tại với tài khoản trong cơ sở dữ liệu: nếu tài khoản đã bị xóa hoặc mật khẩu đã thay đổi, phiên không còn được chấp nhận. Đây là một lớp bảo vệ bổ sung đối với các thay đổi quyền truy cập.

Trên thanh tài khoản, người dùng có thể xem thông tin của mình, thay đổi mật khẩu, làm mới dữ liệu và đăng xuất. Đổi mật khẩu yêu cầu cung cấp mật khẩu cũ chính xác và mật khẩu mới hợp lệ; đăng xuất sẽ xóa trạng thái phiên trong Streamlit. Bên cạnh việc ẩn trang không phù hợp, các thao tác nhạy cảm còn gọi hàm require_role() tại lớp xử lý nhằm kiểm tra quyền trước khi ghi dữ liệu.

7.3.3. Phân quyền theo vai trò

Bảng 7.2. Phân quyền sử dụng các chức năng website theo ba nhóm người dùng

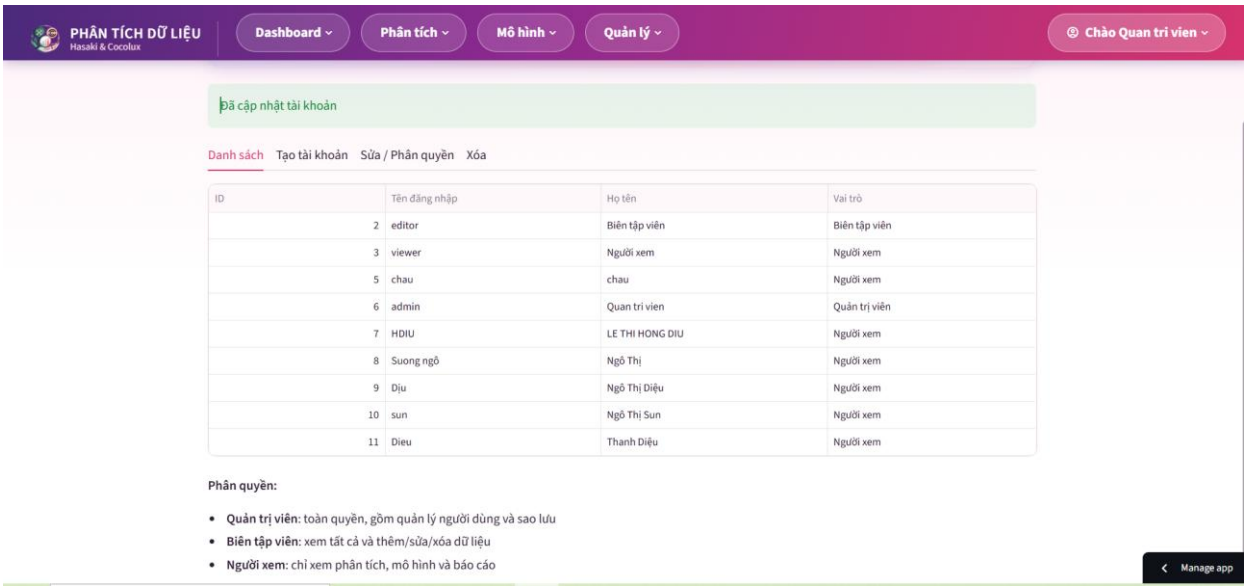
Chức năng	Admin	Editor	Viewer
Dashboard, khám phá và báo cáo	Có	Có	Có
Các trang mô hình	Có	Có	Có

Xem/thêm/sửa/xóa sản phẩm	Có	Có	Không
Quản trị tài khoản và phân quyền	Có	Không	Không
Sao lưu, phục hồi dữ liệu	Có	Không	Không

Nguồn: Tác giả tự tổng hợp.

Hệ thống sử dụng ba vai trò: admin (quản trị viên), editor (biên tập viên) và viewer (người xem). Quản trị viên có quyền cao nhất, bao gồm quản lý sản phẩm, tài khoản, phân quyền và sao lưu – phục hồi. Biên tập viên được thao tác CRUD đối với sản phẩm nhưng không được quản lý tài khoản. Người xem chỉ có quyền khai thác các trang phân tích, mô hình và báo cáo. Cơ chế này tuân theo nguyên tắc cấp quyền phù hợp với nhiệm vụ, giảm rủi ro sửa hoặc xóa nhầm dữ liệu.

Trang Quản trị người dùng cho phép quản trị viên xem danh sách tài khoản, tạo mới, cập nhật họ tên, điều chỉnh vai trò, đặt lại mật khẩu và xóa tài khoản. Các điều kiện bảo vệ bao gồm không cho tự xóa tài khoản đang đăng nhập và phải duy trì ít nhất một tài khoản quản trị viên trong hệ thống. Đây là những kiểm tra cần thiết để tránh việc mất hoàn toàn quyền quản lý.



Hình 7.4. Giao diện quản lý tài khoản và phân quyền người dùng

Nguồn: Tác giả tự tổng hợp.

Đoạn mã xác thực và kiểm soát quyền

```
def verify_user(username, password):
rows = get_store().fetch("users", username=username)
```

```
    if rows and check_password(password, rows[0]["password_hash"]):
        return {"id": rows[0]["id"], "role": rows[0]["role"], ...}
    return None

def require_role(*roles):
    user = current_user()
    if not user or user["role"] not in roles:
        raise PermissionError("Không có quyền truy cập")
```

Đoạn mã rút gọn từ db.py cho thấy quá trình đăng nhập đối chiếu mật khẩu nhập vào với giá trị băm đã lưu, thay vì so sánh hay lưu mật khẩu dưới dạng văn bản thuần. Sau khi đăng nhập, require_role() kiểm tra người dùng hiện hành và vai trò được phép thực hiện chức năng. Chẳng hạn, trang quản lý sản phẩm yêu cầu admin hoặc editor, còn trang quản lý người dùng chỉ dành cho admin. Phần dấu ba chấm trong ví dụ thể hiện các trường thông tin bổ sung đã lược bỏ để dễ trình bày.

Mã băm mật khẩu và xác thực phiên đăng nhập

```
    salt = os.urandom(16)
    digest = hashlib.pbkdf2_hmac("sha256", password.encode(), salt, 100_000)
    return salt.hex() + "$" + digest.hex()
```

Mỗi mật khẩu được kết hợp với salt ngẫu nhiên rồi băm lặp 100.000 lần bằng PBKDF2-HMAC-SHA256. Cơ sở dữ liệu lưu giá trị băm kèm salt, thay vì lưu mật khẩu gốc. Trong security.py, current_user() đọc tài khoản hiện tại từ cơ sở dữ liệu và đối chiếu token phiên với password_hash; do đó tài khoản bị xóa hoặc thay đổi mật khẩu có thể bị vô hiệu hóa phiên cũ.

```
    def require_role(*roles):
    user = current_user()
    if not user or user["role"] not in roles:
        raise PermissionError("Phiên đăng nhập hoặc quyền truy cập đã thay đổi.")
```

Hàm require_role() kiểm tra quyền tại thời điểm thao tác, không chỉ ẩn nút trên giao diện. Các hàm add_product(), update_product() và delete_product() đều yêu cầu vai trò admin hoặc editor; quản trị người dùng và sao lưu dành cho admin. Đây là cơ chế bảo vệ dữ liệu ở tầng nghiệp vụ.

7.4. Tìm kiếm và lọc dữ liệu

7.4.1. Mục tiêu và phạm vi tìm kiếm

Chức năng tìm kiếm và lọc dữ liệu giúp người dùng thu hẹp số lượng sản phẩm trong bộ dữ liệu tổng hợp từ Hasaki và Cocolux. Thay vì quan sát toàn bộ danh mục, người dùng có thể lựa chọn những sản phẩm có đặc điểm phù hợp với mục tiêu phân tích, chẳng hạn so sánh sản phẩm cùng thương hiệu, quan sát khoảng giá hoặc xác định nhóm có mức giảm giá cao.

Trang Khám phá & Lọc dữ liệu sử dụng dữ liệu đã đọc và chuẩn hóa để phản hồi trực tiếp theo các bộ lọc.

7.4.2. Các điều kiện lọc

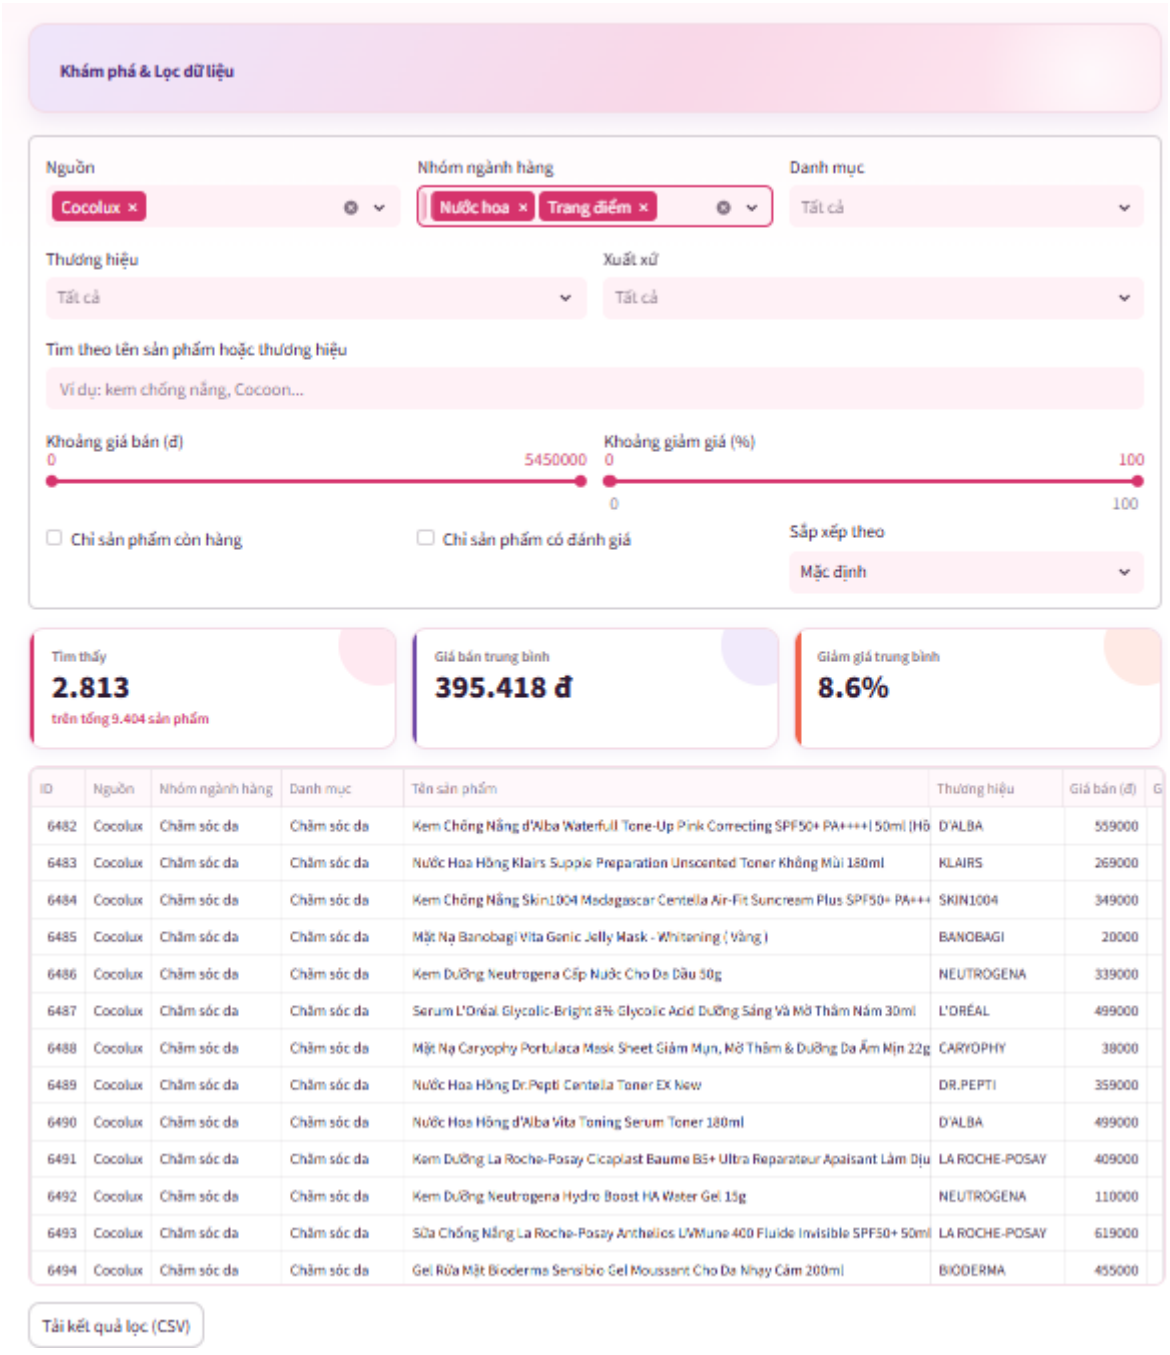
Bộ lọc của trang Khám phá dữ liệu gồm nguồn dữ liệu, nhóm ngành hàng, danh mục, thương hiệu, xuất xứ, khoảng giá bán và khoảng phần trăm giảm giá. Ngoài ra, hệ thống hỗ trợ tìm kiếm theo một phần tên sản phẩm hoặc thương hiệu; lựa chọn chỉ hiển thị sản phẩm còn hàng hoặc sản phẩm đã có đánh giá; và sắp xếp kết quả theo giá tăng dần, giá giảm dần, mức giảm giá cao nhất hoặc số lượt đánh giá nhiều nhất. Khi để trống một trường lựa chọn, trường đó không giới hạn kết quả; khi chọn nhiều điều kiện, hệ thống áp dụng đồng thời để thu hẹp tập dữ liệu.

Ví dụ, để phân tích nhóm kem chống nắng thuộc một thương hiệu cụ thể, người dùng chọn danh mục liên quan, chọn thương hiệu, giới hạn giá bán và bật điều kiện còn hàng. Kết quả thu được bao gồm bảng sản phẩm phù hợp, số lượng tìm thấy, giá bán trung bình và tỷ lệ giảm giá trung bình. Việc kết hợp các điều kiện giúp phân tích sản phẩm theo các tiêu chí nhất quán thay vì chỉ tìm kiếm bằng từ khóa riêng lẻ.

7.4.3. Xử lý và hiển thị kết quả

Trong mã nguồn, phương thức lọc theo từ khóa sử dụng phép kiểm tra chuỗi không phân biệt chữ hoa - chữ thường và không xử lý từ khóa như biểu thức chính quy. Dữ liệu được lọc bằng Pandas theo từng điều kiện; đối với chỉ số số học, hệ thống chỉ tính trên tập kết quả còn lại sau lọc. Bảng kết quả hiển thị các thuộc tính cần thiết như nguồn, nhóm ngành, tên, thương hiệu, giá bán, giá niêm yết, tỷ lệ giảm giá, điểm đánh giá, số lượt đánh giá, tình trạng còn hàng và liên kết sản phẩm.

Trang này có nút “Tải kết quả lọc (CSV)”, cho phép tải đúng tập sản phẩm đang được hiển thị theo điều kiện đã chọn dưới dạng tệp ket_qua_loc.csv. Mặt khác, trang Quản lý dữ liệu có ô tìm riêng theo tên, thương hiệu hoặc ID, thực hiện tìm kiếm trên bộ sản phẩm trong cơ sở dữ liệu và phân trang tối đa 100 sản phẩm/trang. Hai cơ chế phục vụ hai mục đích khác nhau: tìm kiếm đa điều kiện để phân tích và tra cứu phân trang để quản lý bản ghi.



Hình 7.5. Giao diện tìm kiếm và lọc sản phẩm

Nguồn: Tác giả tự tổng hợp.

Đoạn mã lọc và sắp xếp sản phẩm

```
        kq = df[df["price"].between(*khoang_gia)
         & df["discount_pct"].between(*khoang_giam)]
if thuong_hieu:
    kq = kq[kq["brand"].isin(thuong_hieu)]
if tu_khoa.strip():
    t = tu_khoa.strip()
    kq = kq[kq["name"].str.contains(
        t, case=False, regex=False)]
```

Trong app.py, Pandas được sử dụng để kết hợp các điều kiện lọc trên cùng một bảng dữ liệu. between() giới hạn khoảng giá và tỷ lệ giảm giá, isin() lựa chọn một hoặc nhiều thương hiệu, còn str.contains() thực hiện tìm kiếm chuỗi không phân biệt chữ hoa – chữ thường. Đoạn minh họa chỉ giữ phần tìm theo tên; chương trình thực tế còn tìm theo thương hiệu, lọc nguồn, danh mục, xuất xứ, trạng thái tồn kho và đánh giá. Kết quả sau lọc được dùng để tính số lượng sản phẩm và các chỉ tiêu trung bình.

Ở trang quản lý, hàm product_page() ưu tiên truy vấn trực tiếp MongoDB để chỉ lấy số bản ghi của trang hiện tại (mặc định 100 sản phẩm/trang), thay vì tải toàn bộ collection. re.escape() xử lý từ khóa như chuỗi thông thường; $options: i giúp tìm kiếm không phân biệt chữ hoa/chữ thường; skip() và limit() điều khiển phân trang. Nếu từ khóa là số nguyên, mã đầy đủ còn tìm chính xác theo id.

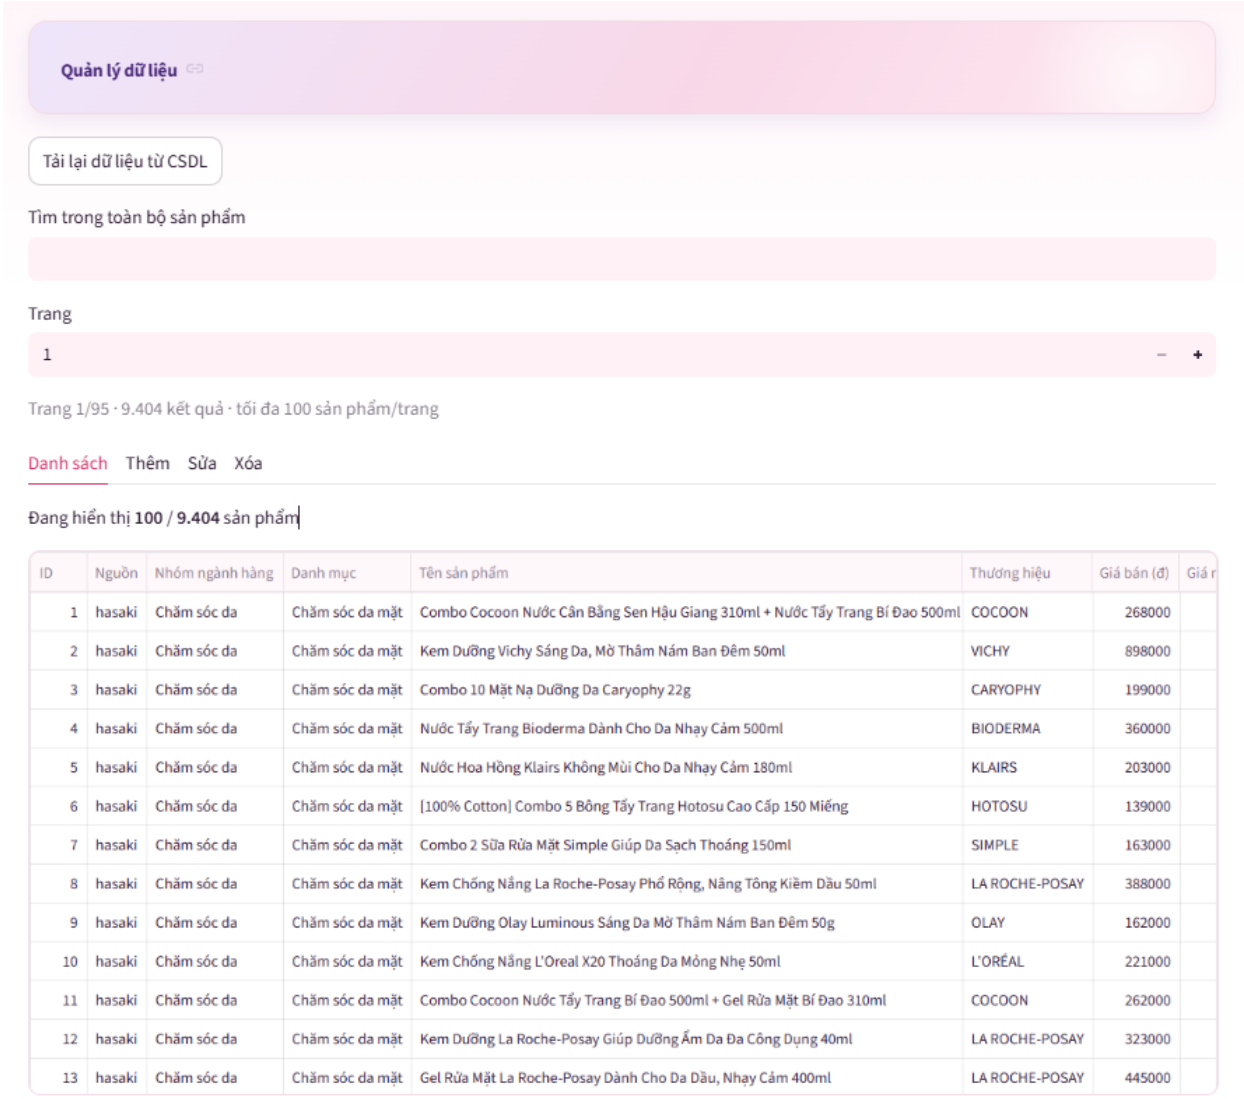
7.5. Quản lý dữ liệu

7.5.1. Tổng quan chức năng CRUD

CRUD là nhóm thao tác Create (thêm), Read (xem), Update (sửa) và Delete (xóa), cho phép duy trì bộ dữ liệu sản phẩm ngay trên giao diện website. Chức năng được triển khai tại trang Quản lý dữ liệu trong admin_pages.py và chỉ cấp cho admin, editor. Giao diện được chia thành bốn tab “Danh sách”, “Thêm”, “Sửa” và “Xóa”, giúp người dùng xác định rõ thao tác cần thực hiện. Mọi thao tác được chuyển đến các hàm xử lý trong db.py thay vì ghi trực tiếp từ giao diện.

7.5.2. Xem và tra cứu dữ liệu

Tab Danh sách hiển thị các bản ghi sản phẩm dưới dạng bảng. Đối với MongoDB, hàm product_page() đếm số bản ghi phù hợp, thực hiện truy vấn tìm kiếm và lấy dữ liệu theo trang, với giới hạn mặc định là 100 dòng/trang. Việc phân trang tránh phải truyền toàn bộ tập dữ liệu lên giao diện quản trị trong một lần, đặc biệt khi số sản phẩm lớn. Người dùng có thể nhập tên, thương hiệu hoặc ID để nhanh chóng tìm sản phẩm cần sửa, xóa.



ID	Nguồn	Nhóm ngành hàng	Danh mục	Tên sản phẩm	Thương hiệu	Giá bán (đ)	Giá r
1	hasaki	Chăm sóc da	Chăm sóc da mặt	Combo Cocoon Nước Cân Bằng Sen Hậu Giang 310ml + Nước Tẩy Trang Bí Đao 500ml	COCOON	268000	
2	hasaki	Chăm sóc da	Chăm sóc da mặt	Kem Dưỡng Vichy Sáng Da, Mờ Thâm Nám Ban Đêm 50ml	VICHY	898000	
3	hasaki	Chăm sóc da	Chăm sóc da mặt	Combo 10 Mặt Nạ Dưỡng Da Caryophy 22g	CARYOPHY	199000	
4	hasaki	Chăm sóc da	Chăm sóc da mặt	Nước Tẩy Trang Bioderma Dành Cho Da Nhạy Cảm 500ml	BIODERMA	360000	
5	hasaki	Chăm sóc da	Chăm sóc da mặt	Nước Hoa Hồng Klairs Không Mùi Cho Da Nhạy Cảm 180ml	KLAIRS	203000	
6	hasaki	Chăm sóc da	Chăm sóc da mặt	[100% Cotton] Combo 5 Bông Tẩy Trang Hotosu Cao Cấp 150 Miếng	HOTOSU	139000	
7	hasaki	Chăm sóc da	Chăm sóc da mặt	Combo 2 Sữa Rửa Mặt Simple Giúp Da Sạch Thoáng 150ml	SIMPLE	163000	
8	hasaki	Chăm sóc da	Chăm sóc da mặt	Kem Chống Nắng La Roche-Posay Phổ Rộng, Nâng Tông Kiềm Dầu 50ml	LA ROCHE-POSAY	388000	
9	hasaki	Chăm sóc da	Chăm sóc da mặt	Kem Dưỡng Olay Luminous Sáng Da Mờ Thâm Nám Ban Đêm 50g	OLAY	162000	
10	hasaki	Chăm sóc da	Chăm sóc da mặt	Kem Chống Nắng L'Oreal X20 Thoáng Da Mỏng Nhẹ 50ml	L'ORÉAL	221000	
11	hasaki	Chăm sóc da	Chăm sóc da mặt	Combo Cocoon Nước Tẩy Trang Bí Đao 500ml + Gel Rửa Mặt Bí Đao 310ml	COCOON	262000	
12	hasaki	Chăm sóc da	Chăm sóc da mặt	Kem Dưỡng La Roche-Posay Giúp Dưỡng Ẩm Da Đa Công Dụng 40ml	LA ROCHE-POSAY	323000	
13	hasaki	Chăm sóc da	Chăm sóc da mặt	Gel Rửa Mặt La Roche-Posay Dành Cho Da Dầu, Nhạy Cảm 400ml	LA ROCHE-POSAY	445000	

Hình 7.6. Giao diện danh sách và tra cứu sản phẩm

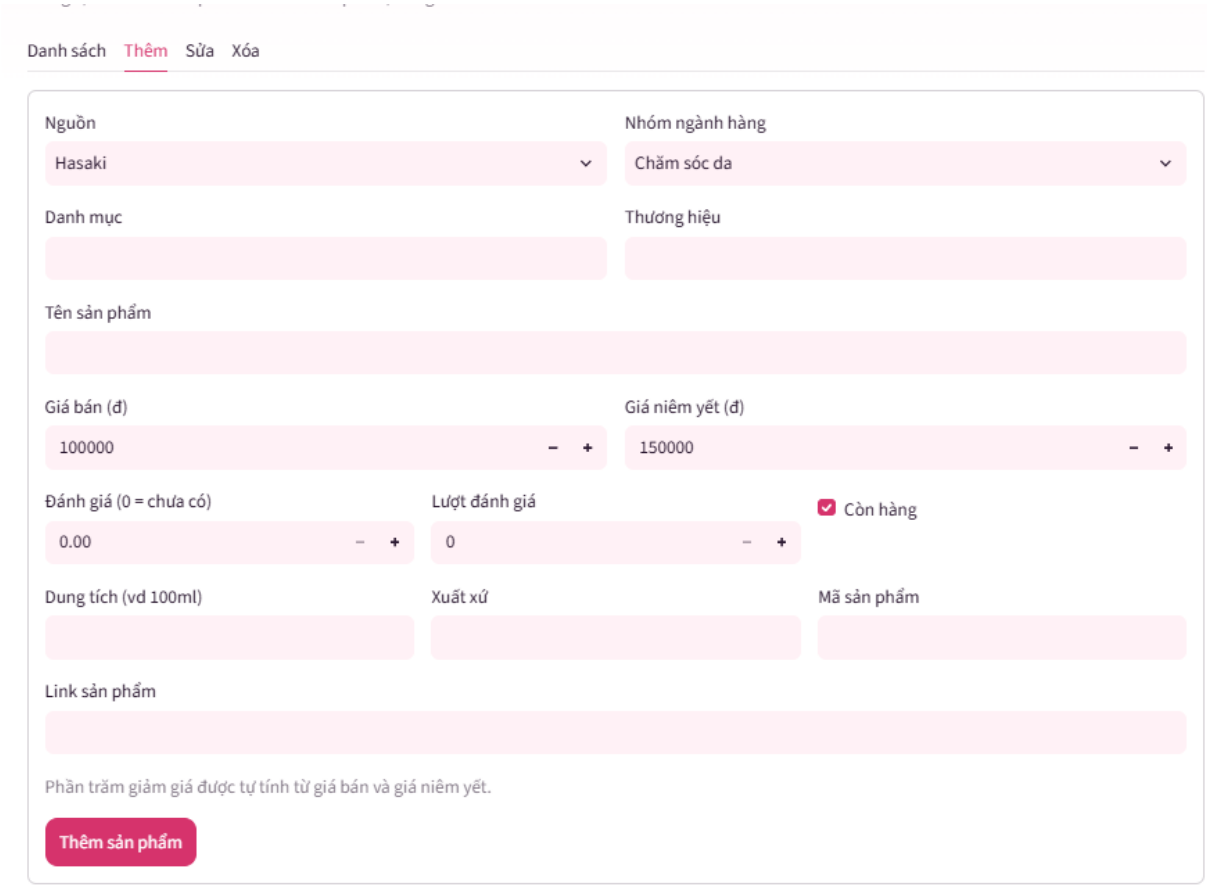
Nguồn: Tác giả tự tổng hợp.

7.5.3. Thêm sản phẩm (Create)

Ở tab Thêm, biểu mẫu yêu cầu hoặc cho phép nhập nguồn dữ liệu, nhóm ngành hàng, danh mục, thương hiệu, tên sản phẩm, giá bán, giá niêm yết, điểm đánh giá, số lượt đánh giá, tình trạng còn hàng, dung tích, xuất xứ, mã sản phẩm và đường dẫn. Tỷ lệ giảm giá được tính tự động từ giá niêm yết và giá bán theo công thức: Tỷ lệ giảm giá (%) = (1 − Giá bán/Giá niêm yết) × 100; trong mã nguồn, kết quả được làm tròn thành số nguyên.

Trước khi thêm mới, hệ thống kiểm tra tên sản phẩm và nguồn không được rỗng; giá bán không âm; giá niêm yết lớn hơn 0; giá bán không lớn hơn giá niêm yết; điểm đánh giá trong khoảng từ 0 đến 5; số lượt đánh giá không âm. Điểm đánh giá bằng 0 được lưu như chưa có đánh giá. Trong cơ chế MongoDB, hệ thống còn kiểm tra trùng liên kết sản phẩm hoặc

trùng cặp nguồn – mã sản phẩm theo logic đã lập trình. Bản ghi hợp lệ được cấp ID, thêm thời điểm ghi nhận và lưu vào collection sản phẩm.



Hình 7.7. Giao diện thêm mới sản phẩm

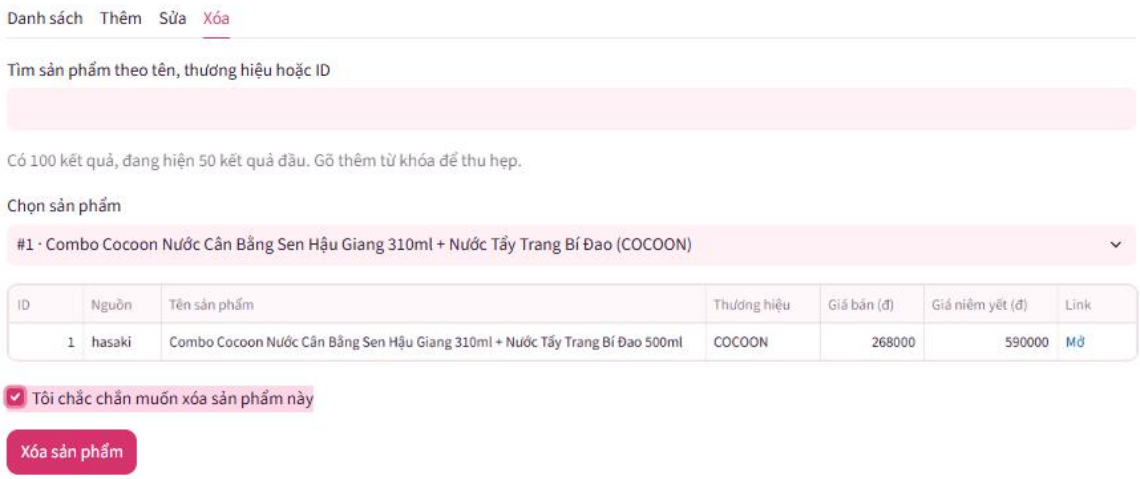
Nguồn: Tác giả tự tổng hợp.

7.5.4. Cập nhật sản phẩm (Update)

Tại tab Sửa, người quản lý sử dụng ô tìm kiếm và danh sách chọn để xác định sản phẩm, sau đó chỉnh sửa thông tin trên biểu mẫu đã được điền dữ liệu hiện tại. Khi chọn "Lưu thay đổi", hệ thống áp dụng lại các bước kiểm tra hợp lệ tương tự chức năng thêm. Việc cập nhật được thực hiện theo ID; nếu bản ghi đã bị xóa hoặc không còn tồn tại, hệ thống thông báo để người dùng tải lại dữ liệu. Sau khi sửa thành công, ứng dụng chạy lại giao diện để hiển thị giá trị mới, giúp thống nhất thông tin giữa trang quản lý và các trang phân tích.

7.5.5. Xóa sản phẩm (Delete)

Ở tab Xóa, hệ thống hiển thị bản ghi được chọn cùng các thông tin định danh quan trọng để người dùng đối chiếu. Nút xóa chỉ có thể sử dụng khi người thao tác đánh dấu ô xác nhận "Tôi chắc chắn muốn xóa sản phẩm này". Sau khi xác nhận, chương trình gọi hàm xóa theo ID, ghi kết quả và làm mới trang. Đây là thao tác xóa bản ghi thực sự khỏi cơ sở dữ liệu, vì vậy yêu cầu đúng quyền và xác nhận trước khi thực hiện.



Hình 7.8. Giao diện xóa sản phẩm

Nguồn: Tác giả tự tổng hợp.

7.5.6. Tính nhất quán, nhật ký và sao lưu

Sau khi người dùng thực hiện chỉnh sửa hoặc xóa sản phẩm trên website, hệ thống sẽ cập nhật trực tiếp dữ liệu vào MongoDB. Các thay đổi được lưu trữ trong cơ sở dữ liệu và đồng bộ với giao diện website, bảo đảm tính chính xác và nhất quán của dữ liệu.

Trong cấu hình MongoDB, mongo_store.py triển khai thao tác ghi bằng transaction để nhóm các bước cập nhật và ghi nhật ký thay đổi. Collection audit_log lưu thời điểm, tài khoản thực hiện, loại thao tác, collection và dữ liệu trước/sau khi thay đổi (không đưa password_hash vào nhật ký). Bên cạnh đó, hệ thống có trang Sao lưu & phục hồi dành cho admin, cho phép chuẩn bị bản sao dữ liệu, tải về dưới dạng JSON nén .json.gz đối với MongoDB và phục hồi sau khi xác nhận. Quá trình phục hồi thực hiện kiểm tra dữ liệu hợp lệ, có ít nhất một quản trị viên, nhằm hạn chế tình trạng thay thế bằng bộ dữ liệu không sử dụng được.

Đoạn mã CRUD sản phẩm

```
    with st.form("form_add"):
data = _product_form("add", df)
if st.form_submit_button("Thêm sản phẩm"):
    ok, msg = db.add_product(data)
    if ok:
        st.rerun()
```

```
else:
    st.error(msg)
```

Trong admin_pages.py, biểu mẫu Streamlit thu thập các trường sản phẩm và chỉ ghi dữ liệu khi người dùng nhấn nút xác nhận. Lệnh db.add_product(data) chuyển công việc kiểm tra và lưu trữ xuống lớp cơ sở dữ liệu; kết quả trả về gồm trạng thái thành công và thông báo. Nếu thêm thành công, st.rerun() cập nhật trang để hiển thị dữ liệu mới. Các thao tác sửa và xóa cũng gọi hàm xử lý tương ứng của db.py; riêng xóa yêu cầu tích xác nhận trước khi nút xóa được kích hoạt.

Code kiểm tra dữ liệu trước khi lưu

```
    if not text("name"):
    return None, "Tên sản phẩm không được để trống"
if price < 0 or original <= 0 or price > original:
    return None, "Giá bán hoặc giá niêm yết không hợp lệ"
"discount_pct": round((1 - price / original) * 100)
```

_clean_product() đảm bảo sản phẩm có tên và nguồn hợp lệ, giá không âm, giá niêm yết dương, giá bán không vượt giá niêm yết, rating trong khoảng 0-5 và số lượt đánh giá không âm. Tỷ lệ giảm giá được tính tự động thay vì nhập thủ công để tránh sai lệch giữa các trường giá. Sau khi kiểm tra, chức năng thêm và sửa mới thực sự ghi dữ liệu xuống kho lưu trữ.

Code ghi dữ liệu và nhật ký trong MongoStore

```
    self.collection(table).insert_one(row, session=session)
self._audit(session, "insert", table, after=row)
# Với cập nhật: update_one(..., {"$set": fields}, session=session)
```

Lệnh insert_one() ghi một document mới; update_one() sửa các thuộc tính được chọn bằng toán tử $set. Việc truyền session cho các thao tác cho phép lưu bản ghi và audit_log trong cùng transaction. MongoStore còn cấp id tăng dần thông qua collection counters để giao diện có mã số nhất quán và kiểm tra trùng URL hoặc mã sản phẩm theo nguồn trước khi ghi.

Code sao lưu và khôi phục

db.backup_bytes() đóng gói dữ liệu để tải tệp dự phòng; db.validate_backup() kiểm tra tính hợp lệ trước khi phục hồi; db.replace_tables() thực hiện thay thế dữ liệu có kiểm soát. Quy trình này khác thao tác Delete thông thường vì có thể ảnh hưởng toàn bộ bảng/collection, nên được đặt trong khu vực quản trị và yêu cầu xác thực vai trò admin.

7.6. Xuất báo cáo thống kê

7.6.1. Mục đích của chức năng xuất báo cáo

Xuất báo cáo là bước chuyển kết quả khai thác dữ liệu từ giao diện website thành tệp có thể lưu trữ, chia sẻ và tiếp tục xử lý. Chức năng này hữu ích trong việc tổng hợp số liệu nhóm, đối chiếu kết quả trên bảng tính và chuẩn bị dữ liệu cho báo cáo môn học. Website triển

khai trang “Xuất báo cáo” cho tất cả vai trò đã đăng nhập, đồng thời cho phép tải riêng kết quả lọc từ trang Khám phá dữ liệu.

7.6.2. Nội dung thống kê được tổng hợp

Trước khi xuất báo cáo, ứng dụng lấy tập dữ liệu sản phẩm hiện có và tính các thống kê mô tả cho các trường số gồm giá bán, giá niêm yết, phần trăm giảm giá, điểm đánh giá, số lượt đánh giá và dung tích quy đổi. Thống kê được tạo bằng hàm describe() của Pandas, cung cấp các đại lượng như số quan sát hợp lệ, trung bình, độ lệch chuẩn, giá trị nhỏ nhất, các phân vị và giá trị lớn nhất. Hệ thống còn tổng hợp theo nguồn và nhóm ngành hàng để tính số sản phẩm, giá bán trung bình, mức giảm giá trung bình; tổng hợp theo thương hiệu để thống kê số sản phẩm, giá trung bình, giảm giá trung bình và tổng lượt đánh giá.

Các bảng tổng hợp phản ánh dữ liệu có trong cơ sở dữ liệu đang được ứng dụng sử dụng. Số liệu từ Hasaki và Cocolux ở đây chủ yếu là thông tin sản phẩm được thu thập, không mặc nhiên đại diện cho doanh số bán hàng, lượng giao dịch hay toàn bộ thị trường mỹ phẩm. Vì vậy, các kết luận khi trình bày cần được giới hạn trong phạm vi bộ dữ liệu nghiên cứu.

7.6.3. Xuất tệp CSV và Excel

Với định dạng CSV, người dùng nhấn “Tải CSV” để nhận tệp bao_cao.csv chứa danh sách sản phẩm với tên cột được chuyển thành tiếng Việt. Tệp được mã hóa UTF-8 có BOM nhằm hỗ trợ hiển thị tiếng Việt trong các phần mềm bảng tính. Khi cần báo cáo có nhiều bảng, người dùng chọn “Chuẩn bị file Excel” và sau đó tải tệp bao_cao.xlsx. Chương trình sử dụng bộ nhớ đệm BytesIO và thư viện openpyxl để tạo file Excel, không yêu cầu lưu tệp trung gian trên máy chủ.

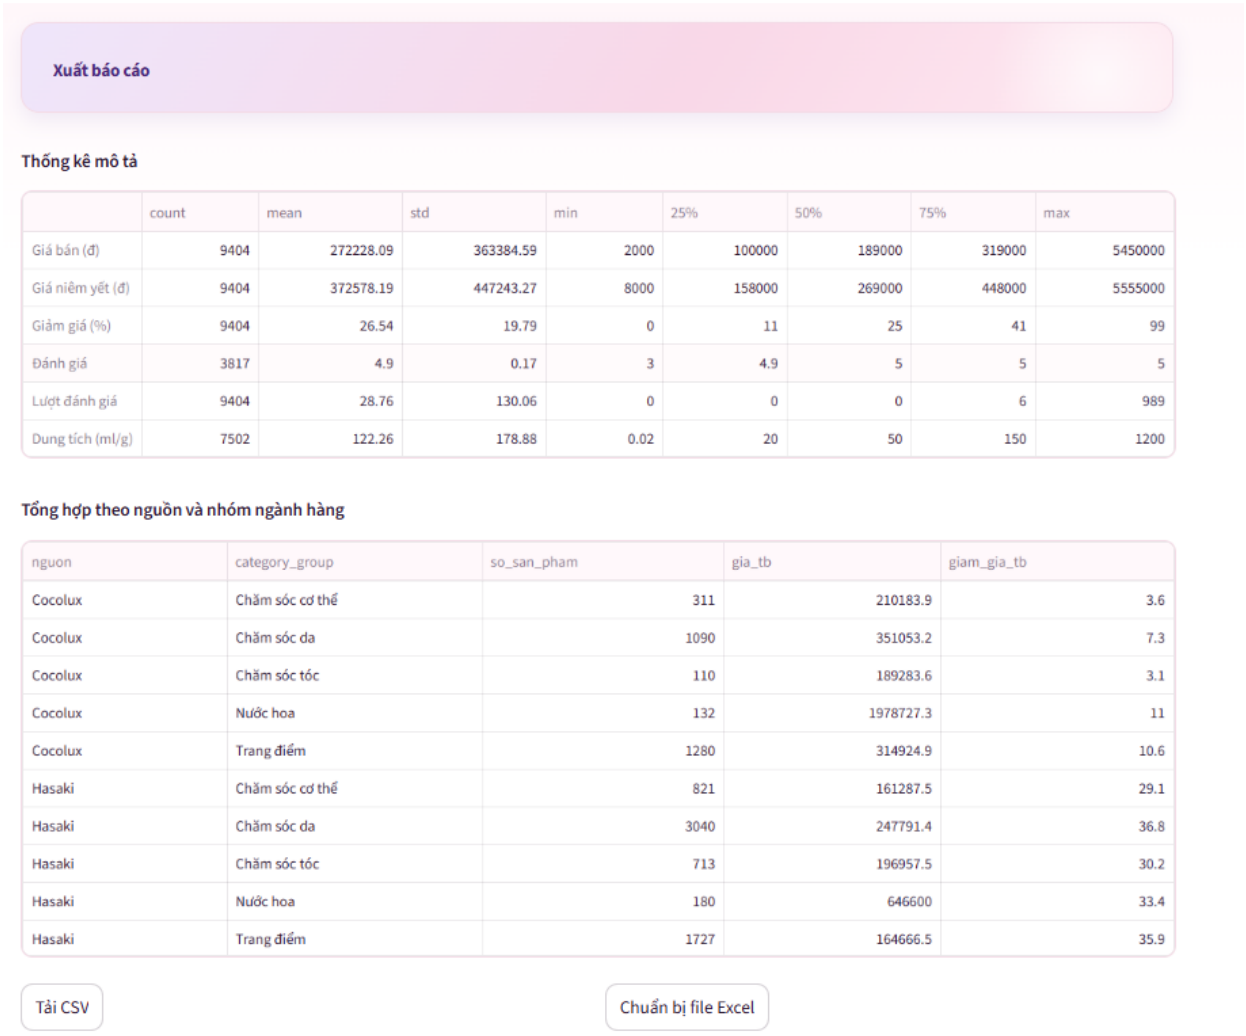
Bảng 7.3. Cấu trúc và nội dung các trang tính trong tệp báo cáo Excel xuất từ website

Sheet trong Excel	Nội dung
Du lieu	Bảng dữ liệu sản phẩm với tên cột hiển thị
Thong ke	Thống kê mô tả các thuộc tính số
Theo nhom	Số sản phẩm, giá và giảm giá trung bình theo nguồn và nhóm ngành
Theo thuong hieu	Thống kê số sản phẩm, giá, giảm giá và lượt đánh giá theo thương hiệu

Nguồn: Tác giả tự tổng hợp.

Ngoài báo cáo tổng hợp, tệp ket_qua_loc.csv ở trang Khám phá dữ liệu phản ánh các tiêu chí lọc mà người dùng đang áp dụng. Điều này giúp tạo những bộ dữ liệu nhỏ hơn phục

vụ các câu hỏi cụ thể, ví dụ so sánh một nhóm ngành hàng trong hai nguồn hoặc đánh giá chính sách giá của từng thương hiệu.



	count	mean	std	min	25%	50%	75%	max
Giá bán (đ)	9404	272228.09	363384.59	2000	100000	189000	319000	5450000
Giá niêm yết (đ)	9404	372578.19	447243.27	8000	158000	269000	448000	5555000
Giảm giá (%)	9404	26.54	19.79	0	11	25	41	99
Đánh giá	3817	4.9	0.17	3	4.9	5	5	5
Lượt đánh giá	9404	28.76	130.06	0	0	0	6	989
Dung tích (ml/g)	7502	122.26	178.88	0.02	20	50	150	1200

nguon	category_group	so_san_pham	gia_tb	giam_gia_tb
Cocolux	Chăm sóc cơ thể	311	210183.9	3.6
Cocolux	Chăm sóc da	1090	351053.2	7.3
Cocolux	Chăm sóc tóc	110	189283.6	3.1
Cocolux	Nước hoa	132	1978727.3	11
Cocolux	Trang điểm	1280	314924.9	10.6
Hasaki	Chăm sóc cơ thể	821	161287.5	29.1
Hasaki	Chăm sóc da	3040	247791.4	36.8
Hasaki	Chăm sóc tóc	713	196957.5	30.2
Hasaki	Nước hoa	180	646600	33.4
Hasaki	Trang điểm	1727	164666.5	35.9

Hình 7.9. Giao diện xuất báo cáo thống kê

Nguồn: Tác giả tự tổng hợp.

Đoạn mã xuất báo cáo

```
        so = df[["price", "discount_pct", "rating"]].describe().T
theo_nhom = df.groupby(["nguon", "category_group"]).agg(
    so_san_pham=("id", "size"),
    gia_tb=("price", "mean")
).reset_index()
xuat.to_excel(writer, sheet_name="Du lieu", index=False)
```

Trong app.py, describe() được dùng để tính thống kê mô tả như số quan sát, trung bình, độ lệch chuẩn và các giá trị phân vị; groupby() kết hợp agg() tổng hợp số lượng và giá trung bình theo nguồn cùng nhóm hàng. Mã nguồn thực tế còn tính các chỉ tiêu giảm giá, lượt đánh giá, đồng thời ghi bốn sheet Excel gồm Du lieu, Thong ke, Theo nhom và Theo thuong hieu.

Người dùng có thể tải dữ liệu CSV trực tiếp hoặc chuẩn bị rồi tải file Excel bằng các nút download_button của Streamlit.

Code tạo tệp Excel nhiều trang tính

```
    with pd.ExcelWriter(bo_nho, engine="openpyxl") as writer:
 xuat.to_excel(writer, sheet_name="Du lieu", index=False)
 so.to_excel(writer, sheet_name="Thong ke")
 theo_nhom.to_excel(writer, sheet_name="Theo nhom", index=False)
 theo_hang.to_excel(writer, sheet_name="Theo thuong hieu", index=False)
```

ExcelWriter kết hợp openpyxl tạo một tệp Excel trong bộ nhớ, gồm bốn sheet: dữ liệu chi tiết, thống kê mô tả, tổng hợp theo nguồn–nhóm ngành hàng và tổng hợp theo thương hiệu. Chức năng tải file được thực hiện qua st.download_button(), giúp người dùng lưu kết quả phân tích để tiếp tục xử lý hoặc đính kèm báo cáo mà không cần truy cập trực tiếp MongoDB.

CHƯƠNG 8. NHẬN ĐỊNH, ĐỀ XUẤT

8.1 Nhận định về dữ liệu

8.1.1 Nhận định về chất lượng và độ phủ của dữ liệu

Bộ dữ liệu sau khi làm sạch gồm 9.404 sản phẩm (Hasaki 6.481, Cocolux 2.923) thuộc 488 thương hiệu. Chỉ 12 bản ghi bị loại (khoảng 0,12% dữ liệu thô) và toàn bộ bản ghi đều đủ 7 trường bắt buộc. Dữ liệu vì thế đủ tin cậy để so sánh hai nhà bán lẻ theo nhóm ngành, thương hiệu, xuất xứ và mức giá.

Độ phủ của các trường không bắt buộc không đồng đều:

- Trường giá, giảm giá, thương hiệu, danh mục và tồn kho gần như đầy đủ, nên các kết luận về giá và khuyến mãi có độ tin cậy cao nhất.

- Trường rating thiếu ở 59,4% sản phẩm, origin thiếu 27,5% và volume thiếu 20,2%. Các kết luận về đánh giá và xuất xứ chỉ phản ánh phần dữ liệu có sẵn.

- Dữ liệu chủ yếu mô tả cách hai sàn niêm yết, định giá và khuyến mãi. Lượt đánh giá chỉ là chỉ báo gián tiếp về mức quan tâm, không đại diện cho doanh số.

8.1.2 Nhận định về đặc điểm thị trường

Cơ cấu ngành hàng tập trung: Chăm sóc da (43,9%) và Trang điểm (32,0%) chiếm gần 76% số sản phẩm, nên đây là nơi cạnh tranh gay gắt nhất. Nước hoa chỉ chiếm 3,3% nhưng có giá trị đơn vị cao nhất, với giá trung vị tại Cocolux là 1,95 triệu đồng, gấp hơn 6 lần Hasaki (322.500 đ).

Hai sàn theo hai chiến lược giá khác nhau: Hasaki cạnh tranh bằng khuyến mãi sâu và phổ biến, hướng đến khách nhạy cảm về giá. Cocolux giữ giá niêm yết và định vị cao hơn, thiên về thương hiệu và nước hoa cao cấp. Khoảng cách này xuất hiện ở mọi nhóm ngành, rõ nhất ở chăm sóc da (giảm trung bình 36,8% tại Hasaki so với 7,3% tại Cocolux).

Chỉ số	Hasaki	Cocolux
Giá trung vị	159.000 đ	259.000 đ
Chiết khấu trung bình	34,7%	8,4%
Tỷ lệ sản phẩm có giảm giá	98,9%	45,7%
Lượt đánh giá / sản phẩm	8,9	72,8
Tỷ lệ còn hàng	73,2%	99,97%

Khuyến mãi tập trung ở phân khúc giá thấp: Sản phẩm dưới 100.000 đ giảm trung bình 32,1%. Nhóm trên 2 triệu đồng (85 sản phẩm, 70 thuộc Cocolux) chỉ giảm trung bình 13,9% và không sản phẩm nào vượt 47%. Hàng cao cấp giữ giá tốt hơn.

Mức giảm sâu của Hasaki không chỉ do hàng cận date: Có 1.272 sản phẩm gắn nhãn HSD (13,5% dữ liệu), gần như toàn bộ thuộc Hasaki (1.246 sản phẩm, 19,2% danh mục của sàn). Nhóm HSD giảm trung bình 46,5%, so với 23,4% ở nhóm còn lại. Khi loại hàng HSD, chiết khấu trung bình của Hasaki vẫn đạt 31,7%. Vì vậy khi đánh giá khuyến mãi cần tách riêng hàng cận date.

Thị trường phân tán về thương hiệu: Mười thương hiệu lớn nhất chỉ chiếm 20,3% số sản phẩm. Có 213 trong 488 thương hiệu (43,6%) có không quá 5 sản phẩm. Quy mô danh mục và sức hút với khách hàng là hai chỉ số khác nhau: 3CE dẫn đầu về số sản phẩm (266) nhưng CLIO dẫn đầu về lượt đánh giá (33.988).

Xuất xứ mỗi nước có thế mạnh riêng: Hàn Quốc dẫn đầu (28,6% trong số sản phẩm có xuất xứ), tiếp theo là Mỹ (14,0%) và Việt Nam (13,9%). Hàn Quốc tập trung ở chăm sóc da và trang điểm. Pháp mạnh ở chăm sóc da và có giá trung vị cao nhất (285.500 đ). Trung Quốc gần như chỉ ở trang điểm với giá thấp (124.500 đ).

Đánh giá cao nhưng ít phân biệt: Điểm trung bình là 4,9/5, trong đó 54,9% sản phẩm có đánh giá đạt đúng 5,0 sao và chỉ 4,2% dưới 4,5 sao. Điểm sao khó dùng để phân biệt chất lượng, còn số lượt đánh giá mới phản ánh mức quan tâm. Tương tác tập trung ở Cocolux, nơi chiếm 78,7% tổng lượt đánh giá dù chỉ có 31,1% số sản phẩm.

Tồn kho Hasaki là điểm cần chú ý: Hasaki có 1.735 sản phẩm hết hàng (26,8%), còn Cocolux chỉ có 1 sản phẩm. Nước hoa có tỷ lệ còn hàng thấp nhất (72,1%). Một số sản phẩm hết hàng vẫn có nhiều đánh giá, như Klairs Nước Hoa Hồng Không Mùi bản mini (148 lượt) và nhóm Skin1004 Rau Má (102 lượt). Đây là dấu hiệu nhu cầu thực tế chưa được đáp ứng.

8.1.3 Nhận định về kết quả các mô hình học máy

Bốn mô hình có độ tin cậy khác nhau nên cần dùng đúng mục đích:

Bảng 8.1. Nhận định về kết quả các mô hình học máy

Mô hình	Kết quả chính	Nhận định
Dự đoán giá niêm yết (Random Forest)	R^2 kiểm định chéo 0,839; sai lệch trung vị 14,6% (Ridge: 23,8%)	Khá đáng tin, dùng được làm giá tham chiếu. Thương hiệu là yếu tố giải thích giá mạnh nhất (0,876), sàn bán gần như không ảnh hưởng, tức cùng một sản phẩm thì

		giá niêm yết ở hai sàn không khác nhau đáng kể
Dự đoán hết hàng (Hasaki)	AUC 0,813; recall 0,724; precision 0,241	Phù hợp để sàng lọc danh sách cần rà soát tồn kho, không phải kết luận. Cứ khoảng 4 cảnh báo mới có 1 cảnh báo đúng, gấp khoảng 2 lần mức đoán ngẫu nhiên
Phân khúc thương hiệu (K-Means, K = 4)	Silhouette 0,299 (Cocolux), 0,179 (Hasaki)	Cocolux tách nhóm khá rõ. Các nhóm Hasaki chồng lấn nên chỉ dùng để mô tả
Phát hiện bất thường	68 sản phẩm bị từ 2 phương pháp trở lên gắn cờ, 12 sản phẩm bị cả 3 phương pháp gắn cờ; thêm 154 sản phẩm lệch giá so với mô hình giá	Là danh sách ưu tiên kiểm tra, chưa kiểm chứng thủ công

Phát hiện đáng chú ý nhất là ba sản phẩm mặt nạ có giá niêm yết cao gấp 6-13 lần giá dự đoán và giảm 85-89%. Điều này gợi ý giá niêm yết có thể bị đẩy lên để tạo cảm giác giảm sâu.

Nhìn tổng thể, thương hiệu là yếu tố chi phối cả giá lẫn tình trạng hết hàng. Điều này phù hợp với đặc điểm của ngành mỹ phẩm, nơi uy tín thương hiệu quyết định mặt bằng giá.

8.2 Đề xuất kinh doanh

Các đề xuất dưới đây dựa trên dữ liệu niêm yết của hai sàn nên mang tính định hướng, cần thử nghiệm quy mô nhỏ (ví dụ A/B testing) trước khi áp dụng rộng.

8.2.1 Đối với thương hiệu và nhà phân phối

Bảng 8.2. Bảng đề xuất kinh doanh

Nhận định từ dữ liệu	Đề xuất
Hai sàn có chiến lược giá khác nhau (Hasaki giảm sâu, Cocolux giữ giá)	Phân kênh theo định vị: dòng phổ thông, nhạy cảm về giá ưu tiên Hasaki; dòng cao cấp, nước hoa ưu tiên Cocolux để bảo vệ hình ảnh thương hiệu
Hàng trên 2 triệu đồng chỉ giảm trung bình 13,9%, tối đa 47%	Thương hiệu cao cấp nên giữ giá, dùng quà tặng, combo hoặc tích điểm thay cho giảm giá trực tiếp

Mặt bằng giảm giá tại Hasaki là 34,7%, khách đã quen mức này	So sánh mức giảm của sản phẩm mình với trung bình nhóm ngành trên từng sàn để tránh giảm quá tay hoặc quá thấp
Mô hình giá bám sát giá thực (sai lệch trung vị 14,6%) và thương hiệu là yếu tố chính	Dùng mô hình làm giá tham chiếu khi định giá sản phẩm mới trong nhóm ngành tương tự. Với thiết bị, serum, toner (mô hình đoán thấp) thì đối chiếu thêm thủ công
Mỗi nhóm thương hiệu có hồ sơ riêng	Nhóm "nhiều sản phẩm, nhiều combo" đủ lớn để đàm phán chương trình combo. Nhóm "giảm giá sâu, giá cao" đang phụ thuộc khuyến mãi để bán, nên xây dựng thêm giá trị ngoài giá. Nhóm "hay hết hàng" cần rà soát chuỗi cung ứng
Phân khúc trên 700.000 đ chỉ chiếm 3,7% sản phẩm Hasaki (Cocolux 8,4%) và nước hoa Hasaki có giá trung vị thấp	Cân nhắc thử nghiệm đưa dòng cao cấp, nước hoa vào Hasaki, đây là phân khúc còn ít sản phẩm
Cocolux có nhiều đánh giá nhưng nhiều thương hiệu nhỏ chưa có đánh giá nào (nhóm "ít giảm giá, ít sản phẩm" có trung vị 0 đánh giá)	Thương hiệu nhỏ nên đầu tư thu thập đánh giá thật (tặng mẫu thử, nhắc đánh giá sau mua) để tăng độ tin cậy trước khách

8.2.2 Đối với nhà bán lẻ

Hasaki

Tách báo cáo khuyến mãi giữa hàng HSD và hàng thường. Cách này đo đúng hiệu quả chương trình, vì nhóm HSD giảm trung bình 46,5% và kéo mặt bằng chung lên.

Ưu tiên rà soát tồn kho. Với 26,8% sản phẩm hết hàng, nên dùng danh sách nguy cơ của mô hình để kiểm tra trước, bắt đầu từ các sản phẩm hết hàng nhưng nhiều đánh giá (Klairs, Skin1004) vì nhu cầu thực tế đã được chứng minh.

Kiểm tra các sản phẩm giảm 85–99% có giá niêm yết cao bất thường để giữ tính minh bạch về giá và niềm tin của khách.

Khai thác phân khúc cao cấp bằng cách mở rộng nước hoa và thương hiệu giá cao, vì phân khúc này còn nhỏ so với Cocolux.

Cocolux

Thử nghiệm khuyến mãi có chọn lọc ở nhóm trang điểm và chăm sóc da. Hiện 54,3% sản phẩm không giảm giá, trong khi đây là nhóm Hasaki cạnh tranh bằng mức giảm sâu.

Tận dụng lượng tương tác lớn (72,8 lượt đánh giá/sản phẩm) để làm nội dung so sánh, xếp hạng sản phẩm bán chạy và nổi bật các thương hiệu được quan tâm như CLIO, Peripera, Black Rouge.

Bổ sung thông tin xuất xứ và loại da cho sản phẩm. Hai trường này gần như trống ở Cocolux nhưng là tiêu chí khách hàng thường dùng để lọc.

Giữ định vị cao cấp, đặc biệt ở nước hoa, vì đây là điểm khác biệt rõ nhất so với Hasaki.

Cả hai sàn

Hiển thị đầy đủ dung tích, xuất xứ và đánh giá để khách dễ so sánh.

Khuyến khích khách đánh giá, vì 59,4% sản phẩm chưa có đánh giá nào.

Duy trì quy trình thu thập và theo dõi giá định kỳ trên hệ thống đã xây dựng để theo dõi đối thủ thay cho việc duyệt web thủ công.

8.3 Hạn chế

8.3.1 Hạn chế về dữ liệu

Dữ liệu là ảnh chụp một thời điểm: Toàn bộ dữ liệu được thu thập trong ngày 24-25/10/2026, không có chuỗi thời gian. Nhóm không theo dõi được biến động giá, chu kỳ khuyến mãi hay xu hướng và các mô hình không có khả năng dự báo theo thời gian.

Thiếu dữ liệu giao dịch và hành vi: Trường sold trống hoàn toàn ở cả hai nguồn và dữ liệu không có đơn hàng, khách hàng hay clickstream. Vì vậy không thể kết luận về doanh số, thị phần hay hiệu quả khuyến mãi, chỉ mô tả được cách hai sàn niêm yết và định giá.

Nhiều trường bị thiếu: rating thiếu 59,4%, origin thiếu 27,5% và volume thiếu 20,2%. Cocolux gần như không có xuất xứ và loại da, nên so sánh giữa hai sàn ở các trường này không cân bằng.

Giả định về tồn kho: Ô in_stock thiếu (1.736 ô) được quy ước là hết hàng. Nếu giả định này không đúng với một số sản phẩm thì tỷ lệ hết hàng của Hasaki có thể bị phóng đại.

Điểm đánh giá ít phân biệt: Điểm trung bình 4,9/5 và 54,9% sản phẩm có đánh giá đạt đúng 5,0 sao, nên rating khó dùng để so sánh chất lượng.

Chuẩn hóa chưa gộp theo công ty mẹ: Số thương hiệu giảm từ 616 xuống 488 nhưng nhóm không gộp các thương hiệu cùng tập đoàn.

8.3.2 Hạn chế về mô hình học máy

Mô hình giá phụ thuộc thương hiệu: Thương hiệu giải thích phần lớn giá (mức quan trọng 0,876), nên thương hiệu mới chưa từng xuất hiện sẽ bị đoán kém hơn. Mô hình đoán

thấp nhóm thiết bị (tỷ lệ 0,73), serum và toner. Hàng cận hạn [HSD] không được đưa vào mô hình.

Mô hình hết hàng chưa đủ mạnh: Precision chỉ 0,241 (cứ khoảng 4 cảnh báo mới có 1 cảnh báo đúng), recall tập kiểm tra 0,724 thấp hơn mục tiêu 0,8, và AUC chỉ hơn mô hình mốc Logistic khoảng 0,03. Mô hình chỉ áp dụng cho Hasaki vì Cocolux gần như không có hàng hết.

Phân khúc Hasaki chồng lấn: Silhouette 0,179 và ARI 0,415, DBSCAN coi 66 thương hiệu là điểm lẻ. Hai sàn dùng bộ đặc trưng khác nhau (Hasaki có thêm tỷ lệ hết hàng) nên không so trực tiếp được.

Danh sách bất thường chưa được kiểm chứng: Không có nhãn đúng/sai nên chưa đo được độ chính xác. Nhóm chọn trước tỷ lệ kỳ vọng 2% nên Isolation Forest và LOF luôn gắn cờ gần 2% dữ liệu. File kiểm tra thủ công chưa ghi kết luận. Đặc trưng lech phụ thuộc mô hình giá nên có thể gắn cờ oan cho các loại mà mô hình giá đoán sai.

8.3.3 Hạn chế về hệ thống

Chương trình thu thập phụ thuộc cấu trúc website. Khi Hasaki hoặc Cocolux đổi giao diện hay cách hiển thị, các quy tắc nhận dạng liên kết và đọc dữ liệu có thể phải sửa. Việc thu thập chạy lâu (Hasaki khoảng 12 giờ, Cocolux khoảng 7 giờ) và chưa được lên lịch tự động.

Website xây bằng Streamlit nên giao diện và xử lý nằm chung một ứng dụng, chưa tách frontend và REST API. Điều này đủ cho phạm vi đồ án nhưng khó mở rộng khi có nhiều người dùng đồng thời.

Các trang mô hình phụ thuộc tệp có sẵn. Chúng chỉ hoạt động khi các tệp mô hình và kết quả đã được tạo trước đó bằng chuỗi bước 0-7 và chưa tự cập nhật khi dữ liệu thay đổi.

Sao lưu mới được kiểm tra ở mức số lượng. Việc số document và chỉ mục sau phục hồi khớp (9.435 document, 0 lỗi) chưa chứng minh từng giá trị giống hệt; nhóm cũng mới phục hồi trên MongoDB cục bộ và chưa lên lịch sao lưu định kỳ.

Bảo mật còn ở mức cơ bản. Hệ thống có băm mật khẩu, phân quyền ba vai trò và kiểm tra phiên, nhưng chưa có xác thực hai lớp, giới hạn số lần đăng nhập sai hay giám sát truy cập.

8.4 Hướng phát triển

Bảng 8.3. Bảng hướng phát triển

Hướng phát triển	Nội dung	Lợi ích
Thu thập dữ liệu theo thời gian	Lên lịch thu thập định kỳ (hằng tuần hoặc theo đợt khuyến mãi), lưu lịch sử giá	Phân tích chu kỳ giảm giá, mùa vụ, dự báo giá và theo dõi phản ứng của đối thủ;

	theo scraped_at thay vì ghi đè	thêm bài toán chuỗi thời gian
Bổ sung dữ liệu hành vi	Thu thập nội dung bình luận, số lượng đã bán, tồn kho thực tế; kết hợp dữ liệu đơn hàng và khách hàng nếu có hợp tác với doanh nghiệp	Phân tích cảm xúc, dự báo nhu cầu, gợi ý sản phẩm, phân khúc khách hàng bằng RFM và luật kết hợp
Cải thiện mô hình	Kiểm chứng thủ công danh sách bất thường; bổ sung đặc trưng (mô tả, thành phần, loại da) cho mô hình giá và hết hàng; thử mô hình khác (gradient boosting có điều chỉnh tham số); mở rộng mô hình hết hàng sang Cocolux khi có đủ mẫu	Tăng độ chính xác, giảm báo động giả, giảm sai lệch ở thiết bị, serum, toner
Tự động hóa quy trình	Chạy trọn chuỗi thu thập, làm sạch, nạp MongoDB, huấn luyện lại mô hình theo lịch; cảnh báo khi phát hiện giá hoặc mức giảm bất thường	Giảm công sức thủ công, dữ liệu và mô hình luôn cập nhật
Nâng cấp hệ thống website	Tách API và giao diện; triển khai trên máy chủ hoặc dịch vụ đám mây; sao lưu định kỳ tự động; bổ sung xác thực hai lớp và giám sát truy cập	Đáp ứng nhiều người dùng, tăng bảo mật và độ ổn định
Mở rộng sang ngành hàng khác	Áp dụng cùng quy trình cho thực phẩm chức năng, mẹ và bé, thời trang	Chứng minh khả năng tái sử dụng của hệ thống

Trong quá trình mở rộng, nhóm tiếp tục tuân thủ đạo đức dữ liệu: chỉ thu thập dữ liệu công khai, nghỉ giữa các lần truy cập để tránh gây tải, không vượt CAPTCHA và ghi rõ nguồn khi công bố kết quả.

PHẦN KẾT LUẬN

Đề tài đã xây dựng được hệ thống hoàn chỉnh từ thu thập, làm sạch, lưu trữ đến phân tích và website. Nhóm thu được 9.416 bản ghi thô từ Hasaki và Cocolux, làm sạch còn 9.404 sản phẩm thuộc 488 thương hiệu, lưu trên MongoDB Atlas có sao lưu và phục hồi. Dữ liệu được trực quan hóa bằng dashboard Power BI 6 trang, phân tích bằng bốn mô hình học máy và triển khai trên website Streamlit có phân quyền, CRUD, tìm kiếm-lọc và xuất báo cáo.

Kết quả chính cho thấy Hasaki cạnh tranh bằng khuyến mãi sâu (chiết khấu trung bình 34,7%, giá trung vị 159.000 đ), còn Cocolux giữ giá và định vị cao hơn (8,4%, 259.000 đ). Thương hiệu chi phối cả giá lẫn tình trạng hết hàng. Mô hình giá đáng tin nhất (R^2 kiểm định chéo 0,839), còn mô hình hết hàng và danh sách bất thường phù hợp để sàng lọc.

Dữ liệu chỉ là ảnh chụp một thời điểm và chưa có thông tin giao dịch, nên kết quả mô tả cách hai sàn niêm yết và định giá, chưa phản ánh doanh số. Giá trị lớn nhất của đề tài là một quy trình có thể chạy lại và mở rộng. Khi bổ sung dữ liệu theo thời gian và các nguồn mới, hệ thống có thể trở thành công cụ theo dõi thị trường mỹ phẩm, hỗ trợ ra quyết định kinh doanh.

TÀI LIỆU THAM KHẢO

Metric (2026). *[Mới nhất] Báo cáo thị trường Làm đẹp: Xu hướng tăng trưởng từ sản lượng sang giá trị. Metric Insights.* Truy cập tại: **https://metric.vn/insights/bao-cao-thi-truong-lam-dep-tren-tmdt-xu-huong-tang-truong-tu-san-luong-sang-gia-tri/**